

Chapitre 16

Classer un nouveau client

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Correction — Exercice 1


- (a) $|0,4 - (-1,2)| = 1,6$; $|0,4 - 0,1| = 0,3$; $|0,4 - 1,5| = 1,1$.
(b) La distance la plus faible est 0,3, vers B : le client est affecté au groupe B.



- (c) La règle **bayésienne**, qui pondère la distance par les probabilités a priori (les effectifs relatifs) de chaque groupe : elle demanderait davantage de « preuves » (une distance plus faible) pour affecter un client au groupe C, minoritaire, qu'au groupe B, majoritaire.

Correction — Exercice 2

- (a) Groupe A : $40/50 = 80\%$. Groupe B : $20/50 = 40\%$. Groupe C : $45/50 = 90\%$.
(b) Taux global : $\frac{40 + 20 + 45}{150} = \frac{105}{150} = 70\%$.



- (c) Non : le taux global de 70 % masque une très forte hétérogénéité entre groupes – il ressemble à une bonne règle en apparence, mais le groupe B n'est correctement classé qu'une fois sur deux à peine. C'est le groupe B que la règle prédit le moins bien.


Correction — Exercice 3

- (a) $72 - 61 = 11$ points.
(b) Non : cet écart (11 points) est bien plus important que celui du cours ($67,0 - 65,3 = 1,7$ point) – près de sept fois plus grand.
(c) Un écart aussi large entre resubstitution et validation croisée signale un **surajustement** marqué : la règle s'est en partie ajustée au bruit des données d'apprentissage plutôt qu'à une structure généralisable. C'est le taux en **validation croisée** (61 %), plus honnête, qu'il faut publier – jamais le taux de resubstitution.

2 Exercices cumulatifs (introduction au chapitre 16)

Correction — Exercice 4

- (a) $|0,6 - (-0,785)| = 1,385$; $|0,6 - (-0,036)| = 0,636$; $|0,6 - 0,901| = 0,301$. La distance la plus faible (0,301) est vers « hebdomadaire » : le client y est bien affecté. Vérifié.



(b) $67,0 - 46,0 = 21$ points. Vérifié.

(c) $67,0 - 65,3 = 1,7$ point. Vérifié. Ce faible écart est **rassurant** : il signifie que la règle discriminante, construite sur les 300 clients, se généralise presque aussi bien à un client laissé de côté qu'aux données ayant servi à la construire – un signe que la règle n'est pas surajustée.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) La classe prédite (« à risque ») désigne 22 000 clients, bien plus que le budget disponible (3 000 contacts) : elle ne fournit aucun critère pour choisir *lesquels* de ces 22 000 contacter en priorité.
- (b) Il faut ordonner l'ensemble des 80 000 clients par **score** décroissant (probabilité de résiliation), puis contacter exactement les 3 000 premiers de ce classement – quel que soit leur nombre au sein de la classe « à risque » prédite.
- (c) Le score est une variable **continue** qui permet un classement fin de tous les clients les uns par rapport aux autres, alors que la classe prédite est une information **binaire** (à risque ou non) qui ne distingue pas, à l'intérieur d'un même groupe, les cas les plus et les moins probables – c'est exactement la logique illustrée par l'exemple du cours (« 78^e rang sur 300 »).

Correction — Exercice 6

- (a) Un score élevé garantit seulement qu'un client **ressemble** statistiquement aux clients fidèles sur les variables observées (une **association**) ; il ne garantit **pas** qu'un client au score initialement bas deviendra fidèle si on modifie une des variables (ici, la qualité perçue du service) – ni même que la relation observée se maintiendra dans le temps.
- (b) Deux sens sont possibles : soit le client visite fréquemment *parce que* le service est bon (le service cause la fidélité) ; soit le client note bien le service *parce qu'il* visite fréquemment et connaît bien le magasin, ou y est simplement attaché pour d'autres raisons (la fidélité cause – ou coïncide avec – la bonne note).
- (c) Il faudrait un dispositif **causal** : par exemple une **expérimentation** (former le personnel dans un sous-ensemble de magasins tirés au hasard, et comparer l'évolution de la fidélité à celle des magasins non formés), ou une méthode d'**inférence causale** appropriée en l'absence de tirage aléatoire – exactement le type de dispositif que l'AFD, méthode descriptive, ne fournit pas d'elle-même.