

Analyse des données avancée

Chapitre 16 : Classer un nouveau client

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Appliquer la règle du centre le plus proche

Trois groupes ont pour centres sur l'axe discriminant : $A = -1,2$, $B = 0,1$, $C = 1,5$. Un nouveau client a pour score 0,4.

- (a) Calculer la distance du score de ce client à chacun des trois centres.
- (b) À quel groupe la règle géométrique l'affecte-t-elle ?
- (c) Un collègue objecte que le groupe C ne représente que 4 % de la clientèle, contre 48 % pour B . Quel raffinement du cours permettrait de tenir compte de cette information, que la règle géométrique simple ignore ?

Exercice 2 — Lire une matrice de confusion ligne par ligne

Une règle de classement à trois groupes (50 individus chacun) obtient les bons classements suivants : groupe A : 40/50 ; groupe B : 20/50 ; groupe C : 45/50.

- (a) Calculer le taux de bon classement de chaque groupe.
- (b) Calculer le taux global de bon classement.
- (c) Le taux global à lui seul donnerait-il une image fidèle de la qualité de cette règle ? Quel groupe la règle prédit-elle le moins bien ?

Exercice 3 — Repérer un surajustement par validation croisée

Une règle de classement obtient un taux de bon classement de 72 % en resubstitution (sur les mêmes individus qui ont servi à la construire), et de 61 % en validation croisée.

- (a) Calculer l'écart entre les deux taux.
- (b) Cet écart est-il comparable à celui obtenu dans le cours (entre 67,0 % et 65,3 %) ?
- (c) Que doit-on en conclure sur le risque de surajustement de cette règle, et quel taux faut-il publier ?

2 Exercices cumulatifs (introduction au chapitre 16)

Exercice 4 — Vérifier le classement d'un client et l'écart de validation croisée

On reprend les trois centres du cours sur l'axe discriminant : Rare $-0,785$, Mensuelle $-0,036$, Hebdomadaire $+0,901$. Un client a un score de $+0,6$.

- (a) Calculer la distance de ce score aux trois centres, et vérifier que le client est bien affecté au groupe « hebdomadaire », comme l'affirme le cours.
- (b) Calculer l'écart entre le taux global de bon classement (67,0 %) et le taux du groupe « mensuelle » (46,0 %), et vérifier qu'on retrouve 21 points.
- (c) Calculer l'écart entre le taux en resubstitution (67,0 %) et le taux en validation croisée (65,3 %), et vérifier qu'on retrouve 1,7 point. Ce faible écart est-il plutôt rassurant ou inquiétant quant au risque de surajustement de la règle ?

3 Applications en sciences économiques

Exercice 5 — Cibler une campagne avec un budget limité

Une compagnie d'assurance dispose d'un score de résiliation (analogue au score discriminant du cours) pour 80 000 clients, et d'un budget permettant de contacter 3 000 clients avec une offre de rétention.

- (a) La règle de classement affecterait « à risque de résiliation » environ 22 000 clients. Pourquoi cette classe prédite est-elle inutilisable telle quelle pour cibler la campagne ?
- (b) Comment utiliser le score plutôt que la classe prédite pour respecter exactement le budget de 3 000 contacts ?
- (c) Pourquoi le score permet-il ce type d'arbitrage budgétaire, alors que la classe prédite (« à risque » ou non) ne le permet pas ?

Exercice 6 — Ne pas confondre score et cause

Une enseigne constate qu'un score discriminant élevé (construit sur les notes de service) est fortement associé à la fidélité des clients, et envisage de lancer une campagne de formation du personnel d'accueil dans les magasins où le score moyen des clients est le plus bas, en espérant ainsi augmenter la fidélité.


- (a) D'après le cours, que garantit – et que ne garantit pas – un score discriminant élevé sur le plan du comportement futur du client ?
- (b) Formuler les deux sens de causalité possibles entre « bonne note de service » et « fréquence de visite élevée », sans trancher lequel est le bon.
- (c) Quel type de dispositif faudrait-il mettre en place pour établir que la formation du personnel a effectivement un effet causal sur la fidélité, plutôt qu'une simple association ?

1 Exercices du chapitre

Correction — Exercice 1

(a) $|0,4 - (-1,2)| = 1,6$; $|0,4 - 0,1| = 0,3$; $|0,4 - 1,5| = 1,1$.

(b) La distance la plus faible est 0,3, vers B : le client est affecté au groupe B.




(c) La règle **bayésienne**, qui pondère la distance par les probabilités a priori (les effectifs relatifs) de chaque groupe : elle demanderait davantage de « preuves » (une distance plus faible) pour affecter un client au groupe C, minoritaire, qu'au groupe B, majoritaire.

Correction — Exercice 2

(a) Groupe A : $40/50 = 80\%$. Groupe B : $20/50 = 40\%$. Groupe C : $45/50 = 90\%$.

(b) Taux global : $\frac{40 + 20 + 45}{150} = \frac{105}{150} = 70\%$.



(c) Non : le taux global de 70 % masque une très forte hétérogénéité entre groupes – il ressemble à une bonne règle en apparence, mais le groupe B n'est correctement classé qu'une fois sur deux à peine. C'est le groupe B que la règle prédit le moins bien.

Correction — Exercice 3

(a) $72 - 61 = 11$ points.


(b) Non : cet écart (11 points) est bien plus important que celui du cours ($67,0 - 65,3 = 1,7$ point) – près de sept fois plus grand.

(c) Un écart aussi large entre resubstitution et validation croisée signale un **surajustement** marqué : la règle s'est en partie ajustée au bruit des données d'apprentissage plutôt qu'à une structure généralisable. C'est le taux en **validation croisée** (61 %), plus honnête, qu'il faut publier – jamais le taux de resubstitution.

2 Exercices cumulatifs (introduction au chapitre 16)

Correction — Exercice 4

(a) $|0,6 - (-0,785)| = 1,385$; $|0,6 - (-0,036)| = 0,636$; $|0,6 - 0,901| = 0,301$. La distance la plus faible (0,301) est vers « hebdomadaire » : le client y est bien affecté. Vérifié.



(b) $67,0 - 46,0 = 21$ points. Vérifié.

(c) $67,0 - 65,3 = 1,7$ point. Vérifié. Ce faible écart est **rassurant** : il signifie que la règle discriminante, construite sur les 300 clients, se généralise presque aussi bien à un client laissé de côté qu'aux données ayant servi à la construire – un signe que la règle n'est pas surajustée.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) La classe prédite (« à risque ») désigne 22 000 clients, bien plus que le budget disponible (3 000 contacts) : elle ne fournit aucun critère pour choisir *lesquels* de ces 22 000 contacter en priorité.
- (b) Il faut ordonner l'ensemble des 80 000 clients par **score** décroissant (probabilité de résiliation), puis contacter exactement les 3 000 premiers de ce classement – quel que soit leur nombre au sein de la classe « à risque » prédite.
- (c) Le score est une variable **continue** qui permet un classement fin de tous les clients les uns par rapport aux autres, alors que la classe prédite est une information **binaire** (à risque ou non) qui ne distingue pas, à l'intérieur d'un même groupe, les cas les plus et les moins probables – c'est exactement la logique illustrée par l'exemple du cours (« 78^e rang sur 300 »).

Correction — Exercice 6

- (a) Un score élevé garantit seulement qu'un client **ressemble** statistiquement aux clients fidèles sur les variables observées (une **association**) ; il ne garantit **pas** qu'un client au score initialement bas deviendra fidèle si on modifie une des variables (ici, la qualité perçue du service) – ni même que la relation observée se maintiendra dans le temps.
- (b) Deux sens sont possibles : soit le client visite fréquemment *parce que* le service est bon (le service cause la fidélité) ; soit le client note bien le service *parce qu'il* visite fréquemment et connaît bien le magasin, ou y est simplement attaché pour d'autres raisons (la fidélité cause – ou coïncide avec – la bonne note).
- (c) Il faudrait un dispositif **causal** : par exemple une **expérimentation** (former le personnel dans un sous-ensemble de magasins tirés au hasard, et comparer l'évolution de la fidélité à celle des magasins non formés), ou une méthode d'**inférence causale** appropriée en l'absence de tirage aléatoire – exactement le type de dispositif que l'AFD, méthode descriptive, ne fournit pas d'elle-même.