

Analyse des données avancée

Chapitre 6 : Combien d'axes retenir

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Un pourcentage cumulé qui ne veut rien dire seul

Une étude A porte sur $p = 4$ variables réduites et retient 2 axes portant 85 % de l'inertie. Une étude B porte sur $p = 40$ variables réduites et retient 2 axes portant 55 % de l'inertie.

- (a) Combien de variables restent « hors » des deux axes retenus dans chaque étude ?
- (b) Laquelle des deux réductions est la plus impressionnante, au sens du cours ?
- (c) Pourquoi serait-il absurde de conclure que « l'étude A a mieux réussi » sous prétexte que son pourcentage cumulé est plus élevé ?

Exercice 2 — Kaiser, puis le seuil corrigé

Une ACP normée porte sur $p = 10$ variables et $n = 50$ individus. Les deux premières valeurs propres valent $\lambda_1 = 2,8$ et $\lambda_2 = 1,7$.

- (a) D'après le critère de Kaiser brut ($\lambda_k > 1$), combien d'axes ces deux valeurs propres permettent-elles de retenir ?
- (b) Calculer le seuil corrigé de Karlis, Saporta et Spinaki, $1 + 2\sqrt{(p-1)/(n-1)}$.
- (c) $\lambda_2 = 1,7$ dépasse-t-il ce seuil corrigé ? Le nombre d'axes retenus change-t-il par rapport à la question (a) ?

Exercice 3 — Repérer le coude de Cattell

Un éboulis de valeurs propres, sur $p = 7$ variables réduites, donne : 3,9, 1,8, 0,45, 0,35, 0,25, 0,15, 0,10.

- (a) Calculer les six chutes successives $\lambda_k - \lambda_{k+1}$.
- (b) Où se situe la chute la plus marquée, en proportion des chutes voisines ?
- (c) Combien d'axes le critère du coude suggère-t-il de retenir ?

2 Exercices cumulatifs (introduction au chapitre 6)

Exercice 4 — Les quatre critères, vérifiés sur les 300 clients

On reprend les huit valeurs propres du fichier des 300 clients (chapitre 4) : 4,535 ; 1,645 ; 0,382 ; 0,349 ; 0,327 ; 0,283 ; 0,249 ; 0,229, avec $n = 300$ et $p = 8$.

- (a) Vérifier que le pourcentage cumulé des deux premiers axes vaut bien 77,3 %, et que le critère de Kaiser brut ($\lambda_k > 1$) retient exactement deux axes.
- (b) Calculer le seuil corrigé de Karlis, Saporta et Spinaki pour $n = 300$ et $p = 8$, et vérifier qu'on retrouve 1,306 (cours). $\lambda_2 = 1,645$ dépasse-t-il encore ce seuil ?
- (c) Calculer les sept chutes successives entre valeurs propres consécutives, et vérifier que la chute entre λ_2 et λ_3 est bien environ 40 fois plus grande que la chute suivante (entre λ_3 et λ_4). Les quatre critères convergent-ils tous vers le même nombre d'axes ?

3 Applications en sciences économiques

Exercice 5 — Combien de facteurs pour un tableau de bord risque

Une banque calcule les valeurs propres d'une ACP normée sur $p = 12$ indicateurs de risque réduits, avec $n = 400$ dossiers : $\lambda_1 = 5,2$, $\lambda_2 = 2,1$, $\lambda_3 = 1,3$, $\lambda_4 = 0,9$, puis huit valeurs propres toutes proches de 0,3.

- (a) Combien d'axes le critère de Kaiser brut retient-il ?
- (b) Calculer le seuil corrigé de Karlis, Saporta et Spinaki pour $n = 400$, $p = 12$. $\lambda_3 = 1,3$ le dépasse-t-il ?
- (c) La banque hésite entre retenir 2 ou 3 axes pour son tableau de bord visuel. D'après la règle « un axe se garde s'il s'interprète », quelle démarche doit-elle suivre avant de trancher, plutôt que de s'en tenir mécaniquement aux seuils numériques ?

Exercice 6 — Représenter n'est pas classer

Une entreprise dispose de $p = 15$ variables réduites décrivant ses fournisseurs. Elle veut, d'une part, produire une carte visuelle de ses fournisseurs pour une présentation, et d'autre part, les répartir en groupes homogènes par un algorithme de classification.

- (a) Pour l'objectif de représentation visuelle, combien d'axes l'entreprise doit-elle raisonnablement retenir, et pourquoi ?
- (b) Pour l'objectif de classification, le cours recommande-t-il de se limiter au même nombre d'axes ? Quel seuil d'inertie cumulée est habituellement visé dans ce second cas ?
- (c) Pourquoi classer les fournisseurs sur les axes retenus (plutôt que sur les 15 variables brutes) rend-il, d'après le cours, la classification **plus juste** et pas seulement plus rapide à calculer ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Étude A : $4 - 2 = 2$ variables restent hors des axes retenus. Étude B : $40 - 2 = 38$ variables restent hors des axes retenus.
- (b) La réduction de l'étude B est la plus impressionnante : conserver 55 % de l'inertie de 40 variables avec seulement 2 axes signale une structure de corrélation très forte, alors qu'atteindre 85 % avec 2 axes sur seulement 4 variables de départ est presque automatique.
- (c) Un pourcentage cumulé ne se juge jamais dans l'absolu : il doit être rapporté au nombre de variables de départ p . Comparer directement 85 % (sur $p = 4$) à 55 % (sur $p = 40$) revient à ignorer que la seconde réduction porte sur une structure bien plus complexe – ce n'est pas parce qu'un pourcentage est plus élevé que la réduction qu'il décrit est meilleure.

Correction — Exercice 2

- (a) $\lambda_1 = 2,8 > 1$ et $\lambda_2 = 1,7 > 1$: Kaiser brut retient **deux** axes.
- (b) $1 + 2\sqrt{\frac{10-1}{50-1}} = 1 + 2\sqrt{\frac{9}{49}} = 1 + 2 \times \frac{3}{7} = 1 + \frac{6}{7} \approx 1,857$.
- (c) $\lambda_2 = 1,7$ ne dépasse **pas** 1,857 : avec le seuil corrigé, seul λ_1 est retenu, soit **un seul** axe – le nombre d'axes retenus change par rapport à Kaiser brut, qui était trop généreux ici (petit n relativement à p).


Correction — Exercice 3

- (a) $3,9 - 1,8 = 2,1$; $1,8 - 0,45 = 1,35$; $0,45 - 0,35 = 0,10$; $0,35 - 0,25 = 0,10$; $0,25 - 0,15 = 0,10$; $0,15 - 0,10 = 0,05$.
- (b) La chute entre λ_2 et λ_3 (1,35) est plus de 13 fois supérieure aux chutes suivantes (environ 0,10 chacune) : c'est là que se situe la cassure la plus marquée.
- (c) Le critère du coude suggère de retenir **deux** axes – ceux situés avant la cassure nette.

2 Exercices cumulatifs (introduction au chapitre 6)

Correction — Exercice 4

- (a) $\frac{4,535 + 1,645}{8} = \frac{6,180}{8} = 77,25\% \approx 77,3\%$. Seuls $\lambda_1 = 4,535$ et $\lambda_2 = 1,645$ dépassent 1; $\lambda_3 = 0,382$ en est loin. Kaiser brut retient bien **deux** axes.
- (b) $1 + 2\sqrt{\frac{8-1}{300-1}} = 1 + 2\sqrt{\frac{7}{299}} = 1 + 2 \times 0,153 \approx 1,306$. $\lambda_2 = 1,645$ dépasse encore largement ce seuil corrigé : **deux** axes, de nouveau.
- (c) Chutes : $4,535 - 1,645 = 2,890$; $1,645 - 0,382 = 1,263$; $0,382 - 0,349 = 0,033$; $0,349 - 0,327 = 0,022$; $0,327 - 0,283 = 0,044$; $0,283 - 0,249 = 0,034$; $0,249 - 0,229 = 0,020$. Le rapport entre la chute $\lambda_2 \rightarrow \lambda_3$ (1,263) et la chute suivante $\lambda_3 \rightarrow \lambda_4$ (0,033) vaut $1,263/0,033 \approx 38,3$, soit bien environ 40 fois plus grand, conformément au cours. Les **quatre** critères (cumulé, Kaiser, seuil corrigé, coude) convergent tous vers **deux** axes.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $\lambda_1 = 5,2$, $\lambda_2 = 2,1$ et $\lambda_3 = 1,3$ dépassent 1 ; les huit suivantes ($\approx 0,3$) sont toutes inférieures. Kaiser brut retient **trois** axes.

(b) $1 + 2\sqrt{\frac{12-1}{400-1}} = 1 + 2\sqrt{\frac{11}{399}} \approx 1 + 2 \times 0,166 \approx 1,332$. $\lambda_3 = 1,3$ ne dépasse **pas** ce seuil corrigé ($1,3 < 1,332$) : avec le critère corrigé, seuls **deux** axes sont retenus.

(c) Avant de trancher entre 2 et 3 axes, la banque doit examiner si le troisième axe **s'interprète** : regarder quels indicateurs de risque lui sont fortement corrélés et si cette combinaison a un sens économique reconnaissable (un profil de risque identifiable). Si le troisième axe ne se laisse pas nommer clairement, on suit le seuil corrigé et on s'arrête à 2 axes ; s'il révèle une dimension de risque distincte et interprétable, on peut le garder malgré le seuil, en gardant à l'esprit la mise en garde du cours : « un axe se garde s'il s'interprète » prime sur les critères numériques.

Correction — Exercice 6

(a) Pour la représentation visuelle, l'entreprise doit se limiter à **deux** axes (éventuellement un second plan si un troisième est retenu) : au-delà, « on ne dessine pas en dimension trois » de façon lisible sur une feuille ou un écran.

(b) Non : pour la classification, rien n'oblige à se limiter à 2 axes puisqu'on ne cherche pas à *visualiser* le résultat. L'usage est de viser 80 à 90 % d'inertie cumulée, quitte à conserver cinq, six axes ou davantage, qu'on ne représentera jamais graphiquement.

(c) Classer sur les axes retenus plutôt que sur les 15 variables brutes n'est pas seulement plus rapide : c'est plus **juste**, car les derniers axes (les plus faibles) portent essentiellement le **bruit** du tableau – des directions sans structure partagée entre variables. Les inclure dans un calcul de classification reviendrait à laisser ce bruit contribuer à la formation des groupes, ce qui peut créer des classes artificielles ; les écarter en amont, en ne classant que sur les axes retenus, empêche ce bruit de peser dans le résultat final.