

Chapitre 6

Combien d'axes retenir

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Exercice 1 — Un pourcentage cumulé qui ne veut rien dire seul

Une étude A porte sur $p = 4$ variables réduites et retient 2 axes portant 85 % de l'inertie. Une étude B porte sur $p = 40$ variables réduites et retient 2 axes portant 55 % de l'inertie.

- (a) Combien de variables restent « hors » des deux axes retenus dans chaque étude ?
- (b) Laquelle des deux réductions est la plus impressionnante, au sens du cours ?
- (c) Pourquoi serait-il absurde de conclure que « l'étude A a mieux réussi » sous prétexte que son pourcentage cumulé est plus élevé ?

Exercice 2 — Kaiser, puis le seuil corrigé

Une ACP normée porte sur $p = 10$ variables et $n = 50$ individus. Les deux premières valeurs propres valent $\lambda_1 = 2,8$ et $\lambda_2 = 1,7$.

- (a) D'après le critère de Kaiser brut ($\lambda_k > 1$), combien d'axes ces deux valeurs propres permettent-elles de retenir ?
- (b) Calculer le seuil corrigé de Karlis, Saporta et Spinaki, $1 + 2\sqrt{(p-1)/(n-1)}$.
- (c) $\lambda_2 = 1,7$ dépasse-t-il ce seuil corrigé ? Le nombre d'axes retenus change-t-il par rapport à la question (a) ?

Exercice 3 — Repérer le coude de Cattell

Un éboulis de valeurs propres, sur $p = 7$ variables réduites, donne : 3,9, 1,8, 0,45, 0,35, 0,25, 0,15, 0,10.

- (a) Calculer les six chutes successives $\lambda_k - \lambda_{k+1}$.
- (b) Où se situe la chute la plus marquée, en proportion des chutes voisines ?
- (c) Combien d'axes le critère du coude suggère-t-il de retenir ?

2 Exercices cumulatifs (introduction au chapitre 6)

Exercice 4 — Les quatre critères, vérifiés sur les 300 clients

On reprend les huit valeurs propres du fichier des 300 clients (chapitre 4) : 4,535 ; 1,645 ; 0,382 ; 0,349 ; 0,327 ; 0,283 ; 0,249 ; 0,229, avec $n = 300$ et $p = 8$.

- (a) Vérifier que le pourcentage cumulé des deux premiers axes vaut bien 77,3 %, et que le critère de Kaiser brut ($\lambda_k > 1$) retient exactement deux axes.
- (b) Calculer le seuil corrigé de Karlis, Saporta et Spinaki pour $n = 300$ et $p = 8$, et vérifier qu'on retrouve 1,306 (cours). $\lambda_2 = 1,645$ dépasse-t-il encore ce seuil ?
- (c) Calculer les sept chutes successives entre valeurs propres consécutives, et vérifier que la chute entre λ_2 et λ_3 est bien environ 40 fois plus grande que la chute suivante (entre λ_3 et λ_4). Les quatre critères convergent-ils tous vers le même nombre d'axes ?

3 Applications en sciences économiques

Exercice 5 — Combien de facteurs pour un tableau de bord risque

Une banque calcule les valeurs propres d'une ACP normée sur $p = 12$ indicateurs de risque réduits, avec $n = 400$ dossiers : $\lambda_1 = 5,2$, $\lambda_2 = 2,1$, $\lambda_3 = 1,3$, $\lambda_4 = 0,9$, puis huit valeurs propres toutes proches de 0,3.

- (a) Combien d'axes le critère de Kaiser brut retient-il ?
- (b) Calculer le seuil corrigé de Karlis, Saporta et Spinaki pour $n = 400$, $p = 12$. $\lambda_3 = 1,3$ le dépasse-t-il ?
- (c) La banque hésite entre retenir 2 ou 3 axes pour son tableau de bord visuel. D'après la règle « un axe se garde s'il s'interprète », quelle démarche doit-elle suivre avant de trancher, plutôt que de s'en tenir mécaniquement aux seuils numériques ?

Exercice 6 — Représenter n'est pas classer

Une entreprise dispose de $p = 15$ variables réduites décrivant ses fournisseurs. Elle veut, d'une part, produire une carte visuelle de ses fournisseurs pour une présentation, et d'autre part, les répartir en groupes homogènes par un algorithme de classification.

- (a) Pour l'objectif de représentation visuelle, combien d'axes l'entreprise doit-elle raisonnablement retenir, et pourquoi ?
- (b) Pour l'objectif de classification, le cours recommande-t-il de se limiter au même nombre d'axes ? Quel seuil d'inertie cumulée est habituellement visé dans ce second cas ?
- (c) Pourquoi classer les fournisseurs sur les axes retenus (plutôt que sur les 15 variables brutes) rend-il, d'après le cours, la classification **plus juste** et pas seulement plus rapide à calculer ?