

Analyse des données avancée

Chapitre 11 : Distances et dissimilarités

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Vérifier les trois propriétés d'une distance

Trois points ont pour coordonnées $A = (1, 2)$, $B = (4, 6)$, $C = (4, 2)$.

- (a) Calculer les trois distances euclidiennes $d(A, B)$, $d(B, C)$ et $d(A, C)$.
- (b) Vérifier l'inégalité triangulaire sur les trois permutations possibles.
- (c) La distance euclidienne vérifie-t-elle toujours ces trois propriétés, quels que soient les points choisis? Pourquoi peut-on donc l'appeler une véritable « distance » et non une simple « dissimilarité »?

Exercice 2 — Repérer une dissimilarité qui n'est pas une distance

Un panel de consommateurs juge trois enseignes A , B , C deux à deux : dissimilarité perçue $A-B = 2$, $B-C = 2$, $A-C = 9$.

- (a) Vérifier si l'inégalité triangulaire $d(A, C) \leq d(A, B) + d(B, C)$ est respectée.
- (b) Ce jugement peut-il provenir d'une distance euclidienne calculée sur des données réelles? Que peut-on en conclure sur la nature de ce tableau de dissimilarités?
- (c) Pourquoi les jugements de ressemblance recueillis auprès d'êtres humains échappent-ils fréquemment à cette propriété?

Exercice 3 — Choisir une stratégie face à des données mixtes

Un fichier client comporte 6 notes de satisfaction (quantitatives) et 3 variables qualitatives (région, canal préféré, type de contrat).

- (a) Citer les trois solutions possibles face à ce mélange, dans l'ordre de préférence croissante indiqué par le cours.
- (b) Pourquoi la troisième solution (classer sur les axes factoriels) est-elle préférable aux deux autres?
- (c) Sur quel type d'analyse factorielle faudrait-il s'appuyer si les 9 variables (quantitatives et qualitatives) devaient toutes entrer dans le calcul des axes?

2 Exercices cumulatifs (introduction au chapitre 11)

Exercice 4 — Vérifier le choix des deux axes pour classer

On reprend le spectre des valeurs propres de l'ACP du cours sur les 8 notes de satisfaction : 4,535 ; 1,645 ; 0,382 ; 0,349 ; 0,327 ; 0,283 ; 0,249 ; 0,229 (somme = 8).

- (a) Calculer le pourcentage d'inertie cumulé porté par les deux premiers axes, et vérifier qu'on retrouve 77,3 %.
- (b) Calculer le pourcentage porté par le troisième axe seul, et vérifier qu'on retrouve 4,8 %.
- (c) Le chapitre 6 retenait déjà deux axes, mais pour un motif différent (la représentation graphique). Pourquoi le motif invoqué ici (classer plutôt que représenter) autoriserait-il, en principe, à garder davantage d'axes – et pourquoi le cours choisit-il malgré tout de s'arrêter à deux, sur ces données précises?

3 Applications en sciences économiques

Exercice 5 — Choisir la bonne distance selon la nature des données

Une plateforme e-commerce dispose de deux fichiers distincts sur ses clients : un fichier de notes de satisfaction sur 10 critères (échelle 0–20), et un fichier binaire indiquant, pour 50 catégories de produits, si le client en a déjà acheté (1) ou non (0).

- (a) Quelle distance choisir pour comparer des clients sur le fichier de notes ? Pourquoi ?
- (b) Quelle distance choisir pour comparer des clients sur le fichier des achats binaires, sachant que la grande majorité des « 0 » correspond à une simple absence d'achat plutôt qu'à un rejet actif du produit ?
- (c) Pourquoi serait-il maladroit d'appliquer la distance euclidienne brute directement au fichier des 50 indicatrices d'achat ?

Exercice 6 — Le double comptage dans une classification financière

Une société de gestion souhaite regrouper des fonds d'investissement selon quatre ratios financiers : volatilité, ratio de Sharpe, maximum drawdown et VaR à 95 %. Ces quatre ratios sont fortement corrélés entre eux (autour de 0,80), car ils mesurent tous, sous des angles différents, le risque du fonds.

- (a) Si l'on calcule une distance euclidienne directement sur les quatre ratios bruts, pourquoi la dimension « risque » sera-t-elle surpondérée par rapport à ce qu'elle devrait peser dans le regroupement final ?
- (b) Quelle démarche, analogue à celle du cours, permettrait de corriger ce problème avant de classer les fonds ?
- (c) Un collègue propose de simplement retirer trois des quatre ratios pour ne garder que la VaR. En quoi cette solution diffère-t-elle, dans son principe, de la solution recommandée par le cours ?

1 Exercices du chapitre


Correction — Exercice 1

(a) $d(A, B) = \sqrt{(4-1)^2 + (6-2)^2} = \sqrt{9+16} = \sqrt{25} = 5.$

$d(B, C) = \sqrt{(4-4)^2 + (6-2)^2} = \sqrt{0+16} = 4.$

$d(A, C) = \sqrt{(4-1)^2 + (2-2)^2} = \sqrt{9} = 3.$

(b) $d(A, C) = 3 \leq d(A, B) + d(B, C) = 5 + 4 = 9$: vérifié. $d(A, B) = 5 \leq d(A, C) + d(C, B) = 3 + 4 = 7$: vérifié. $d(B, C) = 4 \leq d(B, A) + d(A, C) = 5 + 3 = 8$: vérifié. Les trois inégalités triangulaires sont satisfaites.



(c) Oui : la distance euclidienne vérifie *toujours* les trois propriétés (nullité de $d(i, i)$, symétrie, inégalité triangulaire), pour n'importe quel choix de points dans $\mathbb{R}^p$ – ce sont des propriétés démontrées de la norme euclidienne, pas des coïncidences numériques. C'est pour cela qu'elle mérite le nom de « distance », alors qu'un tableau de dissimilarités quelconque (Exercice 2) n'a aucune garantie de ce type.

Correction — Exercice 2

(a) $d(A, C) = 9$, tandis que $d(A, B) + d(B, C) = 2 + 2 = 4$. Comme $9 > 4$, l'inégalité triangulaire est **violée**.

(b) Non : une distance euclidienne calculée sur des données réelles satisferait nécessairement l'inégalité triangulaire (Exercice 1c). Ce tableau ne peut donc **pas** provenir d'une distance euclidienne : c'est une simple **dissimilarité**, qui ne vérifie que la nullité sur la diagonale et la symétrie.

(c) Un jugement subjectif de ressemblance ne résulte pas d'un calcul géométrique cohérent : un consommateur peut juger A et B proches sur un critère (le positionnement prix), B et C proches sur un autre critère (l'image de marque), sans que A et C ne partagent aucun de ces deux points communs – d'où une distance perçue A – C disproportionnée. C'est précisément le problème que le positionnement multidimensionnel (MDS) est conçu pour traiter.

Correction — Exercice 3

(a) Dans l'ordre de préférence croissante : **1.** découper les notes quantitatives en tranches et traiter tout le fichier en qualitatif ; **2.** utiliser un indice mixte comme celui de **Gower** ; **3.** réaliser une **analyse factorielle d'abord**, puis classer sur les coordonnées obtenues.

(b) Parce que les axes factoriels sont **quantitatifs, non corrélés, et de même nature** quelle que soit la variable d'origine (qu'elle ait été quantitative ou qualitative au départ) : la distance euclidienne y retrouve tout son sens, ce qui n'est le cas ni pour un découpage arbitraire en tranches (qui perd de l'information), ni toujours pleinement pour un indice mixte (dont le choix des pondérations reste largement conventionnel).


(c) Une **analyse factorielle multiple** (AFM), qui traite simultanément des groupes de variables de nature différente (ici : un groupe de 6 notes quantitatives et un groupe de 3 variables qualitatives) en équilibrant leur poids respectif dans le calcul des axes – une généralisation de l'ACP/ACM à des données mixtes structurées en blocs.

2 Exercices cumulatifs (introduction au chapitre 11)

Correction — Exercice 4

(a) $\frac{4,535 + 1,645}{8} = \frac{6,180}{8} \approx 0,7725 = 77,25 \% \approx 77,3 \%$. Vérifié.

(b) $\frac{0,382}{8} \approx 0,04775 = 4,775 \% \approx 4,8 \%$. Vérifié.



(c) Pour **classer**, rien n'oblige à se limiter à ce qui peut se dessiner : on pourrait en principe garder autant d'axes que nécessaire pour atteindre 80–90 % de l'inertie, sans souci de représentation graphique. Mais ici, la chute est nette entre l'axe 2 (20,6 %) et l'axe 3 (4,8 %, à peine plus que les axes suivants) : les axes 3 et au-delà ne portent que du bruit, sans structure supplémentaire interprétable. Le cours s'arrête donc à deux axes non par contrainte de représentation, mais parce que c'est là que s'arrête l'information utile – la même conclusion que le chapitre 6 atteignait par un raisonnement différent (les quatre critères de sélection d'axes), pour la même raison sous-jacente.

3 Applications en sciences économiques

Correction — Exercice 5

(a) La distance **euclidienne** (éventuellement sur variables centrées-réduites) : les 10 notes sont quantitatives, sur une échelle continue comparable, exactement la situation pour laquelle cette distance est conçue.

(b) La distance de **Jaccard** : elle ignore les co-absences (0–0), qui ne signifient qu'un manque d'occasion d'achat plutôt qu'une similarité réelle entre deux clients, et ne compte que les co-présences et les désaccords – adaptée aux données de présence-absence où le « 0 » n'est pas informatif en tant que tel.

(c) Parce qu'avec 50 catégories majoritairement à 0 pour chaque client, une distance euclidienne compterait chaque co-absence comme un point de **similarité**, ce qui gonflerait artificiellement la ressemblance entre deux clients qui n'ont simplement, l'un comme l'autre, presque rien acheté – un artefact statistique plutôt qu'un signal de comportement partagé.

Correction — Exercice 6

(a) Parce que ces quatre ratios mesurent, sous des angles différents, la **même** dimension sous-jacente (le risque) : deux fonds qui diffèrent sur cette dimension unique différeront simultanément sur les quatre ratios corrélés, et leur distance euclidienne brute additionnera quatre fois (presque) le même écart – exactement le mécanisme de double comptage illustré dans le cours avec le bloc prix/choix/qualité.

(b) Réaliser une **ACP** sur les quatre ratios, puis classer les fonds sur leurs coordonnées sur les premiers axes factoriels (non corrélés par construction) plutôt que sur les ratios bruts – exactement la démarche

recommandée par le cours pour les données corrélées.

(c) Retirer trois ratios pour ne garder que la VaR revient à **choisir arbitrairement une seule mesure du risque** et à ignorer l'information (même redondante) apportée par les trois autres ; l'ACP, elle, **combine** l'ensemble des quatre ratios en une ou plusieurs composantes synthétiques qui conservent la part commune d'information sans la compter plusieurs fois – une solution qui utilise tout le fichier au lieu d'en sacrifier les trois quarts.