

Chapitre 11

Distances et dissimilarités

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Exercice 1 — Vérifier les trois propriétés d'une distance

Trois points ont pour coordonnées $A = (1, 2)$, $B = (4, 6)$, $C = (4, 2)$.

- (a) Calculer les trois distances euclidiennes $d(A, B)$, $d(B, C)$ et $d(A, C)$.
- (b) Vérifier l'inégalité triangulaire sur les trois permutations possibles.
- (c) La distance euclidienne vérifie-t-elle toujours ces trois propriétés, quels que soient les points choisis? Pourquoi peut-on donc l'appeler une véritable « distance » et non une simple « dissimilarité »?

Exercice 2 — Repérer une dissimilarité qui n'est pas une distance

Un panel de consommateurs juge trois enseignes A , B , C deux à deux : dissimilarité perçue $A-B = 2$, $B-C = 2$, $A-C = 9$.

- (a) Vérifier si l'inégalité triangulaire $d(A, C) \leq d(A, B) + d(B, C)$ est respectée.
- (b) Ce jugement peut-il provenir d'une distance euclidienne calculée sur des données réelles? Que peut-on en conclure sur la nature de ce tableau de dissimilarités?
- (c) Pourquoi les jugements de ressemblance recueillis auprès d'êtres humains échappent-ils fréquemment à cette propriété?

Exercice 3 — Choisir une stratégie face à des données mixtes

Un fichier client comporte 6 notes de satisfaction (quantitatives) et 3 variables qualitatives (région, canal préféré, type de contrat).

- (a) Citer les trois solutions possibles face à ce mélange, dans l'ordre de préférence croissante indiqué par le cours.
- (b) Pourquoi la troisième solution (classer sur les axes factoriels) est-elle préférable aux deux autres?
- (c) Sur quel type d'analyse factorielle faudrait-il s'appuyer si les 9 variables (quantitatives et qualitatives) devaient toutes entrer dans le calcul des axes?

2 Exercices cumulatifs (introduction au chapitre 11)

Exercice 4 — Vérifier le choix des deux axes pour classer

On reprend le spectre des valeurs propres de l'ACP du cours sur les 8 notes de satisfaction : 4,535 ; 1,645 ; 0,382 ; 0,349 ; 0,327 ; 0,283 ; 0,249 ; 0,229 (somme = 8).

- (a) Calculer le pourcentage d'inertie cumulé porté par les deux premiers axes, et vérifier qu'on retrouve 77,3 %.
- (b) Calculer le pourcentage porté par le troisième axe seul, et vérifier qu'on retrouve 4,8 %.
- (c) Le chapitre 6 retenait déjà deux axes, mais pour un motif différent (la représentation graphique). Pourquoi le motif invoqué ici (classer plutôt que représenter) autoriserait-il, en principe, à garder davantage d'axes – et pourquoi le cours choisit-il malgré tout de s'arrêter à deux, sur ces données précises?

3 Applications en sciences économiques

Exercice 5 — Choisir la bonne distance selon la nature des données

Une plateforme e-commerce dispose de deux fichiers distincts sur ses clients : un fichier de notes de satisfaction sur 10 critères (échelle 0–20), et un fichier binaire indiquant, pour 50 catégories de produits, si le client en a déjà acheté (1) ou non (0).

- (a) Quelle distance choisir pour comparer des clients sur le fichier de notes ? Pourquoi ?
- (b) Quelle distance choisir pour comparer des clients sur le fichier des achats binaires, sachant que la grande majorité des « 0 » correspond à une simple absence d'achat plutôt qu'à un rejet actif du produit ?
- (c) Pourquoi serait-il maladroit d'appliquer la distance euclidienne brute directement au fichier des 50 indicatrices d'achat ?

Exercice 6 — Le double comptage dans une classification financière

Une société de gestion souhaite regrouper des fonds d'investissement selon quatre ratios financiers : volatilité, ratio de Sharpe, maximum drawdown et VaR à 95 %. Ces quatre ratios sont fortement corrélés entre eux (autour de 0,80), car ils mesurent tous, sous des angles différents, le risque du fonds.

- (a) Si l'on calcule une distance euclidienne directement sur les quatre ratios bruts, pourquoi la dimension « risque » sera-t-elle surpondérée par rapport à ce qu'elle devrait peser dans le regroupement final ?
- (b) Quelle démarche, analogue à celle du cours, permettrait de corriger ce problème avant de classer les fonds ?
- (c) Un collègue propose de simplement retirer trois des quatre ratios pour ne garder que la VaR. En quoi cette solution diffère-t-elle, dans son principe, de la solution recommandée par le cours ?