

Chapitre 5

Dualité et relations de transition

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\mathbf{R}$ est 5×5 (nuage des variables). $\mathbf{W}$ est 12×12 (nuage des individus).
(b) $\min(n - 1, p) = \min(11, 5) = 5$ valeurs propres non nulles au maximum.
(c) Non, ce nombre ne changerait pas : une sixième variable combinaison exacte des cinq premières est **redondante** (chapitre 3) – elle n’ajoute aucune dimension d’information nouvelle. Le rang de $\mathbf{Z}$ resterait égal à 5, donc le nombre de valeurs propres non nulles resterait $\min(n - 1, 6) = 5$ (borné par le rang réel des données, pas par le nombre de colonnes).

Correction — Exercice 2

- (a) $\mathbf{G}_1 = \sqrt{9} \times (0,6; 0,8)' = 3 \times (0,6; 0,8)' = (1,8; 2,4)'$.
(b) $1,8^2 + 2,4^2 = 3,24 + 5,76 = 9 = \lambda_1$. Vérifié.
(c) Non, ces coordonnées (1,8 et 2,4) dépassent largement 1 en valeur absolue, ce qui est **incompatible** avec la définition d’une corrélation : une valeur de G_{j1} supérieure à 1 signifierait une contradiction avec le fait que $\mathbf{u}_1$ doit être un vecteur propre **normé** de la matrice des corrélations, ce qui borne nécessairement $G_{j1} = \sqrt{\lambda_1} u_{j1}$ dans l’intervalle $[-1, 1]$ – un tel résultat signalerait une erreur de calcul en amont (un $\mathbf{u}_1$ mal normé, ou une valeur propre incorrecte).


Correction — Exercice 3

- (a) Non, cette lecture n’est pas légitime : les individus vivent dans $\mathbb{R}^p$ et les variables dans $\mathbb{R}^n$ (chapitre 5), deux espaces différents superposés sur le biplot par simple commodité graphique. On ne peut jamais lire une **distance** entre un individu et une variable sur cette figure.
(b) On peut seulement affirmer que le client 42 et la variable *prix* sont du même côté de l’origine sur le premier axe – ce qui traduit une **association** (le client a probablement noté le prix au-dessus de la moyenne) mais sans qu’on puisse quantifier « à quel point » à partir de la seule proximité visuelle sur la figure.
(c) En AFC, la superposition des deux nuages (lignes et colonnes) est **pleinement justifiée** par la construction même de la méthode – contrairement à l’ACP, c’est la seule méthode du cours où cette lecture conjointe repose sur un fondement mathématique solide (chapitre 9 du cours).

2 Exercices cumulatifs (introduction au chapitre 5)

Correction — Exercice 4

- (a) $\min(n - 1, p) = \min(3, 2) = 2$ valeurs propres non nulles. C’est cohérent : $\mathbf{W}$, bien que 4×4 , ne possède que deux valeurs propres non nulles, exactement 1,6 et 0,4 – les deux autres valeurs propres de $\mathbf{W}$ sont nulles.
(b) $\mathbf{G}_1 = \sqrt{1,6} \times (1/\sqrt{2}; 1/\sqrt{2})' \approx 1,265 \times (0,707; 0,707)' \approx (0,894; 0,894)'$. Vérification : $0,894^2 + 0,894^2 \approx 0,8 + 0,8 = 1,6 = \lambda_1$.
(c) $\text{cov}(x_1, F_1) = \frac{1}{4} [(-2)(-1,789) + (-1)(0) + (1)(0) + (2)(1,789)] = \frac{1}{4} (3,578 + 3,578) = 1,789$.
 $r(x_1, F_1) = \frac{1,789}{\sqrt{2,5} \times \sqrt{1,6}} = \frac{1,789}{1,581 \times 1,265} \approx \frac{1,789}{2,000} \approx 0,894$. On retrouve exactement $G_{1,1} \approx 0,894$ calculé en (b) – la coordonnée d’une variable sur le cercle des corrélations *est* bien sa corrélation avec la composante.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $\mathbf{R}$ est 15×15 . $\mathbf{W}$ est $50\,000 \times 50\,000$.

(b) $\frac{50\,000^3}{15^3} = \frac{1,25 \times 10^{14}}{3\,375} \approx 3,7 \times 10^{10}$ – un rapport de plus de 37 milliards.

(c) L'entreprise doit diagonaliser $\mathbf{R}$ (la matrice 15×15 , radicalement moins coûteuse), puis obtenir les coordonnées des 50 000 clients par la relation de transition $\mathbf{F}_k = \mathbf{Z}\mathbf{u}_k$ (chapitre 4) – un simple produit matriciel, sans jamais avoir à diagonaliser $\mathbf{W}$.

Correction — Exercice 6

(a) On peut affirmer qu'il existe une **association** entre le segment « jeune urbain » et la variable *innovation* : ce segment se situe du même côté de l'origine que cette variable sur le premier axe, ce qui traduit une note d'innovation généralement supérieure à la moyenne pour ce segment.

(b) On ne peut pas affirmer une **distance** précise ni un lien quantifié entre les deux points à partir de leur seule proximité visuelle sur le biplot – les deux nuages (segments et variables) vivent dans des espaces différents, et leur superposition graphique ne permet de lire qu'une direction commune, jamais une distance croisée.

(c) Pour chiffrer précisément ce lien, il faudrait calculer directement la **corrélation** $r(\text{innovation}, F_k)$ entre la variable brute *innovation* et les coordonnées factorielles des individus du segment « jeune urbain » (ou, plus simplement, comparer la moyenne des notes d'innovation de ce segment à la moyenne générale) – un calcul rigoureux, plutôt qu'une lecture de distance graphique dépourvue de fondement mathématique en ACP.