

Analyse des données avancée

Chapitre 5 : Dualité et relations de transition

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Combien de valeurs propres non nulles

Un fichier compte $n = 12$ individus et $p = 5$ variables réduites actives.

- (a) Quelle est la taille de $\mathbf{R}$? Quelle est la taille de $\mathbf{W}$?
- (b) D'après la règle du cours, combien de valeurs propres non nulles ces deux matrices partagent-elles au maximum?
- (c) Si l'on ajoutait une sixième variable qui est une combinaison linéaire exacte des cinq premières, ce nombre changerait-il? Pourquoi?

Exercice 2 — Utiliser la formule de transition

Sur un petit fichier, on a $\lambda_1 = 9$ et $\mathbf{u}_1 = (0,6; 0,8)'$ (vecteur propre normé de $\mathbf{R}$).

- (a) Calculer $\mathbf{G}_1 = \sqrt{\lambda_1} \mathbf{u}_1$, les coordonnées des deux variables sur le cercle des corrélations.
- (b) Vérifier que $\sum_j G_{j1}^2 = \lambda_1$.
- (c) Ces deux coordonnées sont-elles compatibles avec la définition d'une corrélation (comprises entre -1 et 1)? Que signifierait une valeur de G_{j1} supérieure à 1 ?

Exercice 3 — Corriger une lecture de biplot

Sur un biplot d'ACP (individus et variables superposés), un consultant écrit : « le client 42 est très proche du point représentant la variable *prix*, donc ce client a attribué une note très élevée au prix ».

- (a) Cette lecture est-elle légitime au sens du cours? Justifier par la nature des deux espaces en cause.
- (b) Reformuler correctement ce que l'on peut affirmer si le client 42 et la variable *prix* sont *du même côté* de l'origine sur le premier axe.
- (c) En quoi la situation serait-elle différente sur un plan d'AFC plutôt que d'ACP, d'après la mise en garde du cours?

2 Exercices cumulatifs (introduction au chapitre 5)

Exercice 4 — La dualité, vérifiée sur le fil rouge

On reprend le fil rouge : $n = 4$, $p = 2$, $\mathbf{R}$ de valeurs propres $\lambda_1 = 1,6$, $\lambda_2 = 0,4$, et $\mathbf{u}_1 = (1,1)'/\sqrt{2}$.

- (a) D'après la règle $\min(n-1, p)$, combien de valeurs propres non nulles $\mathbf{W}$ (matrice 4×4) doit-elle partager avec $\mathbf{R}$? Est-ce cohérent avec les valeurs 1,6 et 0,4 déjà rencontrées?
- (b) Calculer $\mathbf{G}_1 = \sqrt{\lambda_1} \mathbf{u}_1$, les coordonnées des deux variables x_1 et x_2 sur le cercle des corrélations, et vérifier que $\sum_j G_{j1}^2 = \lambda_1$.
- (c) Calculer directement la corrélation $r(x_1, F_1)$ entre la variable brute $x_1 = (-2, -1, 1, 2)$ et la composante $F_1 = (-1,789; 0; 0; 1,789)$ (chapitre 4), sachant $V(x_1) = 2,5$ et $V(F_1) = 1,6$. Retrouve-t-on bien la valeur $G_{1,1}$ calculée en (b)?

3 Applications en sciences économiques

Exercice 5 — Pourquoi la dualité rend un très grand fichier calculable

Une plateforme e-commerce dispose d'un fichier de $n = 50\,000$ clients décrits par $p = 15$ variables réduites.

- (a) Quelle est la taille de $\mathbf{R}$? Quelle est la taille de $\mathbf{W}$?
- (b) Sachant que le coût d'une diagonalisation croît comme le cube de la taille de la matrice, calculer approximativement le rapport entre le coût de diagonalisation de $\mathbf{W}$ et celui de $\mathbf{R}$.
- (c) En pratique, quelle matrice l'entreprise doit-elle diagonaliser, et comment obtient-elle ensuite les coordonnées des 50 000 clients sans avoir diagonalisé $\mathbf{W}$?

Exercice 6 — Un biplot marketing mal interprété

Une agence marketing présente un biplot d'ACP où les 200 clients et les 6 critères de perception d'une marque apparaissent sur la même figure. Le client « segment jeune urbain » tombe du même côté de l'origine que la variable *innovation*, tandis que le segment « familles » tombe du côté opposé, proche de la variable *fiabilité*.

- (a) Que peut-on légitimement affirmer sur le lien entre le segment « jeune urbain » et la variable *innovation*, d'après les règles du cours sur les biplots d'ACP?
- (b) Que ne peut-on **pas** affirmer, même si les deux points semblent visuellement très proches sur la figure?
- (c) L'agence veut chiffrer précisément « à quel point » le segment jeune urbain valorise l'innovation. Quel calcul, plus rigoureux que la lecture du biplot, permettrait de répondre à cette question?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\mathbf{R}$ est 5×5 (nuage des variables). $\mathbf{W}$ est 12×12 (nuage des individus).
(b) $\min(n-1, p) = \min(11, 5) = 5$ valeurs propres non nulles au maximum.
(c) Non, ce nombre ne changerait pas : une sixième variable combinaison exacte des cinq premières est **redondante** (chapitre 3) – elle n’ajoute aucune dimension d’information nouvelle. Le rang de $\mathbf{Z}$ resterait égal à 5, donc le nombre de valeurs propres non nulles resterait $\min(n-1, 6) = 5$ (borné par le rang réel des données, pas par le nombre de colonnes).

Correction — Exercice 2

- (a) $\mathbf{G}_1 = \sqrt{9} \times (0,6; 0,8)' = 3 \times (0,6; 0,8)' = (1,8; 2,4)'$.
(b) $1,8^2 + 2,4^2 = 3,24 + 5,76 = 9 = \lambda_1$. Vérifié.
(c) Non, ces coordonnées (1,8 et 2,4) dépassent largement 1 en valeur absolue, ce qui est **incompatible** avec la définition d’une corrélation : une valeur de G_{j1} supérieure à 1 signifierait une contradiction avec le fait que $\mathbf{u}_1$ doit être un vecteur propre **normé** de la matrice des corrélations, ce qui borne nécessairement $G_{j1} = \sqrt{\lambda_1} u_{j1}$ dans l’intervalle $[-1, 1]$ – un tel résultat signalerait une erreur de calcul en amont (un $\mathbf{u}_1$ mal normé, ou une valeur propre incorrecte).


Correction — Exercice 3

- (a) Non, cette lecture n’est pas légitime : les individus vivent dans $\mathbb{R}^p$ et les variables dans $\mathbb{R}^n$ (chapitre 5), deux espaces différents superposés sur le biplot par simple commodité graphique. On ne peut jamais lire une **distance** entre un individu et une variable sur cette figure.
(b) On peut seulement affirmer que le client 42 et la variable *prix* sont du même côté de l’origine sur le premier axe – ce qui traduit une **association** (le client a probablement noté le prix au-dessus de la moyenne) mais sans qu’on puisse quantifier « à quel point » à partir de la seule proximité visuelle sur la figure.
(c) En AFC, la superposition des deux nuages (lignes et colonnes) est **pleinement justifiée** par la construction même de la méthode – contrairement à l’ACP, c’est la seule méthode du cours où cette lecture conjointe repose sur un fondement mathématique solide (chapitre 9 du cours).

2 Exercices cumulatifs (introduction au chapitre 5)

Correction — Exercice 4

- (a) $\min(n-1, p) = \min(3, 2) = 2$ valeurs propres non nulles. C’est cohérent : $\mathbf{W}$, bien que 4×4 , ne possède que deux valeurs propres non nulles, exactement 1,6 et 0,4 – les deux autres valeurs propres de $\mathbf{W}$ sont nulles.
(b) $\mathbf{G}_1 = \sqrt{1,6} \times (1/\sqrt{2}; 1/\sqrt{2})' \approx 1,265 \times (0,707; 0,707)' \approx (0,894; 0,894)'$. Vérification : $0,894^2 + 0,894^2 \approx 0,8 + 0,8 = 1,6 = \lambda_1$.
(c) $\text{cov}(x_1, F_1) = \frac{1}{4} [(-2)(-1,789) + (-1)(0) + (1)(0) + (2)(1,789)] = \frac{1}{4} (3,578 + 3,578) = 1,789$.
 $r(x_1, F_1) = \frac{1,789}{\sqrt{2,5} \times \sqrt{1,6}} = \frac{1,789}{1,581 \times 1,265} \approx \frac{1,789}{2,000} \approx 0,894$. On retrouve exactement $G_{1,1} \approx 0,894$ calculé en (b) – la coordonnée d’une variable sur le cercle des corrélations *est* bien sa corrélation avec la composante.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $\mathbf{R}$ est 15×15 . $\mathbf{W}$ est $50\,000 \times 50\,000$.

(b) $\frac{50\,000^3}{15^3} = \frac{1,25 \times 10^{14}}{3\,375} \approx 3,7 \times 10^{10}$ – un rapport de plus de 37 milliards.

(c) L'entreprise doit diagonaliser $\mathbf{R}$ (la matrice 15×15 , radicalement moins coûteuse), puis obtenir les coordonnées des 50 000 clients par la relation de transition $\mathbf{F}_k = \mathbf{Z}\mathbf{u}_k$ (chapitre 4) – un simple produit matriciel, sans jamais avoir à diagonaliser $\mathbf{W}$.

Correction — Exercice 6

(a) On peut affirmer qu'il existe une **association** entre le segment « jeune urbain » et la variable *innovation* : ce segment se situe du même côté de l'origine que cette variable sur le premier axe, ce qui traduit une note d'innovation généralement supérieure à la moyenne pour ce segment.

(b) On ne peut pas affirmer une **distance** précise ni un lien quantifié entre les deux points à partir de leur seule proximité visuelle sur le biplot – les deux nuages (segments et variables) vivent dans des espaces différents, et leur superposition graphique ne permet de lire qu'une direction commune, jamais une distance croisée.

(c) Pour chiffrer précisément ce lien, il faudrait calculer directement la **corrélation** $r(\text{innovation}, F_k)$ entre la variable brute *innovation* et les coordonnées factorielles des individus du segment « jeune urbain » (ou, plus simplement, comparer la moyenne des notes d'innovation de ce segment à la moyenne générale) – un calcul rigoureux, plutôt qu'une lecture de distance graphique dépourvue de fondement mathématique en ACP.