

Analyse des données avancée

Chapitre 5 : Dualité et relations de transition

Jaouad Madkour


25 septembre 2026

Plan du chapitre

Les deux nuages	2
Un tableau, deux lectures	2
Ce qui distingue les deux nuages	2
Le théorème de dualité	2
L'énoncé	2
Ce que la démonstration révèle au passage	3
Le prix du calcul	3
Les relations de transition	3
Passer d'un nuage à l'autre	3
Ce que le facteur d'échelle empêche	4
Ce que le cercle des corrélations est vraiment	4
Vérifier sur nos données	5
Les deux calculs coïncident	5
Le petit tableau, des deux côtés	5
Ce qu'il faut retenir	5
Le résumé du chapitre	5

Les deux nuages

Un tableau, deux lectures



Une seule ACP, deux lectures — c'est ce qu'on appelle la dualité.

On ne fait pas deux calculs : la décomposition de la matrice des corrélations donne *en même temps* les axes des individus et ceux des variables. Le pourcentage d'inertie est donc le même des deux côtés.

D'où la **méthode de lecture, invariable** : on interprète d'abord le *cercle des corrélations* — il donne le *sens* des axes — puis le *plan des individus* — il dit *qui se trouve où*. Jamais l'inverse.

Ce qui distingue les deux nuages

Le nuage des individus

n points dans $\mathbb{R}^p$. Deux points sont proches quand les individus ont **répondu de la même façon**.

La métrique est euclidienne — sur données réduites, $d^2(i, \ell) = \sum_j (z_{ij} - z_{\ell j})^2$.

Le nuage des variables

p points dans $\mathbb{R}^n$. Sur données réduites, chaque variable est un vecteur de **norme 1**, et

$$\cos(\mathbf{z}_j, \mathbf{z}_m) = r(x_j, x_m)$$

Ce qui compte n'est donc pas la distance, mais **l'angle** : la corrélation est un cosinus.

Le point à ne pas manquer

Ces deux nuages ne vivent pas dans le même espace, ne se mesurent pas de la même façon, et ne répondent pas à la même question.

Rien n'annonce qu'ils aient un rapport. Et pourtant ils ont les **mêmes valeurs propres**.

Le théorème de dualité

L'énoncé

Les deux matrices

$$\mathbf{R} = \frac{1}{n} \mathbf{Z}' \mathbf{Z} \quad (p \times p) \qquad \mathbf{W} = \frac{1}{n} \mathbf{Z} \mathbf{Z}' \quad (n \times n)$$

Elles ont les **mêmes valeurs propres non nulles**, en nombre égal au rang de $\mathbf{Z}$.

La démonstration, en trois lignes

Soit $\mathbf{R}\mathbf{u} = \lambda\mathbf{u}$ avec $\lambda \neq 0$. Multiplions à gauche par $\mathbf{Z}$:

$$\frac{1}{n}\mathbf{Z}\mathbf{Z}'\mathbf{Z}\mathbf{u} = \lambda\mathbf{Z}\mathbf{u} \quad \text{soit} \quad \mathbf{W}(\mathbf{Z}\mathbf{u}) = \lambda(\mathbf{Z}\mathbf{u})$$

Donc $\mathbf{Z}\mathbf{u}$ est vecteur propre de $\mathbf{W}$ pour la **même** valeur propre. La réciproque s'obtient en multipliant par $\mathbf{Z}'$.

Ce que la démonstration révèle au passage

Intuition

Le vecteur propre de $\mathbf{W}$ n'est pas seulement associé à la même valeur propre : c'est $\mathbf{Z}\mathbf{u}$, c'est-à-dire la composante principale elle-même. Autrement dit, l'analyse des individus ne fournit rien de neuf. Elle **est** l'analyse des variables, lue de l'autre côté.

Le prix du calcul

Pourquoi les logiciels diagonalisent toujours la plus petite

$\mathbf{R}$ est 8×8 . $\mathbf{W}$ est 300×300 .

Le coût d'une diagonalisation croît comme le cube de la taille : $8^3 = 512$ contre $300^3 = 27$ millions. On diagonalise $\mathbf{R}$, puis on **déduit** le nuage des individus.

Sur un fichier de 100 000 clients et 20 variables, la dualité n'est plus une élégance : c'est la seule façon de calculer quoi que ce soit.

Les relations de transition

Passer d'un nuage à l'autre

Les deux formules

$$\mathbf{F}_k = \frac{1}{\sqrt{\lambda_k}} \mathbf{Z} \mathbf{G}_k \quad \mathbf{G}_k = \frac{1}{\sqrt{\lambda_k}} \frac{1}{n} \mathbf{Z}' \mathbf{F}_k$$

où $\mathbf{F}_k$ porte les coordonnées des individus et $\mathbf{G}_k$ celles des variables.

Ce qu'elles disent en français

Un individu se place là où le tirent les variables sur lesquelles il note haut. Un client qui donne de bonnes notes à tout est tiré du côté où toutes les variables se trouvent.

Une variable se place là où sont les individus qui y notent haut. Chaque formule est une moyenne pondérée de l'autre, à un facteur $1/\sqrt{\lambda_k}$ près.

Ce que le facteur d'échelle empêche

Le facteur $1/\sqrt{\lambda_k}$

Sans lui, les deux nuages ne seraient pas à la même échelle et la transition serait fausse. Avec lui, on peut superposer les deux représentations — c'est le **biplot** — mais **jamais lire une distance entre un individu et une variable**.

L'erreur de lecture la plus fréquente

Sur un biplot, un client tombe près de la variable *accueil*. On conclut qu'il a bien noté l'accueil.

C'est illégitime. Les deux nuages sont dans des espaces différents ; leur superposition est une commodité graphique. Seule la **direction** commune se lit : le client est du même côté de l'origine que la variable.


En AFC, au chapitre 9, la superposition sera au contraire **pleinement justifiée** — et c'est la seule méthode du cours où elle le soit.

Ce que le cercle des corrélations est vraiment

La coordonnée d'une variable

$$G_{jk} = r(x_j, \mathbf{F}_k)$$

La coordonnée d'une variable sur l'axe k est sa corrélation avec la composante k .



Trois règles de lecture, et elles ne se discutent pas.

1. **La longueur** mesure la qualité de représentation. Toutes les flèches approchent le cercle : les huit notes sont bien restituées par le plan.

2. **L'angle** mesure la corrélation. *Prix* et *accueil* forment un angle proche de 90° : ces deux jugements sont indépendants.

3. **Le côté** donne le sens. Toutes les flèches pointent à droite : **l'axe 1 est la satisfaction d'ensemble**. L'axe 2 sépare l'offre du service.

Une flèche courte ne s'interprète pas : elle est ailleurs.

Trois conséquences immédiates

Une corrélation est comprise entre -1 et 1 : toutes les variables sont donc **dans** le cercle de rayon 1.

$\sum_j G_{jk}^2 = \lambda_k$: les longueurs sur un axe se somment en la valeur propre.

Une variable **près du cercle** est bien représentée dans le plan ; une variable **près du centre** ne l'est pas, et son angle avec les autres ne veut rien dire.

Vérifier sur nos données

Les deux calculs coïncident

Diagonaliser $\mathbf{R}$, puis transiter

$\mathbf{R}$ donne $\lambda_1 = 4,535$ et le vecteur propre $\mathbf{u}_1$.

La transition $\mathbf{F}_1 = \mathbf{Z}\mathbf{u}_1$ place les 300 clients. On vérifie alors

$$\frac{1}{300} \sum_{i=1}^{300} F_{i1}^2 = 4,535 = \lambda_1$$

La variance des coordonnées des individus est la valeur propre issue des variables. Les deux nuages sont bien deux faces d'un seul objet.

Et dans l'autre sens

$$r(\text{prix}, \mathbf{F}_1) = 0,629 = G_{\text{prix},1}$$

La corrélation calculée directement entre la variable brute et la composante retombe sur la coordonnée lue dans le cercle — à la quatrième décimale.

Le petit tableau, des deux côtés

Quatre individus, deux variables

Côté variables : $\mathbf{R}$ est 2×2 , valeurs propres 1,6 et 0,4.

Côté individus : $\mathbf{W} = \frac{1}{4}\mathbf{Z}\mathbf{Z}'$ est 4×4 . Elle a **quatre** valeurs propres, mais seules deux sont non nulles — et ce sont 1,6 et 0,4.

Pourquoi deux valeurs propres nulles

Le rang de $\mathbf{Z}$ vaut 2 : quatre points de $\mathbb{R}^2$ ne peuvent engendrer qu'un plan.

En règle générale, le nombre de valeurs propres non nulles vaut $\min(n-1, p)$ — le -1 venant du centrage, qui consomme une dimension.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Un tableau définit **deux nuages** : les individus dans $\mathbb{R}^p$, les variables dans $\mathbb{R}^n$.
2. $\mathbf{R}$ et $\mathbf{W}$ ont **les mêmes valeurs propres non nulles** — c'est la dualité.
3. On diagonalise **la plus petite des deux**, puis on déduit l'autre.
4. Les **relations de transition** font passer d'un nuage à l'autre, au facteur $1/\sqrt{\lambda_k}$ près.
5. La coordonnée d'une variable **est** sa corrélation avec la composante : d'où le cercle.
6. Sur un biplot d'ACP, **on ne lit pas une distance individu-variable** : seulement une direction commune.

La suite

Les axes existent, en nombre égal au rang du tableau. Reste la question qu'aucun théorème ne tranche : **combien en garder ?** C'est l'objet du chapitre 6.