

Analyse des données avancée

Chapitre 18 : Étude de cas

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Choisir les variables actives d'une étude

Une direction des ressources humaines veut comprendre quels profils de salariés existent dans l'entreprise, à partir de 12 questions de satisfaction au travail, et dispose en outre de l'ancienneté, du service, du sexe et d'un indicateur de « départ volontaire dans l'année ».

- (a) Quelles variables devraient être actives dans l'ACP de départ ? Lesquelles illustratives ?
- (b) Pourquoi serait-ce une erreur de mettre « départ volontaire » en variable active ?
- (c) Si, une fois les axes calculés, le départ volontaire (en illustratif) s'aligne nettement sur l'axe 1, que peut-on en conclure sur la solidité du résultat ?

Exercice 2 — Associer une question de gestion à une méthode

Pour chacune des quatre questions suivantes, indiquer la méthode du cours la mieux adaptée (ACP, CAH/*k*-means, AFD, ou MDS) : (i) réduire 15 notes corrélées à quelques axes interprétables ; (ii) regrouper des clients en segments homogènes, sans groupe défini à l'avance ; (iii) savoir ce qui distingue des clients « churnés » de clients « fidèles », deux groupes déjà connus ; (iv) reconstruire une carte de positionnement à partir de jugements de ressemblance entre marques, sans aucune variable mesurée.

Exercice 3 — Juger la solidité d'une segmentation par trois signaux

Une étude de segmentation obtient : un saut d'inertie interclasse net entre 5 et 4 classes ; des 4 classes qui s'interprètent aisément ; une CAH et des *k*-means qui aboutissent à des partitions très proches (moins de 10 % de clients déplacés).

- (a) Ces trois signaux, pris isolément, prouvent-ils individuellement que la segmentation est « la bonne » ?
- (b) En quoi leur convergence rend-elle malgré tout la segmentation « défendable », au sens du cours ?
- (c) Si un seul des trois signaux avait fait défaut (par exemple, un déplacement de 45 % des clients lors de la consolidation), la conclusion resterait-elle aussi solide ?

2 Exercices cumulatifs (introduction au chapitre 18)

Exercice 4 — Assembler les résultats-clés de l'étude complète

On reprend les résultats-clés de l'étude du cours sur les 300 clients.

- (a) Calculer l'inertie retenue par les deux premiers axes de l'ACP (56,69 % + 20,57 %), et vérifier qu'on retrouve 77,26 %.
- (b) Calculer le gain d'inertie interclasse apporté par la consolidation (74,93 % → 76,50 %), et vérifier qu'on retrouve 1,57 point.
- (c) Calculer le rapport entre la corrélation du critère « conseil » (0,907) et celle du critère « prix » (0,110) avec l'axe discriminant, et vérifier qu'il dépasse 8. Que révèle ce rapport sur le poids respectif des deux critères dans la fidélisation des clients ?

3 Applications en sciences économiques

Exercice 5 — Rédiger une recommandation sans plan factoriel

Une étude de segmentation de la clientèle d'une compagnie d'assurance aboutit à quatre segments, dont un groupe de 340 assurés (sur 2 500) très satisfaits du service mais jugeant les tarifs élevés, avec un taux de résiliation deux fois inférieur à la moyenne.

- (a) Rédiger, en une phrase, une recommandation destinée à un comité de direction, qui nomme le groupe, chiffre son effectif, et désigne une action – sans mentionner de plan factoriel ni de valeur propre.
- (b) Pourquoi le cours insiste-t-il sur le fait qu'« aucune [phrase de recommandation] ne comporte de plan factoriel » ?
- (c) En quoi cette exigence de rédaction diffère-t-elle de la rigueur méthodologique attendue dans le corps de l'étude elle-même ?

Exercice 6 — Corriger un rapport d'étude incomplet

Un rapport d'étude marketing, réalisé sur 150 clients volontaires ayant répondu à une enquête en magasin, conclut : « Le segment 2 est significativement plus fidèle que les autres, et notre échantillon permet de généraliser ce résultat à l'ensemble de notre clientèle nationale. Le service est donc la cause de la fidélité. »

- (a) Relever, dans cette phrase, les affirmations qui posent problème au regard des quatre limites méthodologiques rappelées par le cours (causalité, généralisation, échantillonnage, tests de significativité).
- (b) Réécrire cette conclusion de façon honnête, en conservant l'information utile mais en corrigeant les excès identifiés.
- (c) Pourquoi le cours affirme-t-il qu'une étude qui tait ses limites n'est pas « une étude sans limites », mais « une étude dont on ignore les limites » ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) **Actives** : les 12 questions de satisfaction au travail (c'est l'opinion que l'on veut structurer).
Illustratives : ancienneté, service, sexe, et départ volontaire dans l'année.
- (b) Mettre « départ volontaire » en actif le ferait **fabriquer** l'axe 1 lui-même : l'ACP découvrirait alors, de façon quasiment circulaire, que les salariés qui partent sont ceux qui partent – un résultat sans valeur explicative, puisque la variable d'intérêt aurait participé à la construction de l'axe censé l'expliquer.
- (c) Cela constitue une **validation externe** solide : un axe construit *sans* la variable de départ volontaire la retrouve tout de même après coup, ce qui suggère que la structure révélée par les 12 questions de satisfaction n'est pas un artefact, mais reflète une réalité liée au comportement de départ des salariés.

Correction — Exercice 2

- (i) réduire 15 notes corrélées à quelques axes interprétables : **ACP**.
- (ii) regrouper des clients en segments homogènes, sans groupe défini à l'avance : **CAH puis k-means**.
- (iii) savoir ce qui distingue des clients « churnés » de clients « fidèles », deux groupes déjà connus : **AFD**.
- (iv) reconstruire une carte de positionnement à partir de jugements de ressemblance, sans aucune variable mesurée : **MDS**.


Correction — Exercice 3

- (a) Non : pris isolément, aucun des trois signaux ne **prouve** quoi que ce soit – un saut d'inertie net peut apparaître sur des données sans structure réelle, des classes peuvent s'interpréter par simple habileté rhétorique, et deux algorithmes peuvent converger par coïncidence sur un petit échantillon.
- (b) C'est leur **convergence** qui rend la segmentation défendable : il serait très improbable que trois indices indépendants (un critère numérique, un critère qualitatif d'interprétabilité, un critère de robustesse algorithmique) pointent tous dans la même direction sans qu'il existe une structure réelle sous-jacente.
- (c) Non : un déplacement massif (45 %) lors de la consolidation signalerait que la partition initiale de la CAH était largement **instable**, contredisant le troisième signal – il faudrait alors reconsidérer la solidité de l'ensemble de la segmentation, malgré les deux autres signaux favorables.

2 Exercices cumulatifs (introduction au chapitre 18)

Correction — Exercice 4

- (a) $56,69 + 20,57 = 77,26 \%$. Vérifié.
- (b) $76,50 - 74,93 = 1,57$ point. Vérifié.



- (c) $0,907/0,110 \approx 8,25$: le critère « conseil » a un pouvoir discriminant plus de **huit fois supérieur** à celui du « prix » pour distinguer les clients selon leur fréquence de visite. Cela confirme, chiffres à

l'appui, que la fidélisation des clients de ce fichier se joue essentiellement sur la qualité du service, et quasiment pas sur le niveau de prix perçu.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Exemple de recommandation : « Il faut cibler en priorité les 340 assurés très satisfaits du service mais sensibles au tarif : leur fidélité actuelle (résiliation deux fois inférieure à la moyenne) est un acquis à préserver, par exemple via une communication rassurante sur le rapport qualité-prix plutôt que par une baisse tarifaire. »
- (b) Parce qu'un comité de direction n'a pas besoin de comprendre la mécanique de l'ACP ou de la CAH pour agir : un plan factoriel ou une valeur propre sont des **outils de travail de l'analyste**, pas des éléments actionnables pour la décision. Insérer un plan factoriel dans la conclusion déplacerait la charge de compréhension vers un public qui n'en a pas besoin, et diluerait le message opérationnel.
- (c) Le corps de l'étude doit rester **intégralement rigoureux et vérifiable** (méthodes, calculs, graphiques, limites) pour tout lecteur compétent qui voudrait l'auditer ; la conclusion, elle, doit être **actionnable et lisible** par un public non spécialiste. Les deux exigences ne se contredisent pas : elles s'adressent à deux publics et à deux moments différents de la lecture du rapport.

Correction — Exercice 6

- (a) Trois affirmations posent problème : « significativement plus fidèle » invoque un **test de significativité** qui n'a pas de sens ici (aucun test n'a été mené, et le mot « significatif » n'est pas approprié en analyse des données descriptive) ; « généraliser à l'ensemble de notre clientèle nationale » suppose un **échantillonnage aléatoire**, alors qu'il s'agit de 150 clients volontaires interrogés en magasin (un échantillon de convenance, non représentatif par construction) ; « le service est donc la cause de la fidélité » affirme une **causalité** qu'aucun des outils mobilisés (ACP, classification) n'établit – seule une association a été observée.
- (b) Une reformulation honnête pourrait être : « Parmi les 150 clients interrogés en magasin, le segment 2 se distingue par une fréquence de visite nettement plus élevée que les autres segments, et cette fréquence est associée à de meilleures notes de service. Ce résultat, obtenu sur un échantillon de volontaires, ne peut pas être généralisé sans réserve à l'ensemble de la clientèle, et n'établit pas de lien de cause à effet entre qualité du service et fidélité. »
- (c) Parce que les limites (absence de causalité, non-généralisation, nature de l'échantillon, absence de test) existent **de toute façon**, qu'elles soient énoncées ou non : les taire ne rend pas l'étude plus rigoureuse, cela prive seulement le lecteur des éléments nécessaires pour juger de sa portée réelle. Une étude qui les explicite n'est pas plus faible qu'une étude qui les cache – elle est simplement plus honnête, et c'est justement ce qui permet à un lecteur compétent de juger si l'auteur a compris ce qu'il a fait.