

Analyse des données avancée

Chapitre 4 : L'ACP en écriture matricielle

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Résoudre le programme de l'ACP sur un exemple

On donne $V = \begin{pmatrix} 5 & 2 \\ 2 & 5 \end{pmatrix}$.

- (a) Écrire la condition du premier ordre $Va = \lambda a$ et en déduire les deux valeurs propres.
- (b) Donner le vecteur propre normé a_1 associé à la plus grande valeur propre (on admettra qu'il s'agit, comme au chapitre 3, de la bissectrice).
- (c) Calculer directement $a_1' V a_1$ et vérifier qu'on retrouve bien λ_1 .

Exercice 2 — Vérifier les trois propriétés des composantes

Sur un fichier à 4 individus, la première composante principale vaut $F_1 = (-3, -1, 1, 3)$ et la seconde $F_2 = (1, -1, -1, 1)$.

- (a) Calculer $\bar{F}_1$ et $\bar{F}_2$. Retrouve-t-on bien $\bar{F}_k = 0$?
- (b) Calculer $V(F_1)$ et $V(F_2)$. En déduire les valeurs propres λ_1 et λ_2 correspondantes.
- (c) Calculer $\text{cov}(F_1, F_2)$. Ce résultat était-il prévisible, sachant que F_1 et F_2 sont construites à partir de deux vecteurs propres d'une même matrice symétrique?

Exercice 3 — Lire une matrice des corrélations avant de calculer

Un questionnaire RH mesure 4 critères réduits : charge de travail perçue (c), autonomie (a), reconnaissance (r), esprit d'équipe (e). La matrice des corrélations est :

$$\begin{pmatrix} 1 & 0,75 & 0,20 & 0,18 \\ 0,75 & 1 & 0,22 & 0,19 \\ 0,20 & 0,22 & 1 & 0,70 \\ 0,18 & 0,19 & 0,70 & 1 \end{pmatrix}$$

- (a) Toutes les corrélations sont-elles positives ? Que peut-on en déduire, sans calcul, sur le signe des quatre coefficients du premier axe ?
- (b) Deux « blocs » de corrélations fortes se distinguent-ils dans cette matrice ? Lesquels ?
- (c) En anticipant sur la lecture du cercle des corrélations (déjà vue en Licence), quelle opposition le second axe risque-t-il de faire apparaître ?

2 Exercices cumulatifs (introduction au chapitre 4)

Exercice 4 — L'ACP normée complète du fil rouge

On reprend le fil rouge : $X = \begin{pmatrix} -2 & -2 \\ -1 & 1 \\ 1 & -1 \\ 2 & 2 \end{pmatrix}$, de variances $s_1^2 = s_2^2 = 2,5$ (chapitre 2), et $R = \begin{pmatrix} 1 & 0,6 \\ 0,6 & 1 \end{pmatrix}$,

de valeurs propres $\lambda_1 = 1,6$ et $\lambda_2 = 0,4$ (cours).

- (a) Calculer les coordonnées réduites $z_{i1} = x_{i1}/\sqrt{2,5}$ et $z_{i2} = x_{i2}/\sqrt{2,5}$ pour l'individu 1 et pour l'individu 4.
- (b) En utilisant $u_1 = (1, 1)'/\sqrt{2}$, calculer $F_{1,1} = (z_{1,1} + z_{1,2})/\sqrt{2}$ (individu 1) et $F_{1,4}$ (individu 4). Vérifier qu'on retrouve les valeurs $-1,789$ et $1,789$ du cours.
- (c) Sachant que $F_{1,2} = F_{1,3} = 0$ (cours), calculer $V(F_1) = \frac{1}{4} \sum_i F_{1,i}^2$ et vérifier qu'on retrouve $\lambda_1 = 1,6$.

3 Applications en sciences économiques

Exercice 5 — Nommer les deux premiers axes d'une étude produit

Une étude de marché mesure 5 critères de perception d'un produit (prix, qualité, innovation, design, service après-vente), tous fortement corrélés positivement entre eux. L'ACP donne $\lambda_1 = 3,1$ et $\lambda_2 = 0,9$ sur un total $I = 5$.

- (a) Calculer le pourcentage d'inertie porté par le premier axe.
- (b) Sachant que les cinq corrélations avec le premier axe sont toutes positives et de taille comparable, quel type d'axe (effet de taille ou effet de forme) le premier axe constitue-t-il? Proposer une interprétation économique.
- (c) Le second axe oppose « prix et service après-vente » à « qualité, innovation et design ». Formuler, en une phrase, ce que cette opposition pourrait signifier pour deux segments de clientèle différents.

Exercice 6 — Construire des facteurs de risque non corrélés

Une société de gestion dispose de 6 indicateurs de risque fortement corrélés entre eux. Après ACP, le premier facteur F_1 a une variance de 3,8 et le second F_2 une variance de 1,1, sur une inertie totale $I = 6$.

- (a) D'après les propriétés du cours, que vaut $\text{cov}(F_1, F_2)$, sans qu'aucun calcul supplémentaire ne soit nécessaire?
- (b) Pourquoi cette absence de corrélation entre F_1 et F_2 est-elle précisément ce que cherchait la société de gestion, si son objectif est d'identifier des sources de risque **distinctes**?
- (c) Un gérant propose d'utiliser directement les 6 indicateurs bruts plutôt que les facteurs, en arguant qu'ils sont « plus faciles à expliquer aux clients ». Quel inconvénient statistique ce choix comporte-t-il, compte tenu de la forte corrélation initiale entre les 6 indicateurs?

1 Exercices du chapitre

Correction — Exercice 1

(a) $(5 - \lambda)^2 - 4 = 0 \Leftrightarrow 5 - \lambda = \pm 2$, donc $\lambda_1 = 7$ et $\lambda_2 = 3$.

(b) $\mathbf{a}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$.

(c) $\mathbf{V}\mathbf{a}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 5+2 \\ 2+5 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 7 \\ 7 \end{pmatrix}$. $\mathbf{a}_1' \mathbf{V}\mathbf{a}_1 = \frac{1}{\sqrt{2}}(7) + \frac{1}{\sqrt{2}}(7) \dots$ plus précisément $\mathbf{a}_1' \mathbf{V}\mathbf{a}_1 = \frac{1}{2}(7+7) = 7 = \lambda_1$. Vérifié.

Correction — Exercice 2

(a) $\bar{F}_1 = \frac{-3-1+1+3}{4} = 0$. $\bar{F}_2 = \frac{1-1-1+1}{4} = 0$. On retrouve bien $\bar{F}_k = 0$.

(b) $V(F_1) = \frac{9+1+1+9}{4} = \frac{20}{4} = 5$, donc $\lambda_1 = 5$. $V(F_2) = \frac{1+1+1+1}{4} = 1$, donc $\lambda_2 = 1$.

(c) $\text{cov}(F_1, F_2) = \frac{(-3)(1) + (-1)(-1) + (1)(-1) + (3)(1)}{4} = \frac{-3+1-1+3}{4} = 0$. Ce résultat était prévisible : le théorème spectral garantit que les vecteurs propres d'une matrice symétrique associés à des valeurs propres distinctes sont orthogonaux, et cette orthogonalité se traduit exactement par une covariance nulle entre les composantes qui en dérivent – ce n'est pas une coïncidence numérique, c'est une conséquence nécessaire de la construction.

Correction — Exercice 3

(a) Oui, toutes les corrélations sont positives. On peut en déduire, sans calcul, que les quatre coefficients du premier axe seront eux aussi tous du **même signe** : un salarié qui note bien un critère aura tendance à bien noter les trois autres, donc le premier axe classera les salariés selon un niveau général (effet de taille).

(b) Deux blocs se distinguent : {charge de travail, autonomie} (corrélation 0,75, forte) et {reconnaissance, esprit d'équipe} (corrélation 0,70, forte), les corrélations *entre* les deux blocs étant nettement plus faibles (0,18 à 0,22).

(c) Le second axe risque d'opposer le bloc « charge de travail–autonomie » au bloc « reconnaissance–esprit d'équipe », exactement comme sur le fichier des 300 clients le second axe oppose « prix–choix–qualité–agencement » à « propreté–rapidité–conseil–accueil » – une structure en blocs dans la matrice des corrélations annonce presque toujours ce type d'opposition sur le second axe.


2 Exercices cumulatifs (introduction au chapitre 4)

Correction — Exercice 4

(a) Individu 1 : $z_{1,1} = \frac{-2}{\sqrt{2,5}} \approx -1,265$, $z_{1,2} = \frac{-2}{\sqrt{2,5}} \approx -1,265$. Individu 4 : $z_{4,1} = \frac{2}{\sqrt{2,5}} \approx 1,265$, $z_{4,2} \approx 1,265$.

(b) $F_{1,1} = \frac{-1,265 - 1,265}{\sqrt{2}} \approx \frac{-2,530}{1,414} \approx -1,789$. $F_{1,4} = \frac{1,265 + 1,265}{\sqrt{2}} \approx 1,789$. On retrouve bien les valeurs du cours.

(c) $V(F_1) = \frac{1}{4} [(-1,789)^2 + 0^2 + 0^2 + (1,789)^2] = \frac{1}{4} (3,2 + 0 + 0 + 3,2) = \frac{6,4}{4} = 1,6 = \lambda_1$. Vérifié.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $\frac{3,1}{5} = 62\%$.

(b) C'est un **effet de taille** : les cinq corrélations positives et comparables signalent un axe qui classe les produits selon un niveau général de perception favorable, sans privilégier un critère particulier – on peut l'interpréter comme « la qualité perçue globale du produit ».

(c) Cette opposition pourrait signaler deux segments de clientèle aux attentes différentes : l'un valorisant surtout le **rapport qualité-prix immédiat et le suivi après achat** (prix, service après-vente), l'autre privilégiant **l'innovation et l'expérience produit** (qualité, innovation, design) – une distinction qu'une simple moyenne des cinq critères n'aurait jamais fait apparaître.

Correction — Exercice 6

(a) $\text{cov}(F_1, F_2) = 0$: c'est une propriété générale des composantes principales, garantie par l'orthogonalité des vecteurs propres d'une matrice symétrique, quelles que soient les valeurs propres associées.

(b) C'est précisément l'objectif recherché : les 6 indicateurs de départ étant fortement corrélés, ils redisaient largement la même information sous des habillages différents. Les facteurs F_1 et F_2 , non corrélés par construction, permettent d'identifier des sources de risque véritablement **distinctes** – une variation de F_1 n'entraîne, par construction, aucune variation systématique de F_2 .

(c) Utiliser les 6 indicateurs bruts, fortement corrélés entre eux, revient à compter plusieurs fois le même risque sous des noms différents – un choc sur un indicateur se propage mécaniquement aux cinq autres, ce qui peut conduire à **surestimer** la diversification apparente d'un portefeuille construit à partir de ces 6 variables prises séparément, alors que les facteurs non corrélés donnent une image plus fidèle des sources de risque réellement indépendantes.