

Chapitre 8

L'AFC et la métrique du khi-deux

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée


1 Exercices du chapitre

Correction — Exercice 1

(a) Les trois termes sont

$$\frac{1}{0,4}(0,6 - 0,2)^2, \quad \frac{1}{0,3}(0,2 - 0,4)^2, \quad \frac{1}{0,3}(0,2 - 0,4)^2.$$

(b) $d_{\chi^2}^2(A, B) = \frac{0,16}{0,4} + \frac{0,04}{0,3} + \frac{0,04}{0,3} = 0,4 + 0,1333 + 0,1333 = 0,6667.$



(c) Sans la pondération $1/f_{.j}$, un écart de profil sur une colonne *rare* (petite marge $f_{.j}$) compterait autant qu'un écart identique sur une colonne *fréquente* – alors qu'un même écart absolu de profil est *statistiquement bien plus surprenant* sur une petite colonne. La pondération par $1/f_{.j}$ corrige cette hétérogénéité, exactement comme la métrique $M = \text{diag}(1/s_j^2)$ standardise les variables en ACP normée.

Correction — Exercice 2


(a) $\text{profil}(A) = (0,5; 0,25; 0,25)$, $\text{profil}(B) = (0,25; 0,375; 0,375)$, marges-colonnes $(0,375; 0,3125; 0,3125)$.

$$d_{\chi^2}^2(A, B) = \frac{(0,25)^2}{0,375} + \frac{(0,125)^2}{0,3125} + \frac{(0,125)^2}{0,3125} = 0,1667 + 0,05 + 0,05 = 0,2667.$$

(b) Colonnes 2 et 3 regroupées : $A = (20, 20)$, $B = (10, 30)$, profils $(0,5; 0,5)$ et $(0,25; 0,75)$, marges $(0,375; 0,625)$.

$$d_{\chi^2}^2(A, B) = \frac{(0,25)^2}{0,375} + \frac{(0,25)^2}{0,625} = 0,1667 + 0,1 = 0,2667.$$

(c) Les deux distances coïncident exactement : $0,2667 = 0,2667$. Ce résultat n'était pas garanti en général – regrouper des colonnes *déforme* d'ordinaire les distances du khi-deux. Il se produit ici parce que les colonnes 2 et 3 ont, pour les deux lignes A et B, un rapport constant entre elles ($10/10 = 1$ pour A, $15/15 = 1$ pour B) : c'est la **propriété d'équivalence distributionnelle**, qui garantit l'invariance de la distance dès lors que les colonnes fusionnées ont des profils proportionnels entre les lignes.




Correction — Exercice 3

(a) $\Phi^2 = \chi^2/n = 86,4/250 = 0,3456$.

(b) Rapport part d'inertie / poids :

$$\text{Jeunes} : \frac{0,15}{0,30} = 0,5, \quad \text{Actifs} : \frac{0,55}{0,50} = 1,1, \quad \text{Seniors} : \frac{0,30}{0,20} = 1,5.$$



(c) La classe **Seniors** est la plus atypique : son ratio (1,5) est le plus éloigné de 1 vers le haut, elle porte 1,5 fois plus d'inertie que ne le laisserait attendre son seul poids – son profil s'écarte donc fortement du profil moyen. La classe **Jeunes** est la plus proche du profil moyen : son ratio (0,5) est le plus bas, elle porte deux fois *moins* d'inertie que son poids ne le suggère, signe que son profil ressemble beaucoup au profil moyen de l'ensemble des clients.


2 Exercices cumulatifs (introduction au chapitre 8)

Correction — Exercice 4

(a) $\Phi^2 = \chi^2/n = 110,41/300 = 0,3680$. On retrouve bien 0,368 (cours).

(b) $\frac{60,8}{110,41} \approx 0,5507 = 55,07\% \approx 55\%$. On retrouve bien le chiffre du cours.

(c) $\lambda_1 + \lambda_2 + \lambda_3 = 0,2267 + 0,1030 + 0,0384 = 0,3681 \approx \Phi^2 = 0,368$ – l'écart de 0,0001 n'est qu'un arrondi. Le tableau CSP $\times$ motif comporte 5 lignes et 4 colonnes ; le rang maximal de l'AFC est $\min(I-1, J-1) = \min(4, 3) = 3$, ce qui correspond bien aux trois valeurs propres non nulles annoncées.



3 Applications en sciences économiques

Correction — Exercice 5

(a) Non : d'après la propriété d'équivalence distributionnelle, si la répartition interne entre « web mobile » et « web ordinateur » est (quasiment) la même pour toutes les catégories de clients, alors regrouper ces deux colonnes en une seule « web » ne change (quasiment) pas les distances du khi-deux entre catégories de clients – exactement comme dans l'Exercice 2, où fusionner deux colonnes de profils proportionnels laissait $d_{\chi^2}^2$ inchangée.


(b) Non, ce résultat ne se maintiendrait plus. Si la répartition 60 %–40 % variait fortement d’une catégorie à l’autre (profils non proportionnels entre les deux colonnes), regrouper « web mobile » et « web ordinateur » *effacerait* une information discriminante entre catégories, et les distances du khi-deux calculées après fusion différeraient de celles calculées avant fusion.

(c) Cette propriété rassure l’analyste car elle montre que, tant que les sous-catégories fusionnées se comportent de façon homogène (proportionnelle) vis-à-vis des autres variables, le niveau de détail choisi (fin ou grossier) n’affecte pas les conclusions de l’AFC portant sur les autres dimensions du tableau. Le découpage en modalités n’a donc pas besoin d’être arbitrairement « parfait » : la méthode absorbe les regroupements raisonnables.

Correction — Exercice 6

(a) $\Phi^2 = \chi^2/n = 54,0/600 = 0,09$.

(b) Rapport part d’inertie / poids : Nord = $0,12/0,40 = 0,3$; Sud = $0,38/0,15 \approx 2,53$.



(c) Ce n’est pas une anomalie : la part d’inertie ne mesure pas la *taille* d’une région mais l’*atypicité* de son profil de satisfaction par rapport au profil moyen. La région Sud, bien que peu peuplée (poids 0,15), a un profil de satisfaction très éloigné du profil moyen (ratio $\approx 2,53$) : c’est justement une petite région qui se comporte *différemment* des autres, et l’AFC est construite pour révéler ce type d’écart, indépendamment des effectifs. À l’inverse, la région Nord, malgré son poids important (0,40), a un profil proche de la moyenne (ratio 0,3) et ne pèse donc que peu dans la construction des axes.