

# Analyse des données avancée

Chapitre 8 : L'AFC et la métrique du khi-deux

**Exercices corrigés**

---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

## Table des matières

|                                       |   |
|---------------------------------------|---|
| <b>Partie 1 --- Énoncés</b> .....     | 1 |
| <b>Partie 2 --- Corrections</b> ..... | 3 |

## 1 Exercices du chapitre

### Exercice 1 — Calculer une distance du khi-deux entre deux profils

Deux groupes de clients  $A$  et  $B$  (50 chacun) sont répartis sur trois canaux d'achat, de profils  $\text{profil}(A) = (0,6; 0,2; 0,2)$  et  $\text{profil}(B) = (0,2; 0,4; 0,4)$ , avec des marges-colonnes  $f_{.1} = 0,4, f_{.2} = 0,3, f_{.3} = 0,3$ .

- (a) Écrire les trois termes de la distance du khi-deux  $d_{\chi^2}^2(A, B) = \sum_j \frac{1}{f_{.j}} (\text{profil}(A)_j - \text{profil}(B)_j)^2$ .
- (b) Calculer  $d_{\chi^2}^2(A, B)$ .
- (c) Pourquoi ne calcule-t-on pas simplement  $\sum_j (\text{profil}(A)_j - \text{profil}(B)_j)^2$ , sans pondérer par  $1/f_{.j}$ ?

### Exercice 2 — Vérifier l'équivalence distributionnelle

Deux lignes  $A$  (effectif total 40) et  $B$  (effectif total 40) sont réparties sur trois colonnes :  $A = (20, 10, 10)$ ,  $B = (10, 15, 15)$ .

- (a) Calculer  $d_{\chi^2}^2(A, B)$  avec les trois colonnes séparées.
- (b) On regroupe les colonnes 2 et 3 en une seule (leurs effectifs s'additionnent :  $A = (20, 20)$ ,  $B = (10, 30)$ ). Recalculer  $d_{\chi^2}^2(A, B)$  avec seulement deux colonnes.
- (c) Les deux distances coïncident-elles? Pourquoi ce résultat n'était-il pas garanti a priori, et que doit-on remarquer sur les colonnes 2 et 3 pour comprendre pourquoi il se produit ici?

### Exercice 3 — Poids et inertie, deux choses distinctes

Une enquête bancaire donne  $\chi^2 = 86,4$  pour  $n = 250$  clients, répartis en trois classes d'âge dont les poids et les parts d'inertie (en fraction de l'inertie totale) sont : Jeunes (poids 0,30, part d'inertie 0,15), Actifs (poids 0,50, part d'inertie 0,55), Seniors (poids 0,20, part d'inertie 0,30).

- (a) Calculer l'inertie totale  $\Phi^2 = \chi^2/n$ .
- (b) Calculer, pour chaque classe, le rapport entre sa part d'inertie et son poids.
- (c) Quelle classe est la plus « atypique » au sens de l'AFC (celle dont le profil s'écarte le plus du profil moyen relativement à sa taille)? Quelle classe est la plus proche du profil moyen?

## 2 Exercices cumulatifs (introduction au chapitre 8)

### Exercice 4 — Vérifier le tableau CSP $\times$ motif du cours

On reprend le tableau CSP  $\times$  motif de fréquentation des 300 clients (cours) :  $\chi^2 = 110,41$  pour 12 degrés de liberté, et les quatre cases les plus contributives (étudiant-prix, cadre-choix, retraité-proximité, indépendant-service) totalisent 60,8 sur ce  $\chi^2$ .

- (a) Calculer l'inertie totale  $\Phi^2 = \chi^2/n$  et vérifier qu'on retrouve 0,368.
- (b) Calculer le pourcentage du  $\chi^2$  total porté par ces quatre seules cases, et vérifier qu'on retrouve environ 55 %.
- (c) Les trois valeurs propres de l'AFC valent  $\lambda_1 = 0,2267, \lambda_2 = 0,1030, \lambda_3 = 0,0384$ . Vérifier que leur somme redonne bien  $\Phi^2$ , et que leur nombre (3) correspond bien à  $\min(5, 4) - 1$ , le rang maximal pour ce tableau  $5 \times 4$ .

## 3 Applications en sciences économiques

### Exercice 5 — Regrouper des catégories sans biaiser l'analyse

Une enseigne de distribution hésite à distinguer, dans son étude, les canaux « web mobile » et « web ordinateur », ou à les regrouper en un seul « web ». Elle observe que, pour chacune des catégories de clients de son fichier, la répartition entre « web mobile » et « web ordinateur » est quasiment identique (environ 60 %–40 % partout).

- (a) D'après la propriété d'équivalence distributionnelle, le choix de regrouper ou non ces deux canaux changera-t-il les distances du khi-deux entre catégories de clients ?
- (b) Si, au contraire, la répartition 60 %–40 % variait fortement d'une catégorie de clients à l'autre, ce résultat resterait-il valable ?
- (c) En quoi cette propriété rassure-t-elle un analyste qui doit choisir, de façon en partie arbitraire, le niveau de détail de son découpage en modalités ?

### Exercice 6 — Décomposer une inertie de satisfaction par région

Une chaîne croise la région (4 modalités) et le niveau de satisfaction déclaré (3 modalités) de 600 clients, avec  $\chi^2 = 54,0$ . La région Nord, qui pèse 0,40 de l'effectif, porte 0,12 de l'inertie totale ; la région Sud, qui pèse 0,15, porte 0,38 de l'inertie totale.

- (a) Calculer l'inertie totale  $\Phi^2$  de ce tableau.
- (b) Calculer le rapport part d'inertie / poids pour chacune des deux régions.
- (c) La direction commerciale s'étonne que la région Sud, pourtant peu peuplée, « pèse autant » dans les résultats de l'étude. Expliquer, à partir de la distinction entre poids et inertie, pourquoi ce n'est pas une anomalie mais un résultat attendu de la méthode.


## 1 Exercices du chapitre

### Correction — Exercice 1

(a) Les trois termes sont

$$\frac{1}{0,4}(0,6 - 0,2)^2, \quad \frac{1}{0,3}(0,2 - 0,4)^2, \quad \frac{1}{0,3}(0,2 - 0,4)^2.$$

(b)  $d_{\chi^2}^2(A, B) = \frac{0,16}{0,4} + \frac{0,04}{0,3} + \frac{0,04}{0,3} = 0,4 + 0,1333 + 0,1333 = 0,6667.$



(c) Sans la pondération  $1/f_{.j}$ , un écart de profil sur une colonne *rare* (petite marge  $f_{.j}$ ) compterait autant qu'un écart identique sur une colonne *fréquente* – alors qu'un même écart absolu de profil est *statistiquement bien plus surprenant* sur une petite colonne. La pondération par  $1/f_{.j}$  corrige cette hétérogénéité, exactement comme la métrique  $M = \text{diag}(1/s_j^2)$  standardise les variables en ACP normée.

### Correction — Exercice 2


(a)  $\text{profil}(A) = (0,5; 0,25; 0,25)$ ,  $\text{profil}(B) = (0,25; 0,375; 0,375)$ , marges-colonnes  $(0,375; 0,3125; 0,3125)$ .

$$d_{\chi^2}^2(A, B) = \frac{(0,25)^2}{0,375} + \frac{(0,125)^2}{0,3125} + \frac{(0,125)^2}{0,3125} = 0,1667 + 0,05 + 0,05 = 0,2667.$$

(b) Colonnes 2 et 3 regroupées :  $A = (20, 20)$ ,  $B = (10, 30)$ , profils  $(0,5; 0,5)$  et  $(0,25; 0,75)$ , marges  $(0,375; 0,625)$ .

$$d_{\chi^2}^2(A, B) = \frac{(0,25)^2}{0,375} + \frac{(0,25)^2}{0,625} = 0,1667 + 0,1 = 0,2667.$$

(c) Les deux distances coïncident exactement :  $0,2667 = 0,2667$ . Ce résultat n'était pas garanti en général – regrouper des colonnes *déforme* d'ordinaire les distances du khi-deux. Il se produit ici parce que les colonnes 2 et 3 ont, pour les deux lignes A et B, un rapport constant entre elles ( $10/10 = 1$  pour A,  $15/15 = 1$  pour B) : c'est la **propriété d'équivalence distributionnelle**, qui garantit l'invariance de la distance dès lors que les colonnes fusionnées ont des profils proportionnels entre les lignes.




### Correction — Exercice 3

(a)  $\Phi^2 = \chi^2/n = 86,4/250 = 0,3456$ .

(b) Rapport part d'inertie / poids :

$$\text{Jeunes : } \frac{0,15}{0,30} = 0,5, \quad \text{Actifs : } \frac{0,55}{0,50} = 1,1, \quad \text{Seniors : } \frac{0,30}{0,20} = 1,5.$$



(c) La classe **Seniors** est la plus atypique : son ratio (1,5) est le plus éloigné de 1 vers le haut, elle porte 1,5 fois plus d'inertie que ne le laisserait attendre son seul poids – son profil s'écarte donc fortement du profil moyen. La classe **Jeunes** est la plus proche du profil moyen : son ratio (0,5) est le plus bas, elle porte deux fois *moins* d'inertie que son poids ne le suggère, signe que son profil ressemble beaucoup au profil moyen de l'ensemble des clients.


## 2 Exercices cumulatifs (introduction au chapitre 8)

### Correction — Exercice 4

(a)  $\Phi^2 = \chi^2/n = 110,41/300 = 0,3680$ . On retrouve bien 0,368 (cours).

(b)  $\frac{60,8}{110,41} \approx 0,5507 = 55,07\% \approx 55\%$ . On retrouve bien le chiffre du cours.

(c)  $\lambda_1 + \lambda_2 + \lambda_3 = 0,2267 + 0,1030 + 0,0384 = 0,3681 \approx \Phi^2 = 0,368$  – l'écart de 0,0001 n'est qu'un arrondi. Le tableau CSP  $\times$  motif comporte 5 lignes et 4 colonnes ; le rang maximal de l'AFC est  $\min(I-1, J-1) = \min(4, 3) = 3$ , ce qui correspond bien aux trois valeurs propres non nulles annoncées.



## 3 Applications en sciences économiques

### Correction — Exercice 5

(a) Non : d'après la propriété d'équivalence distributionnelle, si la répartition interne entre « web mobile » et « web ordinateur » est (quasiment) la même pour toutes les catégories de clients, alors regrouper ces deux colonnes en une seule « web » ne change (quasiment) pas les distances du khi-deux entre catégories de clients – exactement comme dans l'Exercice 2, où fusionner deux colonnes de profils proportionnels laissait  $d_{\chi^2}^2$  inchangée. <sup>4</sup>


(b) Non, ce résultat ne se maintiendrait plus. Si la répartition 60 %–40 % variait fortement d’une catégorie à l’autre (profils non proportionnels entre les deux colonnes), regrouper « web mobile » et « web ordinateur » *effacerait* une information discriminante entre catégories, et les distances du khi-deux calculées après fusion différeraient de celles calculées avant fusion.

(c) Cette propriété rassure l’analyste car elle montre que, tant que les sous-catégories fusionnées se comportent de façon homogène (proportionnelle) vis-à-vis des autres variables, le niveau de détail choisi (fin ou grossier) n’affecte pas les conclusions de l’AFC portant sur les autres dimensions du tableau. Le découpage en modalités n’a donc pas besoin d’être arbitrairement « parfait » : la méthode absorbe les regroupements raisonnables.

### Correction — Exercice 6

(a)  $\Phi^2 = \chi^2/n = 54,0/600 = 0,09$ .

(b) Rapport part d’inertie / poids : Nord =  $0,12/0,40 = 0,3$ ; Sud =  $0,38/0,15 \approx 2,53$ .



(c) Ce n’est pas une anomalie : la part d’inertie ne mesure pas la *taille* d’une région mais l’*atypicité* de son profil de satisfaction par rapport au profil moyen. La région Sud, bien que peu peuplée (poids 0,15), a un profil de satisfaction très éloigné du profil moyen (ratio  $\approx 2,53$ ) : c’est justement une petite région qui se comporte *différemment* des autres, et l’AFC est construite pour révéler ce type d’écart, indépendamment des effectifs. À l’inverse, la région Nord, malgré son poids important (0,40), a un profil proche de la moyenne (ratio 0,3) et ne pèse donc que peu dans la construction des axes.