

Chapitre 8

L'AFC et la métrique du khi-deux

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Exercice 1 — Calculer une distance du khi-deux entre deux profils

Deux groupes de clients A et B (50 chacun) sont répartis sur trois canaux d'achat, de profils $\text{profil}(A) = (0,6; 0,2; 0,2)$ et $\text{profil}(B) = (0,2; 0,4; 0,4)$, avec des marges-colonnes $f_{.1} = 0,4, f_{.2} = 0,3, f_{.3} = 0,3$.

- (a) Écrire les trois termes de la distance du khi-deux $d_{\chi^2}^2(A, B) = \sum_j \frac{1}{f_{.j}} (\text{profil}(A)_j - \text{profil}(B)_j)^2$.
- (b) Calculer $d_{\chi^2}^2(A, B)$.
- (c) Pourquoi ne calcule-t-on pas simplement $\sum_j (\text{profil}(A)_j - \text{profil}(B)_j)^2$, sans pondérer par $1/f_{.j}$?

Exercice 2 — Vérifier l'équivalence distributionnelle

Deux lignes A (effectif total 40) et B (effectif total 40) sont réparties sur trois colonnes : $A = (20, 10, 10)$, $B = (10, 15, 15)$.

- (a) Calculer $d_{\chi^2}^2(A, B)$ avec les trois colonnes séparées.
- (b) On regroupe les colonnes 2 et 3 en une seule (leurs effectifs s'additionnent : $A = (20, 20)$, $B = (10, 30)$). Recalculer $d_{\chi^2}^2(A, B)$ avec seulement deux colonnes.
- (c) Les deux distances coïncident-elles ? Pourquoi ce résultat n'était-il pas garanti a priori, et que doit-on remarquer sur les colonnes 2 et 3 pour comprendre pourquoi il se produit ici ?

Exercice 3 — Poids et inertie, deux choses distinctes

Une enquête bancaire donne $\chi^2 = 86,4$ pour $n = 250$ clients, répartis en trois classes d'âge dont les poids et les parts d'inertie (en fraction de l'inertie totale) sont : Jeunes (poids 0,30, part d'inertie 0,15), Actifs (poids 0,50, part d'inertie 0,55), Seniors (poids 0,20, part d'inertie 0,30).

- (a) Calculer l'inertie totale $\Phi^2 = \chi^2/n$.
- (b) Calculer, pour chaque classe, le rapport entre sa part d'inertie et son poids.
- (c) Quelle classe est la plus « atypique » au sens de l'AFC (celle dont le profil s'écarte le plus du profil moyen relativement à sa taille) ? Quelle classe est la plus proche du profil moyen ?

2 Exercices cumulatifs (introduction au chapitre 8)

Exercice 4 — Vérifier le tableau CSP $\times$ motif du cours

On reprend le tableau CSP $\times$ motif de fréquentation des 300 clients (cours) : $\chi^2 = 110,41$ pour 12 degrés de liberté, et les quatre cases les plus contributives (étudiant-prix, cadre-choix, retraité-proximité, indépendant-service) totalisent 60,8 sur ce χ^2 .

- (a) Calculer l'inertie totale $\Phi^2 = \chi^2/n$ et vérifier qu'on retrouve 0,368.
- (b) Calculer le pourcentage du χ^2 total porté par ces quatre seules cases, et vérifier qu'on retrouve environ 55 %.
- (c) Les trois valeurs propres de l'AFC valent $\lambda_1 = 0,2267, \lambda_2 = 0,1030, \lambda_3 = 0,0384$. Vérifier que leur somme redonne bien Φ^2 , et que leur nombre (3) correspond bien à $\min(5, 4) - 1$, le rang maximal pour ce tableau 5×4 .

3 Applications en sciences économiques

Exercice 5 — Regrouper des catégories sans biaiser l'analyse

Une enseigne de distribution hésite à distinguer, dans son étude, les canaux « web mobile » et « web ordinateur », ou à les regrouper en un seul « web ». Elle observe que, pour chacune des catégories de clients de son fichier, la répartition entre « web mobile » et « web ordinateur » est quasiment identique (environ 60 %–40 % partout).

- (a) D'après la propriété d'équivalence distributionnelle, le choix de regrouper ou non ces deux canaux changera-t-il les distances du khi-deux entre catégories de clients ?
- (b) Si, au contraire, la répartition 60 %–40 % variait fortement d'une catégorie de clients à l'autre, ce résultat resterait-il valable ?
- (c) En quoi cette propriété rassure-t-elle un analyste qui doit choisir, de façon en partie arbitraire, le niveau de détail de son découpage en modalités ?

Exercice 6 — Décomposer une inertie de satisfaction par région

Une chaîne croise la région (4 modalités) et le niveau de satisfaction déclaré (3 modalités) de 600 clients, avec $\chi^2 = 54,0$. La région Nord, qui pèse 0,40 de l'effectif, porte 0,12 de l'inertie totale ; la région Sud, qui pèse 0,15, porte 0,38 de l'inertie totale.

- (a) Calculer l'inertie totale Φ^2 de ce tableau.
- (b) Calculer le rapport part d'inertie / poids pour chacune des deux régions.
- (c) La direction commerciale s'étonne que la région Sud, pourtant peu peuplée, « pèse autant » dans les résultats de l'étude. Expliquer, à partir de la distinction entre poids et inertie, pourquoi ce n'est pas une anomalie mais un résultat attendu de la méthode.