

Analyse des données avancée

Chapitre 10 : L'analyse des correspondances multiples

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer l'inertie totale artificielle d'une ACM

Un questionnaire comporte $p = 4$ variables qualitatives, de 3, 4, 2 et 5 modalités respectivement.

- (a) Calculer K , le nombre total de colonnes du tableau disjonctif complet.
- (b) Calculer l'inertie totale $I_{\text{tot}} = K/p - 1$.
- (c) Un collègue découpe la variable à 5 modalités en 8 modalités plus fines, sans changer les données recueillies. Que devient I_{tot} ? Cela signifie-t-il que le questionnaire est devenu plus informatif?

Exercice 2 — Appliquer la règle de Benzécri

Une ACM porte sur $p = 6$ variables qualitatives. Le spectre des valeurs propres est 0,35; 0,25; 0,18; 0,15; 0,09; 0,05.

- (a) Calculer le seuil de Benzécri $1/p$.
- (b) Combien d'axes dépassent ce seuil?
- (c) Le troisième axe ($\lambda_3 = 0,18$) est proche du seuil. Que recommande le cours pour interpréter un axe, plutôt que de se fier uniquement à son pourcentage d'inertie?

Exercice 3 — Reconnaître une modalité qui ne dit rien

Sur un plan d'ACM, une modalité « Région Centre » a pour coordonnées $F_1 = 0,018$, $F_2 = -0,022$, et une contribution arrondie à 0,0 % sur les deux premiers axes.

- (a) Que signifie, en termes de profil, le fait que cette modalité soit « collée à l'origine »?
- (b) Peut-on en conclure que la région Centre n'a *aucune* caractéristique propre, ou seulement qu'elle n'en a aucune *par rapport aux variables actives de cette ACM*?
- (c) Quelle décision commerciale serait imprudente à prendre à partir de cette seule modalité?

2 Exercices cumulatifs (introduction au chapitre 10)

Exercice 4 — Vérifier l'ACM des cinq variables du fichier client

On reprend l'ACM du cours sur les cinq variables du fichier de 300 clients : CSP (5 modalités), fréquence (3), carte (2), motif (4), sexe (2), soit $K = 16$ colonnes pour $p = 5$ variables.

- (a) Calculer $I_{\text{tot}} = K/p - 1$, et vérifier qu'on retrouve 2,20.
- (b) Calculer le seuil de Benzécri $1/p$, et vérifier qu'on retrouve 0,20. Le cours retient cinq axes de valeurs propres 0,330, 0,296, 0,268, 0,238, 0,205 : vérifier qu'ils dépassent tous ce seuil.
- (c) Sur l'axe 1, quatre modalités (*Rare* 20,6 %, *carte Non* 20,0 %, *carte Oui* 16,0 %, *Hebdomadaire* 15,2 %) sont les plus contributives. Calculer leur somme, et vérifier qu'on retrouve 71,8 %.

3 Applications en sciences économiques

Exercice 5 — Comparer deux études aux pourcentages d'inertie différents

Une agence d'études marketing compare deux enquêtes menées auprès de deux clientèles différentes. La première (questionnaire court, peu de modalités) affiche un premier axe d'ACM à 32 % d'inertie. La seconde (questionnaire long, beaucoup de modalités) affiche un premier axe à 9 % seulement.

- (a) Peut-on en conclure que le premier axe de la première étude est « plus solide » ou « plus informatif » que celui de la seconde?

- (b) Quelle formule du cours explique pourquoi ces deux pourcentages ne sont pas comparables tels quels ?
- (c) Quel indicateur faudrait-il regarder à la place des pourcentages bruts pour juger de la qualité d'un axe d'ACM ?

Exercice 6 — Une variable qui ne structure rien, et ses conséquences pratiques

Une chaîne de magasins envisage de construire toute sa stratégie de communication autour d'une segmentation par sexe de sa clientèle. Une ACM menée sur cinq variables comportementales (fréquence, fidélité, motif, panier moyen, canal) montre que la modalité « Homme » et la modalité « Femme » sont toutes deux collées à l'origine du plan, avec des contributions nulles sur tous les axes retenus.

- (a) Que dit ce résultat sur la pertinence du sexe pour expliquer le comportement d'achat de cette clientèle, sur ces données ?
- (b) Formuler une recommandation à la direction marketing concernant le projet de segmentation par sexe.
- (c) Quelles variables faudrait-il regarder en priorité pour bâtir une segmentation, d'après la lecture des contributions du cours ?


1 Exercices du chapitre

Correction — Exercice 1

(a) $K = 3 + 4 + 2 + 5 = 14$.

(b) $I_{\text{tot}} = \frac{14}{4} - 1 = 3,5 - 1 = 2,5$.


(c) En remplaçant la variable à 5 modalités par 8 modalités, K devient $3 + 4 + 2 + 8 = 17$, donc $I_{\text{tot}} = 17/4 - 1 = 3,25$. L'inertie totale a **augmenté**, alors qu'aucune information nouvelle n'a été recueillie – seul le découpage a changé. Cela ne signifie donc **pas** que le questionnaire est devenu plus informatif : I_{tot} est une quantité structurelle, pas une mesure de contenu.



Correction — Exercice 2

(a) $1/p = 1/6 \approx 0,1667$.

(b) $0,35 > 0,1667$; $0,25 > 0,1667$; $0,18 > 0,1667$; $0,15 < 0,1667$; $0,09 < 0,1667$; $0,05 < 0,1667$. **Trois** axes dépassent le seuil.



(c) Le cours recommande de ne jamais interpréter un axe d'ACM par son seul pourcentage d'inertie (structurellement bas et gonflable par le découpage des modalités), mais par ses **contributions** : quelles modalités le construisent, et à quelle hauteur. C'est la liste des contributions dominantes, pas le pourcentage affiché, qui donne le sens de l'axe.

Correction — Exercice 3

(a) Une modalité collée à l'origine a un profil **proche du profil moyen** sur l'ensemble des variables actives : elle ne se distingue ni dans un sens ni dans l'autre sur les axes retenus.

(b) Seulement la seconde : cette modalité n'a aucune spécificité **par rapport aux variables actives incluses dans cette ACM précise**. Une autre ACM, construite sur d'autres variables (par exemple des habitudes culturelles régionales non retenues ici), pourrait très bien révéler une spécificité de la région Centre que celle-ci ne capture pas.


(c) Il serait imprudent de conclure que la région Centre est « homogène » ou « sans intérêt commercial » en général : l'ACM ne dit rien au-delà des variables qu'elle a effectivement croisées. Bâtir une politique différenciée – ou, à l'inverse, renoncer à toute action ciblée sur cette région – sur la seule base de cette absence de contribution serait une généralisation abusive.

2 Exercices cumulatifs (introduction au chapitre 10)

Correction — Exercice 4

(a) $I_{\text{tot}} = \frac{16}{5} - 1 = 3,20 - 1 = 2,20$. Vérifié.

(b) $1/p = 1/5 = 0,20$. Vérifié. Les cinq valeurs propres 0,330 ; 0,296 ; 0,268 ; 0,238 ; 0,205 sont toutes strictement supérieures à 0,20 (la plus proche, 0,205, le dépasse tout de même) : les cinq axes passent le test de Benzécri.



(c) $20,6 + 20,0 + 16,0 + 15,2 = 71,8 \%$. Vérifié : quatre modalités, issues de seulement deux variables (fréquence et carte), construisent près des trois quarts du premier axe – confirmant que celui-ci est bien un « axe de la fidélité » plutôt qu’un axe résumant l’ensemble des cinq variables.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Non, on ne peut rien en conclure directement : les deux pourcentages ne sont pas comparables entre eux, car ils dépendent avant tout du nombre de modalités de chaque questionnaire, pas seulement de la force du lien qu’ils révèlent.

(b) $I_{\text{tot}} = K/p - 1$: plus un questionnaire comporte de modalités (plus K est grand par rapport à p), plus l’inertie totale à répartir entre les axes est mécaniquement élevée, et donc plus chaque pourcentage d’axe est structurellement écrasé – même si le lien sous-jacent entre variables est tout aussi fort. Le questionnaire long « dilue » artificiellement ses pourcentages.

(c) Il faut regarder les **contributions** des modalités à chaque axe (et éventuellement appliquer le seuil de Benzécri $1/p$ pour savoir combien d’axes retenir), plutôt que le pourcentage d’inertie affiché en tête de sortie logicielle.

Correction — Exercice 6

(a) Le sexe ne structure, sur ces données, **aucune** des cinq variables comportementales retenues (fréquence, fidélité, motif, panier moyen, canal) : hommes et femmes ont, en moyenne, le même profil de comportement d’achat vis-à-vis de ces cinq dimensions.

(b) La direction marketing devrait **renoncer** à fonder sa stratégie de communication sur une segmentation par sexe : les données ne fournissent aucun appui empirique à une différenciation homme/femme du discours commercial. Une telle segmentation, si elle était mise en œuvre, reposerait sur une intuition non vérifiée plutôt que sur une régularité observée.

(c) Il faut se tourner vers les variables qui **contribuent effectivement** aux axes retenus – ici, d’après la structure du plan (analogue à celle du cours), des variables comme la fréquence de visite et la possession d’une carte de fidélité pour l’axe 1, et le motif de fréquentation ou la CSP pour l’axe 2 : ce sont elles qui distinguent réellement des groupes de clients.