

Analyse des données avancée

Chapitre 15 : L'analyse factorielle discriminante

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Comparer deux axes candidats par le critère de l'AFD

Deux directions u_A et u_B sont candidates comme axe discriminant. Pour u_A : $u'_A B u_A = 12$ et $u'_A W u_A = 3$. Pour u_B : $u'_B B u_B = 15$ et $u'_B W u_B = 6$.

- Calculer le rapport $u' B u / u' W u$ pour chacune des deux directions.
- Laquelle sépare le mieux les groupes, au sens du critère de l'AFD?
- L'axe u_B a pourtant la plus grande dispersion *entre* les centres ($u'_B B u_B = 15 > 12$). Pourquoi ne suffit-il pas de maximiser seulement $u' B u$ pour choisir un bon axe discriminant?

Exercice 2 — Calculer un lambda de Wilks

Une AFD à trois groupes donne deux valeurs propres discriminantes : $\mu_1 = 0,64$ et $\mu_2 = 0,09$.

- Calculer le pourcentage de pouvoir séparateur porté par le premier axe.
- Calculer le lambda de Wilks $\Lambda = \prod_k \frac{1}{1 + \mu_k}$.
- Cette valeur de Λ indique-t-elle une séparation plutôt nette ou plutôt faible entre les groupes? Situer la réponse entre les deux bornes 0 (séparation parfaite) et 1 (aucune séparation).

Exercice 3 — Interpréter des corrélations avec l'axe discriminant

Sur un axe discriminant séparant des clients « satisfaits » et « insatisfaits », quatre variables ont pour corrélation avec l'axe : ancienneté $r = 0,85$, montant du dernier achat $r = 0,72$, âge $r = 0,15$, taille du foyer $r = 0,05$.

- Classer les quatre variables par pouvoir discriminant décroissant.
- Quelles variables composent principalement cet axe?
- Que peut-on affirmer sur le pouvoir de l'âge et de la taille du foyer à distinguer les deux groupes de clients, d'après ces corrélations?

2 Exercices cumulatifs (introduction au chapitre 15)

Exercice 4 — Vérifier le pouvoir séparateur et le lambda de Wilks officiels

On reprend l'AFD du cours, opposant les 112 clients rares, 87 mensuels et 101 hebdomadaires sur les huit notes de satisfaction : $\mu_1 = 1,0161$ et $\mu_2 = 0,0103$.

- Calculer le pourcentage de pouvoir séparateur porté par le premier axe, et vérifier qu'on retrouve 99,0 %.
- Calculer le lambda de Wilks Λ , et vérifier qu'on retrouve 0,4909.
- Avec $K = 3$ groupes et $p = 8$ notes, vérifier que le nombre maximal d'axes discriminants, $\min(K - 1, p)$, vaut bien 2 – cohérent avec les deux valeurs propres données.

3 Applications en sciences économiques

Exercice 5 — Utiliser l'AFD pour comprendre un churn client

Un opérateur télécom dispose de 10 indicateurs d'usage (appels, données, réclamations, etc.) pour des clients répartis en deux groupes connus : « résiliés dans les 6 mois » et « toujours clients ». Une AFD est menée pour comprendre ce qui distingue les deux groupes.

- (a) Avec $K = 2$ groupes, combien d'axes discriminants au maximum l'AFD pourra-t-elle produire, quel que soit p ?
- (b) L'axe obtenu a pour corrélations dominantes : nombre de réclamations non résolues ($r = 0,81$), durée moyenne d'attente au support ($r = 0,74$), consommation data ($r = 0,09$). Quelle conclusion opérationnelle l'opérateur peut-il en tirer ?
- (c) Pourquoi cette méthode est-elle mieux adaptée à cette question (« qu'est-ce qui sépare les deux groupes connus ») qu'une CAH ou des k -means ?

Exercice 6 — Score de crédit et prudence sur les tests statistiques

Une banque mène une AFD pour distinguer, sur 15 ratios financiers, les entreprises « en défaut dans les deux ans » des entreprises « saines ». Elle obtient $\Lambda = 0,38$ et souhaiterait présenter un test statistique formel de significativité de cette séparation à son comité des risques.


- (a) Sous quelle hypothèse le lambda de Wilks peut-il, en théorie, se transformer en une statistique de test de Fisher ?
- (b) Pourquoi le cours reste-t-il prudent quant à l'usage de ce test sur des données de notation financière (ratios comptables, souvent asymétriques) ?
- (c) Sans mener ce test formel, comment la seule valeur $\Lambda = 0,38$ peut-elle déjà être présentée, de façon honnête, au comité des risques ?

1 Exercices du chapitre

Correction — Exercice 1

(a) Pour u_A : $12/3 = 4$. Pour u_B : $15/6 = 2,5$.

(b) L'axe u_A sépare mieux les groupes : son rapport $u'Bu/u'Wu$ (4) est supérieur à celui de u_B (2,5), c'est ce rapport, et non $u'Bu$ seul, que l'AFD maximise.



(c) Parce qu'une grande dispersion entre les centres ($u'Bu$ élevé) ne garantit rien si les groupes eux-mêmes sont très étalés autour de leur centre ($u'Wu$ élevé aussi) : les nuages peuvent alors se **recouvrir** malgré des centres éloignés. Seul le rapport des deux quantités mesure la séparation *effective* des groupes – c'est exactement le cas ici, où u_B a le plus grand $u'Bu$ mais aussi le plus grand $u'Wu$, ce qui dégrade son pouvoir séparateur net.

Correction — Exercice 2

(a) $\frac{0,64}{0,64 + 0,09} = \frac{0,64}{0,73} \approx 0,8767 = 87,7\%$.

(b) $\Lambda = \frac{1}{1 + 0,64} \times \frac{1}{1 + 0,09} = \frac{1}{1,64} \times \frac{1}{1,09} \approx 0,6098 \times 0,9174 \approx 0,5594$.

(c) $\Lambda \approx 0,56$ se situe à peu près à mi-chemin entre 0 (séparation parfaite) et 1 (aucune séparation) : la séparation entre les groupes est **modérée**, ni très nette ni inexistante – nettement moins tranchée que celle du cours ($\Lambda = 0,49$, plus proche de 0).

Correction — Exercice 3

(a) Par pouvoir discriminant décroissant : ancienneté (0,85), montant du dernier achat (0,72), âge (0,15), taille du foyer (0,05).

(b) L'axe est principalement composé de l'**ancienneté** et du **montant du dernier achat**, les deux seules variables dont la corrélation dépasse 0,5.


(c) L'âge ($r = 0,15$) et surtout la taille du foyer ($r = 0,05$) n'ont **quasiment aucun** pouvoir à distinguer les clients satisfaits des insatisfaits sur cet axe : leurs corrélations sont trop proches de 0 pour être interprétées comme discriminantes.

2 Exercices cumulatifs (introduction au chapitre 15)

Correction — Exercice 4

(a) $\frac{1,0161}{1,0161 + 0,0103} = \frac{1,0161}{1,0264} \approx 0,9900 = 99,0\%$. Vérifié.

(b) $\Lambda = \frac{1}{1 + 1,0161} \times \frac{1}{1 + 0,0103} = \frac{1}{2,0161} \times \frac{1}{1,0103} \approx 0,4960 \times 0,9898 \approx 0,4909$. Vérifié.



(c) $\min(K - 1, p) = \min(3 - 1, 8) = \min(2, 8) = 2$. Vérifié : c'est exactement le nombre de valeurs propres discriminantes fournies par le cours.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Avec $K = 2$ groupes, le nombre maximal d'axes discriminants est $\min(K - 1, p) = \min(1, p) = 1$, quel que soit le nombre de variables p : opposer deux groupes ne peut jamais produire plus d'un axe discriminant.
- (b) La qualité du service après-vente (réclamations non résolues, temps d'attente au support) sépare bien davantage les clients résiliés des clients fidèles que leur simple niveau de consommation data. L'opérateur devrait donc concentrer ses efforts de rétention sur la **qualité du support client** plutôt que sur des incitations liées à la consommation.
- (c) Parce que l'appartenance aux deux groupes (résilié ou non) est ici **connue à l'avance** : la question n'est pas de découvrir des groupes dans les données (rôle de la CAH ou des k -means), mais de comprendre, parmi des variables mesurées, lesquelles **séparent le mieux** des groupes déjà définis – exactement le problème que l'AFD est construite pour résoudre.

Correction — Exercice 6

- (a) Sous l'hypothèse de **normalité multivariée** des variables explicatives à l'intérieur de chaque groupe : c'est cette hypothèse qui permet de transformer Λ en une statistique de test de Fisher.
- (b) Les ratios financiers comptables sont typiquement **asymétriques** (bornés, avec des valeurs extrêmes fréquentes chez les entreprises en difficulté), ce qui rend l'hypothèse de normalité multivariée **douteuse** – exactement la réserve émise par le cours à propos des notes de satisfaction, discrètes elles aussi. Un test formel construit sur une hypothèse non vérifiée perdrait sa validité statistique.
- (c) La seule valeur $\Lambda = 0,38$, plus proche de 0 (séparation parfaite) que de 1 (aucune séparation), peut être présentée honnêtement comme un indice **descriptif** d'une séparation nette entre entreprises saines et en défaut sur ces 15 ratios – sans prétendre à une significativité statistique testée formellement, mais en la comparant, par exemple, à des valeurs de Λ obtenues sur d'autres portefeuilles ou d'autres périodes pour en juger la robustesse.