

Analyse des données avancée

Chapitre 2 : L'inertie, formalisée

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer l'inertie par la trace, normée ou non

Trois variables centrées ont pour matrice de variance-covariance :

$$\mathbf{V} = \begin{pmatrix} 4 & 2 & -1 \\ 2 & 9 & 0,5 \\ -1 & 0,5 & 1 \end{pmatrix}$$

- (a) Calculer l'inertie non normée $I = \text{trace}(\mathbf{V}\mathbf{I}) = \text{trace}(\mathbf{V})$.
- (b) Sans calculer $\mathbf{V}\mathbf{D}_{1/s^2}$ terme à terme, donner directement l'inertie **normée** de ce nuage, en justifiant par le résultat du cours.
- (c) Pourquoi les covariances hors diagonale $(2, -1, 0,5)$ n'interviennent-elles dans **aucun** des deux calculs précédents ?

Exercice 2 — Décomposer l'inertie sur un sous-espace

Un nuage a une inertie totale $I = 14$. Sa projection sur un sous-espace E conserve une inertie $I_E = 11,2$.

- (a) Calculer l'inertie perdue $I_{E^\perp}$.
- (b) Calculer le pourcentage d'inertie conservée par cette projection.
- (c) Expliquer pourquoi chercher le sous-espace E qui **maximise** I_E revient exactement à chercher celui qui **minimise** $I_{E^\perp}$, sans qu'il soit besoin de résoudre deux problèmes différents.

Exercice 3 — Un nuage d'inertie nulle

Un service qualité soumet le même questionnaire de satisfaction à 50 clients, mais une erreur d'impression fait que tous les clients reçoivent un questionnaire pré-rempli identique, qu'ils renvoient sans le modifier.

- (a) Que vaut l'inertie de ce nuage de 50 réponses ? Justifier à partir de la définition de l'inertie comme moyenne des carrés des distances au centre de gravité.
- (b) Une ACP a-t-elle un quelconque intérêt sur ce fichier ? Pourquoi ?
- (c) Formuler, en une phrase, le lien entre « inertie nulle » et « rien à analyser » évoqué par le cours.

2 Exercices cumulatifs (introduction au chapitre 2)

Exercice 4 — L'inertie du fil rouge, par tous les chemins

On reprend le fil rouge de l'introduction : $\mathbf{X}'\mathbf{X} = \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix}$, de valeurs propres 16 et 4 (introduction), et $p_i = 1/4$ pour les 4 individus.

- (a) Calculer $\mathbf{V} = \frac{1}{4}\mathbf{X}'\mathbf{X}$, puis l'inertie non normée $I = \text{trace}(\mathbf{V})$.
- (b) Vérifier ce résultat par la méthode des distances : calculer $d^2(i, \mathbf{g})$ pour chacun des 4 individus ($\mathbf{g} = (0,0)$), puis $I = \frac{1}{4} \sum_i d^2(i, \mathbf{g})$.
- (c) Les valeurs propres de $\mathbf{X}'\mathbf{X}$ valent 16 et 4 (introduction). Sachant que $\mathbf{V} = \frac{1}{4}\mathbf{X}'\mathbf{X}$, en déduire les valeurs propres de $\mathbf{V}$, puis vérifier que leur somme redonne bien l'inertie I calculée en (a) – quelle propriété générale de la trace d'une matrice cela illustre-t-il ?

3 Applications en sciences économiques

Exercice 5 — Pourquoi l'inertie brute d'un bilan financier ne veut rien dire

On reprend les trois ratios financiers du chapitre 1 (chiffre d'affaires, taux de marge, rotation des stocks), de variances respectives $s_{CA}^2 = 2\,500$ (en millions de dh au carré), $s_{marge}^2 = 9$, $s_{rotation}^2 = 196$.

- (a) Calculer l'inertie non normée $I = \text{trace}(\mathbf{V})$ de ce nuage à trois variables.
- (b) Quel pourcentage de cette inertie brute est porté par le seul chiffre d'affaires ?
- (c) Calculer l'inertie normée de ce même nuage. Pourquoi ce second nombre est-il, contrairement au premier, immédiatement interprétable sans connaître le détail des trois variables ?

Exercice 6 — Combien un facteur de risque explique-t-il ?

Un gérant de portefeuille calcule l'inertie totale d'un nuage de 10 actifs décrits par leurs rendements sur plusieurs périodes : $I = 10$ (données réduites). Le premier facteur de risque identifié conserve une inertie $I_E = 7,4$.

- (a) Calculer l'inertie perdue par ce premier facteur.
- (b) Calculer le pourcentage de risque « expliqué » par ce facteur.
- (c) Le gérant écrit dans son rapport : « ce facteur explique 74 % du risque total, donc les 26 % restants sont un risque non diversifiable et incompressible ». Cette dernière affirmation découle-t-elle de la seule décomposition de l'inertie ? Que faudrait-il vérifier avant de l'écrire ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $I = \text{trace}(\mathbf{V}) = 4 + 9 + 1 = 14$.
- (b) L'inertie normée d'un nuage à p variables vaut toujours exactement p (théorème du cours, $I = \text{trace}(\mathbf{R}) = p$) : ici $p = 3$, donc $I_{\text{normée}} = 3$, sans aucun calcul supplémentaire.
- (c) La trace d'une matrice ne dépend que de ses termes **diagonaux** – les covariances hors diagonale n'entrent jamais dans son calcul, quelle que soit la métrique $\mathbf{I}$ ou $\mathbf{D}_{1/s^2}$ (elle aussi diagonale). L'inertie totale ne « voit » donc que les variances de chaque variable prise isolément, jamais leurs corrélations : ce sont les corrélations qui détermineront, en revanche, comment cette même inertie totale se **répartit** entre les axes factoriels (chapitres suivants).

Correction — Exercice 2

- (a) $I_{E^\perp} = 14 - 11,2 = 2,8$.
- (b) $\frac{11,2}{14} = 80\%$.
- (c) L'inertie totale $I = 14$ est une propriété du nuage, **fixe**, indépendante du sous-espace E choisi. Puisque $I = I_E + I_{E^\perp}$ est une somme constante, augmenter I_E ne peut se faire qu'en diminuant $I_{E^\perp}$ d'exactly la même quantité, et réciproquement : les deux problèmes – maximiser ce qu'on garde, minimiser ce qu'on perd – ont donc nécessairement la **même** solution E , ce n'est pas deux optimisations à mener séparément.


Correction — Exercice 3

- (a) L'inertie de ce nuage est **nulle** : tous les 50 clients ayant renvoyé des réponses identiques, chacun coïncide exactement avec le centre de gravité (qui est aussi cette réponse commune) – $d^2(i, \mathbf{g}) = 0$ pour chaque client i , donc $I = \frac{1}{50} \sum_i d^2(i, \mathbf{g}) = 0$.
- (b) Non, une ACP n'a aucun intérêt ici : il n'existe aucune dispersion entre les individus à décomposer sur des axes. Tous les points du nuage sont confondus en un seul point.
- (c) Un nuage d'inertie nulle est un nuage où « tout le monde est identique » (cours) – et comme l'analyse des données cherche à décrire la façon dont les individus *diffèrent*, l'absence totale de différence signifie qu'il n'y a, littéralement, rien à analyser.

2 Exercices cumulatifs (introduction au chapitre 2)

Correction — Exercice 4

- (a) $\mathbf{V} = \frac{1}{4} \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix} = \begin{pmatrix} 2,5 & 1,5 \\ 1,5 & 2,5 \end{pmatrix}$. $I = \text{trace}(\mathbf{V}) = 2,5 + 2,5 = 5$.
- (b) $d^2(1, \mathbf{g}) = (-2)^2 + (-2)^2 = 8$. $d^2(2, \mathbf{g}) = (-1)^2 + 1^2 = 2$. $d^2(3, \mathbf{g}) = 1^2 + (-1)^2 = 2$. $d^2(4, \mathbf{g}) = 2^2 + 2^2 = 8$. $I = \frac{1}{4}(8 + 2 + 2 + 8) = \frac{20}{4} = 5$. On retrouve exactement le même résultat qu'en (a).
- (c) $\mathbf{V} = \frac{1}{4}\mathbf{X}'\mathbf{X}$, donc les valeurs propres de $\mathbf{V}$ sont celles de $\mathbf{X}'\mathbf{X}$ divisées par 4 : $\frac{16}{4} = 4$ et $\frac{4}{4} = 1$. Leur somme, $4 + 1 = 5$, redonne exactement $I = 5$. Cela illustre la propriété générale selon laquelle la **trace** d'une matrice diagonalisable est toujours égale à la **somme de ses valeurs propres** – c'est cette même propriété, appliquée à $\mathbf{VM}$, qui permettra plus tard de lire l'inertie totale directement sur la liste des valeurs propres d'une ACP.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $I = 2\,500 + 9 + 196 = 2\,705$.

(b) $\frac{2\,500}{2\,705} \approx 92,4\%$.

(c) L'inertie normée vaut toujours $p = 3$, quelles que soient les variances de départ. Ce second nombre est immédiatement interprétable car il ne dépend ni des unités choisies pour chaque variable, ni de leur dispersion respective : un pourcentage calculé sur cette base ($4,54/3$ par exemple) garde le même sens d'un fichier à l'autre, alors que $92,4\%$ d'une inertie brute de $2\,705$ ne dit rien tant qu'on ne connaît pas le détail de chaque variance – un simple changement d'unité du chiffre d'affaires (milliers plutôt que millions) changerait radicalement ce pourcentage brut, sans rien changer au pourcentage normé.

Correction — Exercice 6

(a) $I_{E^\perp} = 10 - 7,4 = 2,6$.

(b) $\frac{7,4}{10} = 74\%$.

(c) Non : la décomposition de l'inertie (74% conservés, 26% perdus par ce premier facteur) est un résultat purement **descriptif** sur ce nuage de rendements – elle ne dit rien, par elle-même, sur la nature **économique** de ce qui reste non expliqué. Avant d'affirmer que les 26% restants constituent un risque « non diversifiable et incompressible », il faudrait vérifier, par d'autres moyens (par exemple en examinant si un second facteur en capte une partie substantielle, ou en confrontant ce résultat à une théorie financière du risque), que cette inertie résiduelle correspond réellement à un risque systématique et non simplement à des facteurs supplémentaires non encore identifiés dans cette analyse exploratoire.