

Analyse des données avancée

Chapitre 12 : La classification ascendante hiérarchique

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer un coût de fusion de Ward

Deux classes ont pour effectifs $n_a = 5$ et $n_b = 3$, et leurs barycentres sont distants de $d^2(G_a, G_b) = 4$.

- (a) Calculer le coût de fusion de Ward $\Delta(a, b) = \frac{n_a n_b}{n_a + n_b} d^2(G_a, G_b)$.
- (b) Si $d^2(G_a, G_b)$ restait identique mais que n_b passait à 15, le coût de fusion augmenterait-il ou diminuerait-il? Vérifier par le calcul.
- (c) Cette évolution illustre quel effet du critère de Ward, décrit dans le cours?

Exercice 2 — Décomposer l'inertie d'une partition

Une partition en trois classes a une inertie totale $I_{\text{totale}} = 10$ et une inertie intraclasse $I_{\text{intraclasse}} = 3$.

- (a) Calculer l'inertie interclasse $I_{\text{interclasse}}$.
- (b) Calculer le pourcentage d'inertie interclasse par rapport à l'inertie totale.
- (c) Une seconde partition, en cinq classes, obtient 85 % d'inertie interclasse. Est-elle nécessairement « meilleure » que la première, sachant qu'elle compte davantage de classes?

Exercice 3 — Mesurer le coût de calcul d'une CAH

Une entreprise veut appliquer une CAH classique sur son fichier de $n = 50\,000$ clients.

- (a) Calculer le nombre de distances $n(n-1)/2$ que la matrice des distances devrait contenir.
- (b) Ce nombre est-il compatible avec un calcul et un stockage courants? Que se passerait-il avec $n = 1\,000\,000$?
- (c) Quelle est la seconde limite de la CAH, indépendante de la taille du fichier, liée à l'irréversibilité des fusions?

2 Exercices cumulatifs (introduction au chapitre 12)

Exercice 4 — Calculer un coût de fusion sur la partition officielle

On reprend la partition en quatre classes du cours, obtenue sur les 300 clients : Classe 1 ($n_1 = 61$, $F_1 = 2,50$, $F_2 = -0,45$), Classe 2 ($n_2 = 82$, $F_1 = 1,06$, $F_2 = 1,31$).

- (a) Calculer $d^2(G_1, G_2)$, la distance au carré entre les barycentres des classes 1 et 2.
- (b) En déduire le coût de fusion de Ward $\Delta(1, 2)$ si l'on devait réunir ces deux classes.
- (c) Sachant que l'inertie interclasse de la partition à quatre classes vaut 74,93 % de l'inertie totale, et que le cours signale un saut d'inertie de 3,62 % à 9,74 % entre quatre et trois classes, ce saut confirme-t-il qu'il est raisonnable de s'arrêter à quatre classes plutôt que de continuer à fusionner?

3 Applications en sciences économiques

Exercice 5 — Décider où couper un dendrogramme commercial

Une enseigne réalise une CAH sur ses clients et observe le tableau du pourcentage d'inertie interclasse en fonction du nombre de classes retenu : 6 classes $\rightarrow$ 91 %, 5 classes $\rightarrow$ 88 %, 4 classes $\rightarrow$ 84 %, 3 classes $\rightarrow$ 60 %, 2 classes $\rightarrow$ 42 %.

- (a) Repérer, dans cette série, l'endroit où se produit la chute la plus marquée quand on réduit le nombre de classes.

- (b) Combien de classes recommanderiez-vous de retenir ? Justifier.
- (c) Un directeur commercial souhaite malgré tout 6 segments « pour des raisons opérationnelles » (une équipe par segment). Quel inconvénient statistique cette décision ferait-elle courir ?

Exercice 6 — Gérer une fusion irréversible dans un audit de portefeuille

Une société de gestion classe 400 fonds d'investissement par CAH. À l'étape 50, deux fonds obligataires très similaires sont fusionnés dans la même classe. À l'étape 380, il apparaît que l'un des deux fonds, entre-temps, aurait davantage sa place dans une classe de fonds mixtes constituée plus tard.


- (a) Pourquoi la CAH ne peut-elle pas corriger d'elle-même cette erreur, une fois l'étape 50 passée ?
- (b) Quelle méthode, présentée par le cours comme complémentaire à la CAH, permettrait de corriger ce type d'erreur après coup ?
- (c) Pourquoi est-il recommandé d'enchaîner les deux méthodes plutôt que de choisir l'une ou l'autre ?

1 Exercices du chapitre

Correction — Exercice 1

(a) $\Delta(a, b) = \frac{5 \times 3}{5 + 3} \times 4 = \frac{15}{8} \times 4 = 7,5.$

(b) Avec $n_b = 15$: $\Delta(a, b) = \frac{5 \times 15}{5 + 15} \times 4 = \frac{75}{20} \times 4 = 15.$ Le coût **augmente** ($7,5 \rightarrow 15$), bien que la distance entre barycentres soit inchangée.



(c) Cette évolution illustre le fait que le critère de Ward **pénalise la fusion de classes déjà volumineuses** : à distance de barycentres égale, fusionner avec une classe plus grosse coûte plus cher en inertie interclasse perdue. C'est ce mécanisme qui pousse Ward à produire des classes de tailles comparables.

Correction — Exercice 2

(a) $I_{\text{interclasse}} = I_{\text{totale}} - I_{\text{intraclasse}} = 10 - 3 = 7.$

(b) $7/10 = 0,70 = 70\%.$

(c) Pas nécessairement : un pourcentage d'inertie interclasse plus élevé s'obtient presque mécaniquement en **augmentant** le nombre de classes (à la limite, avec n classes – une par individu – l'inertie interclasse vaut 100 %). Comparer 70 % à 3 classes et 85 % à 5 classes n'est donc pas équitable : il faut plutôt regarder si le **gain** d'inertie interclasse obtenu en passant de 3 à 5 classes est important (un grand saut) ou marginal, et si les classes supplémentaires s'interprètent.

Correction — Exercice 3

(a) $n(n-1)/2 = 50\,000 \times 49\,999/2 = 1\,249\,975\,000$, soit environ 1,25 milliard de distances.

(b) Ce nombre est déjà très lourd à calculer et à stocker en mémoire pour un usage courant (plus d'un milliard de valeurs). Avec $n = 1\,000\,000$, le nombre de distances serait d'environ 5×10^{11} (cinq cents milliards) : totalement **impraticable** avec une CAH classique.


(c) La seconde limite est l'**irréversibilité des fusions** : une fois deux individus réunis dans la même classe à une étape donnée, ils y restent jusqu'à la fin de l'algorithme, même si une fusion ultérieure révèle que ce regroupement initial n'était pas optimal.

2 Exercices cumulatifs (introduction au chapitre 12)

Correction — Exercice 4

(a) $d^2(G_1, G_2) = (2,50 - 1,06)^2 + (-0,45 - 1,31)^2 = 1,44^2 + (-1,76)^2 = 2,0736 + 3,0976 = 5,1712.$

(b) $\Delta(1, 2) = \frac{61 \times 82}{61 + 82} \times 5,1712 = \frac{5002}{143} \times 5,1712 \approx 34,98 \times 5,1712 \approx 180,9.$




(c) Oui. Un saut de 3,62 % à 9,74 % (multiplié par plus de 2,5) entre les paliers à quatre et trois classes signifie que passer de quatre à trois classes ferait perdre nettement plus d'inertie interclasse que les fusions précédentes – c'est le signal classique du « grand saut » qui indique où arrêter les fusions. Combiné au fait que les quatre classes obtenues s'interprètent sans difficulté et conservent 74,93 % de l'inertie en interclasse, ce sont bien trois signaux concordants en faveur de quatre classes.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Les écarts successifs sont $91 - 88 = 3$, $88 - 84 = 4$, $84 - 60 = 24$, $60 - 42 = 18$. La chute la plus marquée se produit entre **4 et 3 classes** (–24 points).



(b) Il faut retenir **quatre classes** : c'est juste avant le grand saut, là où l'on conserve encore 84 % d'inertie interclasse pour un coût de fusion encore modéré ; passer à trois classes ferait perdre 24 points d'inertie interclasse d'un coup.

(c) Imposer 6 classes pour des raisons purement organisationnelles risque de produire des segments **artificiellement scindés**, sans réelle différence statistique entre eux (91 % contre 84 % à quatre classes, un gain marginal de seulement 7 points pour deux classes en plus) – des équipes travailleraient alors sur des segments qui ne se distinguent pas réellement dans les données.

Correction — Exercice 6

(a) Parce que les fusions de la CAH sont **définitives** : une fois deux individus réunis à l'étape 50, l'algorithme ne revient jamais en arrière pour les séparer, quelle que soit l'information révélée par les étapes suivantes.

(b) La **consolidation**, via un algorithme de partitionnement direct (comme les k -means, présenté au chapitre suivant), qui repart de la partition obtenue par CAH et peut réaffecter individuellement chaque élément à la classe la plus proche, y compris en corrigeant une erreur commise tôt dans le processus hiérarchique.

(c) Parce que les deux méthodes sont **complémentaires** : la CAH fournit une hiérarchie complète et aide à décider du nombre de classes pertinent (via le grand saut d'inertie), tandis que la consolidation

corrige le défaut d'irréversibilité de la CAH en affinant, individu par individu, la partition finale une fois le nombre de classes fixé. Utiliser l'une sans l'autre revient à renoncer soit au diagnostic du nombre de classes (consolidation seule), soit à la correction des erreurs de fusion précoces (CAH seule).