

Chapitre 12

La classification ascendante hiérarchique

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Exercice 1 — Calculer un coût de fusion de Ward

Deux classes ont pour effectifs $n_a = 5$ et $n_b = 3$, et leurs barycentres sont distants de $d^2(G_a, G_b) = 4$.

- (a) Calculer le coût de fusion de Ward $\Delta(a, b) = \frac{n_a n_b}{n_a + n_b} d^2(G_a, G_b)$.
- (b) Si $d^2(G_a, G_b)$ restait identique mais que n_b passait à 15, le coût de fusion augmenterait-il ou diminuerait-il ? Vérifier par le calcul.
- (c) Cette évolution illustre quel effet du critère de Ward, décrit dans le cours ?

Exercice 2 — Décomposer l'inertie d'une partition

Une partition en trois classes a une inertie totale $I_{\text{totale}} = 10$ et une inertie intraclasse $I_{\text{intraclasse}} = 3$.

- (a) Calculer l'inertie interclasse $I_{\text{interclasse}}$.
- (b) Calculer le pourcentage d'inertie interclasse par rapport à l'inertie totale.
- (c) Une seconde partition, en cinq classes, obtient 85 % d'inertie interclasse. Est-elle nécessairement « meilleure » que la première, sachant qu'elle compte davantage de classes ?

Exercice 3 — Mesurer le coût de calcul d'une CAH

Une entreprise veut appliquer une CAH classique sur son fichier de $n = 50\,000$ clients.

- (a) Calculer le nombre de distances $n(n-1)/2$ que la matrice des distances devrait contenir.
- (b) Ce nombre est-il compatible avec un calcul et un stockage courants ? Que se passerait-il avec $n = 1\,000\,000$?
- (c) Quelle est la seconde limite de la CAH, indépendante de la taille du fichier, liée à l'irréversibilité des fusions ?

2 Exercices cumulatifs (introduction au chapitre 12)

Exercice 4 — Calculer un coût de fusion sur la partition officielle

On reprend la partition en quatre classes du cours, obtenue sur les 300 clients : Classe 1 ($n_1 = 61$, $F_1 = 2,50$, $F_2 = -0,45$), Classe 2 ($n_2 = 82$, $F_1 = 1,06$, $F_2 = 1,31$).

- (a) Calculer $d^2(G_1, G_2)$, la distance au carré entre les barycentres des classes 1 et 2.
- (b) En déduire le coût de fusion de Ward $\Delta(1, 2)$ si l'on devait réunir ces deux classes.
- (c) Sachant que l'inertie interclasse de la partition à quatre classes vaut 74,93 % de l'inertie totale, et que le cours signale un saut d'inertie de 3,62 % à 9,74 % entre quatre et trois classes, ce saut confirme-t-il qu'il est raisonnable de s'arrêter à quatre classes plutôt que de continuer à fusionner ?

3 Applications en sciences économiques

Exercice 5 — Décider où couper un dendrogramme commercial

Une enseigne réalise une CAH sur ses clients et observe le tableau du pourcentage d'inertie interclasse en fonction du nombre de classes retenu : 6 classes $\rightarrow$ 91 %, 5 classes $\rightarrow$ 88 %, 4 classes $\rightarrow$ 84 %, 3 classes $\rightarrow$ 60 %, 2 classes $\rightarrow$ 42 %.

- (a) Repérer, dans cette série, l'endroit où se produit la chute la plus marquée quand on réduit le nombre de classes.

- (b) Combien de classes recommanderiez-vous de retenir ? Justifier.
- (c) Un directeur commercial souhaite malgré tout 6 segments « pour des raisons opérationnelles » (une équipe par segment). Quel inconvénient statistique cette décision ferait-elle courir ?

Exercice 6 — Gérer une fusion irréversible dans un audit de portefeuille

Une société de gestion classe 400 fonds d'investissement par CAH. À l'étape 50, deux fonds obligataires très similaires sont fusionnés dans la même classe. À l'étape 380, il apparaît que l'un des deux fonds, entre-temps, aurait davantage sa place dans une classe de fonds mixtes constituée plus tard.

- (a) Pourquoi la CAH ne peut-elle pas corriger d'elle-même cette erreur, une fois l'étape 50 passée ?
- (b) Quelle méthode, présentée par le cours comme complémentaire à la CAH, permettrait de corriger ce type d'erreur après coup ?
- (c) Pourquoi est-il recommandé d'enchaîner les deux méthodes plutôt que de choisir l'une ou l'autre ?