

Chapitre 13

Les k -means et la consolidation

Corrigé

Jaouad Madkour


Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Correction — Exercice 1

(a) $d^2((1, 1), G_A) = (1 - 1)^2 + (1 - 2)^2 = 1$. $d^2((1, 3), G_A) = (1 - 1)^2 + (3 - 2)^2 = 1$. $d^2((5, 1), G_B) = (5 - 5)^2 + (1 - 2)^2 = 1$. $d^2((5, 3), G_B) = (5 - 5)^2 + (3 - 2)^2 = 1$.

(b) $I_{\text{intraclasse}} = \frac{1 + 1 + 1 + 1}{4} = 1$.



(c) L'inertie intraclasse totale **augmenterait** nécessairement : par construction, un point réaffecté à une classe autre que la plus proche de son centre a une distance au carré à ce nouveau centre supérieure ou égale à celle qu'il avait vis-à-vis du centre de sa classe d'origine (ici, (1, 1) affecté à $G_B = (5, 2)$ donnerait $d^2 = 16 + 1 = 17$, bien supérieur à 1). Cela illustre exactement ce que les k -means minimisent : à chaque itération, l'algorithme ne peut que faire décroître (ou laisser inchangée) cette quantité, jamais l'augmenter.

Correction — Exercice 2

(a) Non : les quatre valeurs (55 %, 71 %, 63 %, 74 %) sont très dispersées, sans qu'aucune ne se répète – rien n'indique un optimum commun robuste.

(b) L'analyste doit conclure que ces données ne présentent **pas de groupes nets** en cinq classes : si une structure forte existait, des départs différents retomberaient sur (à peu près) la même partition, comme dans l'exemple du cours où trois départs sur quatre donnaient 76,54 %.

(c) Il devrait **l'écrire explicitement dans son rapport** : indiquer que la structure en cinq classes n'est pas robuste au point de départ de l'algorithme, plutôt que de ne présenter que le meilleur résultat (74 %) comme s'il s'agissait d'une conclusion assurée.

Correction — Exercice 3

(i) le nombre de classes est fourni par l'utilisateur : **k -means** (la CAH le détermine elle-même, via le dendrogramme).

(ii) une observation mal classée tôt peut être corrigée plus tard : **k -means** (la CAH ne revient jamais sur une fusion).

(iii) le résultat final ne dépend d'aucun choix aléatoire : **CAH** (les k -means dépendent du point de départ, sauf à en tester plusieurs).


(iv) le calcul reste rapide sur un très grand fichier : **k -means** (la CAH classique est en $O(n^3)$, impraticable sur de très grands n).

2 Exercices cumulatifs (introduction au chapitre 13)

Correction — Exercice 4

(a) $76,50 - 74,93 = 1,57$ point. Vérifié.

(b) $\frac{26}{300} \times 100 \approx 8,67\% \approx 8,7\%$. Vérifié.



(c) C'est le signe d'une partition initiale **déjà largement correcte** : un gain d'inertie interclasse aussi faible (1,57 point) pour un déplacement aussi limité (8,7 % des clients) montre que la CAH et les k -means, deux logiques différentes, retrouvent presque la même partition. Une partition réellement instable aurait produit soit un gain d'inertie beaucoup plus important, soit un déplacement massif d'individus (voire les deux).

3 Applications en sciences économiques

Correction — Exercice 5

(a) Non : un étalement de 42 % à 69 % sur dix départs, sans valeur qui se démarque en fréquence, signale une absence d'optimum robuste – il serait imprudent de recommander cette segmentation en six groupes à la direction.

(b) L'agence pourrait, par exemple : essayer un **nombre de classes différent** (k plus petit, en s'appuyant sur le coude de la courbe d'inertie ou sur une CAH préalable) ; ou **classer sur des axes factoriels** plutôt que sur les variables brutes si ce n'est pas déjà fait (débruitage, décorrélation) ; ou, plus radicalement, conclure que ce marché ne présente **pas de segments naturels** exploitables avec les variables disponibles.

(c) Parce que présenter uniquement le meilleur résultat (69 %) donnerait l'illusion d'une partition solide et reproductible, alors qu'elle n'est en réalité que le fruit du hasard d'un tirage de départ favorable parmi dix essais très dispersés – une pratique trompeuse que le cours met explicitement en garde de ne pas adopter.

Correction — Exercice 6

(a) Gain d'inertie interclasse : $70,1 - 68,0 = 2,1$ points. Pourcentage de fonds déplacés : $95/250 \times 100 = 38,0\%$.

(b) Les deux indicateurs sont nettement plus élevés que ceux du cours (1,57 point et 8,7 % pour les clients) : le gain d'inertie est ici plus grand (2,1 contre 1,57 point), et surtout, plus d'un **tiers** des fonds change de catégorie (38,0 %) contre moins d'un dixième chez les clients (8,7 %) – plus de quatre fois plus de mouvement relatif. Cela suggère que la partition CAH initiale des fonds était **beaucoup moins stable** que celle des clients du cours : deux logiques de classement différentes (hiérarchique et itérative) s'accordent nettement moins bien sur ces données financières.

(c) Face à un tel volume de réaffectations, la société de gestion devrait **examiner attentivement les catégories concernées** avant de publier ses résultats – par exemple en testant plusieurs départs aléatoires pour les k -means (comme au chapitre 13), en vérifiant si le nombre de classes (5) est réellement adapté (coude de la courbe d'inertie), voire en documentant explicitement, comme le

recommande le cours, que cette classification est moins robuste que d'ordinaire plutôt que de la présenter sans réserve.