

Analyse des données avancée

Chapitre 13 : Les k-means et la consolidation

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer l'inertie intraclasse d'une partition k -means

Quatre points sont répartis en deux classes : Classe $A = \{(1, 1), (1, 3)\}$ de centre $G_A = (1, 2)$; Classe $B = \{(5, 1), (5, 3)\}$ de centre $G_B = (5, 2)$.

- (a) Calculer $d^2(i, G_k)$ pour chacun des quatre points par rapport au centre de sa propre classe.
- (b) En déduire $I_{\text{intraclasse}} = \frac{1}{n} \sum_k \sum_{i \in C_k} d^2(i, G_k)$.
- (c) Si l'un des points de la classe A était réaffecté par erreur à la classe B , l'inertie intraclasse totale augmenterait-elle ou diminuerait-elle nécessairement? Pourquoi cela illustre-t-il le critère que minimisent les k -means?

Exercice 2 — Juger la robustesse d'une partition à partir de plusieurs départs

Un analyste relance un k -means à $k = 5$ depuis quatre points de départ aléatoires différents, et obtient les inerties interclasses suivantes : 55 %, 71 %, 63 %, 74 %.

- (a) Ces quatre résultats convergent-ils vers un optimum commun?
- (b) Que doit conclure l'analyste sur la présence, ou l'absence, de groupes nets dans ces données?
- (c) Que devrait-il écrire dans son rapport, d'après la mise en garde du cours?

Exercice 3 — Comparer CAH et k -means

Pour chacune des quatre caractéristiques suivantes, indiquer si elle décrit plutôt la CAH, plutôt les k -means, ou aucune des deux : (i) le nombre de classes est fourni par l'utilisateur ; (ii) une observation mal classée tôt peut être corrigée plus tard ; (iii) le résultat final ne dépend d'aucun choix aléatoire ; (iv) le calcul reste rapide sur un très grand fichier.

2 Exercices cumulatifs (introduction au chapitre 13)

Exercice 4 — Vérifier le gain de la consolidation

On reprend les résultats du cours sur les 300 clients : l'inertie interclasse de la partition CAH initiale valait 74,93 % ; après consolidation par k -means partant des centres de la CAH, elle atteint 76,50 %, et 26 clients ont changé de classe.

- (a) Calculer le gain d'inertie interclasse apporté par la consolidation, et vérifier qu'on retrouve 1,57 point.
- (b) Calculer le pourcentage de clients ayant changé de classe, et vérifier qu'on retrouve 8,7 %.
- (c) Un gain de 1,57 point pour 8,7 % de clients déplacés est-il le signe d'une partition initiale très instable, ou au contraire d'une partition déjà largement correcte? Justifier à partir des deux nombres calculés.

3 Applications en sciences économiques

Exercice 5 — Décider si une segmentation est publiable

Une agence marketing teste un k -means à $k = 6$ sur les données d'un nouveau marché, avec dix départs aléatoires. Les inerties interclasses obtenues s'étalent de 42 % à 69 %, sans qu'aucune valeur ne se détache nettement des autres par sa fréquence d'apparition.

- (a) Cette dispersion des résultats permet-elle de recommander une segmentation en six groupes à

la direction du marketing ?

- (b) Quelles décisions l'agence pourrait-elle envisager face à ce résultat (au moins deux pistes) ?
- (c) Pourquoi serait-il trompeur de simplement présenter la meilleure des dix inerties obtenues (69 %) sans mentionner les neuf autres ?

Exercice 6 — Consolider une classification de fonds d'investissement

Une société de gestion classe 250 fonds en cinq catégories par CAH, obtenant une inertie interclasse de 68,0 %. Elle consolide ensuite cette partition par k -means en partant des cinq centres issus de la CAH, et obtient 70,1 % d'inertie interclasse, avec 95 fonds ayant changé de catégorie.


- (a) Calculer le gain d'inertie interclasse et le pourcentage de fonds déplacés.
- (b) Comparer ces deux pourcentages à ceux du cours (Exercice 4). Que suggère cette comparaison sur la stabilité de la classification initiale de fonds, par rapport à celle des clients du cours ?
- (c) Quelle décision méthodologique cette différence pourrait-elle inciter la société de gestion à prendre avant de présenter ses résultats ?

1 Exercices du chapitre

Correction — Exercice 1

(a) $d^2((1,1), G_A) = (1-1)^2 + (1-2)^2 = 1$. $d^2((1,3), G_A) = (1-1)^2 + (3-2)^2 = 1$. $d^2((5,1), G_B) = (5-5)^2 + (1-2)^2 = 1$. $d^2((5,3), G_B) = (5-5)^2 + (3-2)^2 = 1$.

(b) $I_{\text{intraclasse}} = \frac{1+1+1+1}{4} = 1$.



(c) L'inertie intraclasse totale **augmenterait** nécessairement : par construction, un point réaffecté à une classe autre que la plus proche de son centre a une distance au carré à ce nouveau centre supérieure ou égale à celle qu'il avait vis-à-vis du centre de sa classe d'origine (ici, (1,1) affecté à $G_B = (5,2)$ donnerait $d^2 = 16+1 = 17$, bien supérieur à 1). Cela illustre exactement ce que les k -means minimisent : à chaque itération, l'algorithme ne peut que faire décroître (ou laisser inchangée) cette quantité, jamais l'augmenter.

Correction — Exercice 2

(a) Non : les quatre valeurs (55 %, 71 %, 63 %, 74 %) sont très dispersées, sans qu'aucune ne se répète – rien n'indique un optimum commun robuste.

(b) L'analyste doit conclure que ces données ne présentent **pas de groupes nets** en cinq classes : si une structure forte existait, des départs différents retomberaient sur (à peu près) la même partition, comme dans l'exemple du cours où trois départs sur quatre donnaient 76,54 %.

(c) Il devrait **l'écrire explicitement dans son rapport** : indiquer que la structure en cinq classes n'est pas robuste au point de départ de l'algorithme, plutôt que de ne présenter que le meilleur résultat (74 %) comme s'il s'agissait d'une conclusion assurée.

Correction — Exercice 3

(i) le nombre de classes est fourni par l'utilisateur : **k -means** (la CAH le détermine elle-même, via le dendrogramme).

(ii) une observation mal classée tôt peut être corrigée plus tard : **k -means** (la CAH ne revient jamais sur une fusion).

(iii) le résultat final ne dépend d'aucun choix aléatoire : **CAH** (les k -means dépendent du point de départ, sauf à en tester plusieurs).


(iv) le calcul reste rapide sur un très grand fichier : **k -means** (la CAH classique est en $O(n^3)$, impraticable sur de très grands n).

2 Exercices cumulatifs (introduction au chapitre 13)

Correction — Exercice 4

(a) $76,50 - 74,93 = 1,57$ point. Vérifié.

(b) $\frac{26}{300} \times 100 \approx 8,67\% \approx 8,7\%$. Vérifié.



(c) C'est le signe d'une partition initiale **déjà largement correcte** : un gain d'inertie interclasse aussi faible (1,57 point) pour un déplacement aussi limité (8,7 % des clients) montre que la CAH et les k -means, deux logiques différentes, retrouvent presque la même partition. Une partition réellement instable aurait produit soit un gain d'inertie beaucoup plus important, soit un déplacement massif d'individus (voire les deux).

3 Applications en sciences économiques

Correction — Exercice 5

(a) Non : un étalement de 42 % à 69 % sur dix départs, sans valeur qui se démarque en fréquence, signale une absence d'optimum robuste – il serait imprudent de recommander cette segmentation en six groupes à la direction.

(b) L'agence pourrait, par exemple : essayer un **nombre de classes différent** (k plus petit, en s'appuyant sur le coude de la courbe d'inertie ou sur une CAH préalable) ; ou **classer sur des axes factoriels** plutôt que sur les variables brutes si ce n'est pas déjà fait (débruitage, décorrélation) ; ou, plus radicalement, conclure que ce marché ne présente **pas de segments naturels** exploitables avec les variables disponibles.

(c) Parce que présenter uniquement le meilleur résultat (69 %) donnerait l'illusion d'une partition solide et reproductible, alors qu'elle n'est en réalité que le fruit du hasard d'un tirage de départ favorable parmi dix essais très dispersés – une pratique trompeuse que le cours met explicitement en garde de ne pas adopter.

Correction — Exercice 6

(a) Gain d'inertie interclasse : $70,1 - 68,0 = 2,1$ points. Pourcentage de fonds déplacés : $95/250 \times 100 = 38,0\%$.

(b) Les deux indicateurs sont nettement plus élevés que ceux du cours (1,57 point et 8,7 % pour les clients) : le gain d'inertie est ici plus grand (2,1 contre 1,57 point), et surtout, plus d'un **tiers** des fonds change de catégorie (38,0 %) contre moins d'un dixième chez les clients (8,7 %) – plus de quatre fois plus de mouvement relatif. Cela suggère que la partition CAH initiale des fonds était **beaucoup moins stable** que celle des clients du cours : deux logiques de classement différentes (hiérarchique et itérative) s'accordent nettement moins bien sur ces données financières.

(c) Face à un tel volume de réaffectations, la société de gestion devrait **examiner attentivement les catégories concernées** avant de publier ses résultats – par exemple en testant plusieurs départs aléatoires pour les k -means (comme au chapitre 13), en vérifiant si le nombre de classes (5) est réellement adapté (coude de la courbe d'inertie), voire en documentant explicitement, comme le

recommande le cours, que cette classification est moins robuste que d'ordinaire plutôt que de la présenter sans réserve.