

Chapitre 13

Les k -means et la consolidation

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Exercice 1 — Calculer l'inertie intraclasse d'une partition k -means

Quatre points sont répartis en deux classes : Classe $A = \{(1, 1), (1, 3)\}$ de centre $G_A = (1, 2)$; Classe $B = \{(5, 1), (5, 3)\}$ de centre $G_B = (5, 2)$.

- (a) Calculer $d^2(i, G_k)$ pour chacun des quatre points par rapport au centre de sa propre classe.
- (b) En déduire $I_{\text{intraclasse}} = \frac{1}{n} \sum_k \sum_{i \in C_k} d^2(i, G_k)$.
- (c) Si l'un des points de la classe A était réaffecté par erreur à la classe B , l'inertie intraclasse totale augmenterait-elle ou diminuerait-elle nécessairement? Pourquoi cela illustre-t-il le critère que minimisent les k -means?

Exercice 2 — Juger la robustesse d'une partition à partir de plusieurs départs

Un analyste relance un k -means à $k = 5$ depuis quatre points de départ aléatoires différents, et obtient les inerties interclasses suivantes : 55 %, 71 %, 63 %, 74 %.

- (a) Ces quatre résultats convergent-ils vers un optimum commun?
- (b) Que doit conclure l'analyste sur la présence, ou l'absence, de groupes nets dans ces données?
- (c) Que devrait-il écrire dans son rapport, d'après la mise en garde du cours?

Exercice 3 — Comparer CAH et k -means

Pour chacune des quatre caractéristiques suivantes, indiquer si elle décrit plutôt la CAH, plutôt les k -means, ou aucune des deux : (i) le nombre de classes est fourni par l'utilisateur; (ii) une observation mal classée tôt peut être corrigée plus tard; (iii) le résultat final ne dépend d'aucun choix aléatoire; (iv) le calcul reste rapide sur un très grand fichier.

2 Exercices cumulatifs (introduction au chapitre 13)

Exercice 4 — Vérifier le gain de la consolidation

On reprend les résultats du cours sur les 300 clients : l'inertie interclasse de la partition CAH initiale valait 74,93 %; après consolidation par k -means partant des centres de la CAH, elle atteint 76,50 %, et 26 clients ont changé de classe.

- (a) Calculer le gain d'inertie interclasse apporté par la consolidation, et vérifier qu'on retrouve 1,57 point.
- (b) Calculer le pourcentage de clients ayant changé de classe, et vérifier qu'on retrouve 8,7 %.
- (c) Un gain de 1,57 point pour 8,7 % de clients déplacés est-il le signe d'une partition initiale très instable, ou au contraire d'une partition déjà largement correcte? Justifier à partir des deux nombres calculés.

3 Applications en sciences économiques

Exercice 5 — Décider si une segmentation est publiable

Une agence marketing teste un k -means à $k = 6$ sur les données d'un nouveau marché, avec dix départs aléatoires. Les inerties interclasses obtenues s'étalent de 42 % à 69 %, sans qu'aucune valeur ne se détache nettement des autres par sa fréquence d'apparition.

- (a) Cette dispersion des résultats permet-elle de recommander une segmentation en six groupes à

la direction du marketing?

- (b) Quelles décisions l'agence pourrait-elle envisager face à ce résultat (au moins deux pistes)?
- (c) Pourquoi serait-il trompeur de simplement présenter la meilleure des dix inerties obtenues (69 %) sans mentionner les neuf autres?

Exercice 6 — Consolider une classification de fonds d'investissement

Une société de gestion classe 250 fonds en cinq catégories par CAH, obtenant une inertie interclasse de 68,0 %. Elle consolide ensuite cette partition par k -means en partant des cinq centres issus de la CAH, et obtient 70,1 % d'inertie interclasse, avec 95 fonds ayant changé de catégorie.

- (a) Calculer le gain d'inertie interclasse et le pourcentage de fonds déplacés.
- (b) Comparer ces deux pourcentages à ceux du cours (Exercice 4). Que suggère cette comparaison sur la stabilité de la classification initiale de fonds, par rapport à celle des clients du cours?
- (c) Quelle décision méthodologique cette différence pourrait-elle inciter la société de gestion à prendre avant de présenter ses résultats?