

Analyse des données avancée

Chapitre 19 : Mise en œuvre sur R et Python

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Lire les arguments actif/illustratif d'un appel PCA

Un fichier de 500 salariés comporte, dans cet ordre de colonnes, les variables suivantes : (1) identifiant, (2) service, (3) ancienneté, (4) sexe, (5) à (12) huit notes de satisfaction au travail, (13) départ volontaire dans l'année.

- (a) Écrire l'appel `PCA(sal, quanti.sup = ..., quali.sup = ...)` qui mettrait les huit notes en actif et le reste en illustratif, sous FactoMineR.
- (b) Un collègue propose `PCA(sal)`, sans aucun argument. Que se passerait-il, et pourquoi le logiciel ne signalerait-il aucune erreur ?
- (c) Pourquoi la ligne `quanti.sup/quali.sup` mérite-t-elle, d'après le cours, d'être « relue trois fois avant de commenter quoi que ce soit » ?

Exercice 2 — Traduire une commande R en Python

Pour chacune des commandes R suivantes, donner l'équivalent Python d'après le tableau de correspondance du cours : (i) `PCA(...)`; (ii) `hclust(..., "ward.D2")`; (iii) `lda(...)` (paquet MASS); (iv) `cmdscale(...)`.

Exercice 3 — Repérer un piège que le logiciel ne signale pas

Un étudiant lance `HCPC(acp, nb.clust = 5)` sur des données dont il n'a jamais vérifié le saut d'inertie, et obtient un dendrogramme et cinq classes d'apparence parfaitement convaincante.

- (a) Le fait que la fonction produise un résultat « propre » garantit-il que ces cinq classes reflètent une structure réelle des données ?
- (b) Que devrait faire l'étudiant *avant* de fixer `nb.clust = 5`, d'après les chapitres 12 et 13 ?
- (c) Reformuler, dans ses propres mots, la mise en garde du cours : « ce n'est pas à la fonction de trancher ».

2 Exercices cumulatifs (introduction au chapitre 19)

Exercice 4 — Vérifier les sorties logicielles officielles

On reprend les sorties R du cours sur les 300 clients.

- (a) `acp$eig` affiche 4,535 puis 1,645 sur 8 notes. Calculer les deux pourcentages d'inertie associés, et vérifier qu'on retrouve 56,69 % et 20,56 % (arrondi à 20,57 dans le cours).
- (b) `chisq.test(tab)` affiche $\chi^2 = 110,41$ pour 12 degrés de liberté sur le tableau CSP $\times$ motif ($n = 300$). `afc$eig` affiche ensuite 0,2267 et 0,1030. Calculer les pourcentages associés (rapportés à $\Phi^2 = \chi^2/n$), et vérifier qu'on retrouve environ 61,6 % et 28,0 %.
- (c) `table(cl$frequence, predict(afd)$class)` donne un taux de bon classement de 67,0 %, contre 65,3 % en validation croisée. Ces deux nombres, déjà vérifiés au chapitre 16, apparaissent-ils cohérents avec la sortie logicielle du cours ?

3 Applications en sciences économiques

Exercice 5 — Choisir R ou Python pour un projet d'entreprise

Une banque veut, d'une part, réaliser une étude ponctuelle de segmentation de 2 000 clients premium pour son comité marketing, et d'autre part, recalculer chaque nuit un score de risque sur l'ensemble de ses 3 millions de clients pour alimenter son système d'alerte.

- (a) Quel langage recommanderiez-vous pour l'étude ponctuelle, et pourquoi ?
- (b) Quel langage recommanderiez-vous pour le recalcul quotidien du score, et pourquoi ?
- (c) En quoi la sortie de FactoMineR (contributions et $\cos^2$ fournis d'emblée) est-elle particulièrement adaptée au premier usage, et peu déterminante pour le second ?

Exercice 6 — Auditer un script avant de publier ses résultats

Un analyste transmet un script R qui charge un fichier clients, appelle `PCA(c1)` sans aucun argument `quant1.sup/qual1.sup`, puis `HCPC(acp, nb.clust = 4)` sans avoir examiné le graphique du saut d'inertie, et conclut à quatre segments « robustes ».

- (a) Identifier les deux défauts méthodologiques de ce script, en s'appuyant sur les deux pièges rappelés dans ce chapitre.
- (b) Pour chacun des deux défauts, indiquer précisément quelle instruction ou quelle vérification manque.
- (c) Le script tourne sans message d'erreur et produit des graphiques d'apparence professionnelle. Pourquoi cela ne suffit-il pas à garantir la validité des conclusions ?

1 Exercices du chapitre

Correction — Exercice 1

(a) Les colonnes 2 (service), 3 (ancienneté), 4 (sexe) et 13 (départ volontaire) doivent être illustratives ; les colonnes 5 à 12 (les huit notes) restent actives par défaut. Avec le sexe et le service en qualitatives et l'ancienneté en quantitative :

```
PCA(sal, quanti.sup = c(3, 13), quali.sup = c(2, 4), scale.unit = TRUE)
```

(en supposant « départ volontaire » codé numériquement ; s'il est codé oui/non, il rejoint `quali.sup`).

(b) `PCA(sal)` sans argument mettrait **toutes** les colonnes numériques en actif, y compris l'identifiant et l'ancienneté, et calculerait des axes construits en partie sur des variables qui n'ont rien à voir avec l'opinion à structurer. Le logiciel ne signale aucune erreur car, techniquement, le calcul est parfaitement valide : rien ne distingue, du point de vue de R, une colonne « censée être active » d'une colonne qui ne l'est pas – c'est une décision de **contenu**, que seul l'analyste peut prendre.

(c) Parce que cette ligne encode, en deux vecteurs d'indices, la décision méthodologique la plus engageante de toute l'étude (le chapitre 1 du cours) : une erreur d'indice glissée dans `quanti.sup` ou `quali.sup` produit un résultat **parfaitement propre et parfaitement faux**, sans qu'aucun message d'erreur ne le signale.

Correction — Exercice 2

(i) `PCA(...)` → `prince.PCA(...)`.

(ii) `hclust(..., "ward.D2")` → `scipy.cluster.hierarchy.linkage(..., method="ward")`.

(iii) `lda(...)` (MASS) → `sklearn.discriminant_analysis.LinearDiscriminantAnalysis`.

(iv) `cmdscale(...)` → `sklearn.manifold.MDS`.

Correction — Exercice 3

(a) Non, absolument pas : HCPC produira un dendrogramme et des classes d'apparence convaincante **même sur des données tirées au hasard**, comme le rappelle explicitement le cours (« un arbre existe toujours », chapitre 12). L'apparence propre du résultat ne garantit rien sur la réalité de la structure.

(b) Il devrait d'abord examiner la **courbe des sauts d'inertie** (le dendrogramme complet, sans nombre de classes imposé) pour repérer un éventuel « grand saut » justifiant un nombre de classes précis, et éventuellement croiser ce diagnostic avec plusieurs départs de *k*-means (chapitre 13) pour vérifier la robustesse du résultat – avant de fixer arbitrairement `nb.clust = 5`.


(c) Une reformulation possible : « la fonction calcule ce qu'on lui demande de calculer, mais elle ne sait pas si le résultat a un sens – c'est à l'analyste, en examinant le saut d'inertie, l'interprétabilité des classes et la convergence entre méthodes, de décider si la segmentation obtenue reflète une structure réelle ou n'est qu'un découpage arbitraire d'un nuage sans forme. »

2 Exercices cumulatifs (introduction au chapitre 19)

Correction — Exercice 4

(a) $4,535/8 = 0,5669 = 56,69\%$. $1,645/8 = 0,205625 \approx 20,56\%$ (le cours arrondit à 20,57%). Vérifié.

(b) $\Phi^2 = 110,41/300 \approx 0,3680$. $0,2267/0,3680 \approx 0,6160 = 61,60\%$. $0,1030/0,3680 \approx 0,2799 = 27,99\% \approx 28,0\%$. Vérifié.



(c) Oui : les deux taux (67,0 % en resubstitution, 65,3 % en validation croisée) sont exactement ceux calculés et vérifiés au chapitre 16 – la sortie logicielle du cours ne fait que reproduire, via `lda` et `predict`, un calcul que nous avons déjà mené et vérifié « à la main ». C’est précisément l’objet de ce chapitre : montrer qu’« aucune sortie de logiciel ne contient rien que nous n’ayons établi ».

3 Applications en sciences économiques

Correction — Exercice 5

- (a) **R**, pour l’étude ponctuelle : FactoMineR fournit d’emblée contributions, $\cos^2$ et éléments illustratifs, exactement les indicateurs nécessaires pour interpréter en profondeur un plan factoriel destiné à un comité marketing – un usage typique d’analyse approfondie sur un fichier de taille modérée.
- (b) **Python**, pour le recalcul quotidien : l’écosystème Python (via `scikit-learn`, `pandas`) est mieux outillé pour **industrialiser** un calcul récurrent sur de gros volumes (trois millions de clients chaque nuit), s’intégrer dans un pipeline de production, et s’articuler avec d’autres systèmes d’information.
- (c) Pour l’étude ponctuelle, l’interprétation fine du plan factoriel (via contributions et $\cos^2$) est l’objectif même du travail : que R les fournisse d’emblée est un gain de temps décisif. Pour le score quotidien, en revanche, ce sont uniquement les **coordonnées finales** (le score lui-même) qui comptent une fois le modèle stabilisé – la disponibilité immédiate des contributions et $\cos^2$ n’apporte alors aucune valeur ajoutée au traitement automatisé.

Correction — Exercice 6

- (a) Les deux défauts sont exactement les deux pièges rappelés dans ce chapitre : `PCA(c1)` sans `quant.sup/quali.sup` met **toutes** les variables en actif, y compris celles qui n’auraient pas dû l’être (le logiciel « ne choisit pas les variables actives »); et `HCPC(acp, nb.clust = 4)` sans avoir examiné le saut d’inertie impose un nombre de classes sans vérifier qu’une structure en quatre groupes existe réellement (le logiciel « ne dit pas si les classes existent »).
- (b) Pour le premier défaut : il manque les arguments `quant.sup` et `quali.sup`, désignant explicitement les colonnes qui doivent rester illustratives. Pour le second : il manque l’examen préalable du **dendrogramme complet** (ou de la courbe des sauts d’inertie), avant de fixer arbitrairement `nb.clust = 4`.
- (c) Parce qu’un script qui « tourne » et produit des graphiques soignés donne une **illusion de rigueur** qui n’a rien à voir avec la validité du contenu analytique : le logiciel exécute fidèlement des instructions, même mal posées, et ne peut détecter une erreur de décision méthodologique (comme un mauvais choix de variables actives ou un nombre de classes arbitraire). Seule une lecture critique du script par un analyste compétent – pas l’absence de message d’erreur – peut garantir la validité des conclusions.