

Chapitre 19

Mise en œuvre sur R et Python

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Exercice 1 — Lire les arguments actif/illustratif d'un appel PCA

Un fichier de 500 salariés comporte, dans cet ordre de colonnes, les variables suivantes : (1) identifiant, (2) service, (3) ancienneté, (4) sexe, (5) à (12) huit notes de satisfaction au travail, (13) départ volontaire dans l'année.

- (a) Écrire l'appel `PCA(sal, quanti.sup = ..., quali.sup = ...)` qui mettrait les huit notes en actif et le reste en illustratif, sous FactoMineR.
- (b) Un collègue propose `PCA(sal)`, sans aucun argument. Que se passerait-il, et pourquoi le logiciel ne signalerait-il aucune erreur ?
- (c) Pourquoi la ligne `quanti.sup/quali.sup` mérite-t-elle, d'après le cours, d'être « relue trois fois avant de commenter quoi que ce soit » ?

Exercice 2 — Traduire une commande R en Python

Pour chacune des commandes R suivantes, donner l'équivalent Python d'après le tableau de correspondance du cours : (i) `PCA(...)`; (ii) `hclust(..., "ward.D2")`; (iii) `lda(...)` (paquet MASS); (iv) `cmdscale(...)`.

Exercice 3 — Repérer un piège que le logiciel ne signale pas

Un étudiant lance `HCPC(acp, nb.clust = 5)` sur des données dont il n'a jamais vérifié le saut d'inertie, et obtient un dendrogramme et cinq classes d'apparence parfaitement convaincante.

- (a) Le fait que la fonction produise un résultat « propre » garantit-il que ces cinq classes reflètent une structure réelle des données ?
- (b) Que devrait faire l'étudiant *avant* de fixer `nb.clust = 5`, d'après les chapitres 12 et 13 ?
- (c) Reformuler, dans ses propres mots, la mise en garde du cours : « ce n'est pas à la fonction de trancher ».

2 Exercices cumulatifs (introduction au chapitre 19)

Exercice 4 — Vérifier les sorties logicielles officielles

On reprend les sorties R du cours sur les 300 clients.

- (a) `acp$eig` affiche 4,535 puis 1,645 sur 8 notes. Calculer les deux pourcentages d'inertie associés, et vérifier qu'on retrouve 56,69 % et 20,56 % (arrondi à 20,57 dans le cours).
- (b) `chisq.test(tab)` affiche $\chi^2 = 110,41$ pour 12 degrés de liberté sur le tableau CSP $\times$ motif ($n = 300$). `afc$eig` affiche ensuite 0,2267 et 0,1030. Calculer les pourcentages associés (rapportés à $\Phi^2 = \chi^2/n$), et vérifier qu'on retrouve environ 61,6 % et 28,0 %.
- (c) `table(cl$frequence, predict(afd)$class)` donne un taux de bon classement de 67,0 %, contre 65,3 % en validation croisée. Ces deux nombres, déjà vérifiés au chapitre 16, apparaissent-ils cohérents avec la sortie logicielle du cours ?

3 Applications en sciences économiques

Exercice 5 — Choisir R ou Python pour un projet d'entreprise

Une banque veut, d'une part, réaliser une étude ponctuelle de segmentation de 2 000 clients premium pour son comité marketing, et d'autre part, recalculer chaque nuit un score de risque sur l'ensemble de ses 3 millions de clients pour alimenter son système d'alerte.

- (a) Quel langage recommanderiez-vous pour l'étude ponctuelle, et pourquoi ?
- (b) Quel langage recommanderiez-vous pour le recalcul quotidien du score, et pourquoi ?
- (c) En quoi la sortie de FactoMineR (contributions et $\cos^2$ fournis d'emblée) est-elle particulièrement adaptée au premier usage, et peu déterminante pour le second ?

Exercice 6 — Auditer un script avant de publier ses résultats

Un analyste transmet un script R qui charge un fichier clients, appelle `PCA(c1)` sans aucun argument `quant1.sup/qual1.sup`, puis `HCPC(acp, nb.clust = 4)` sans avoir examiné le graphique du saut d'inertie, et conclut à quatre segments « robustes ».

- (a) Identifier les deux défauts méthodologiques de ce script, en s'appuyant sur les deux pièges rappelés dans ce chapitre.
- (b) Pour chacun des deux défauts, indiquer précisément quelle instruction ou quelle vérification manque.
- (c) Le script tourne sans message d'erreur et produit des graphiques d'apparence professionnelle. Pourquoi cela ne suffit-il pas à garantir la validité des conclusions ?