

Analyse des données avancée

Chapitre 9 : Profils, barycentres et lecture conjointe

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Appliquer la formule de transition

Une ligne a pour profil $(0,5; 0,3; 0,2)$ sur trois colonnes dont les coordonnées sur l'axe 1 valent $G_1 = (1,2; -0,8; 0,3)$. La valeur propre de cet axe est $\lambda_1 = 0,16$.

- (a) Calculer le barycentre non dilaté $\sum_j \frac{f_{ij}}{f_{i.}} G_1(j)$.
- (b) Calculer le facteur de dilatation $1/\sqrt{\lambda_1}$.
- (c) En déduire la coordonnée $F_1(i)$ de cette ligne.

Exercice 2 — Contribution et cosinus carré en AFC

Une modalité-ligne pèse $f_{i.} = 0,15$ dans l'effectif total. Sa coordonnée sur l'axe 1 vaut $F_1(i) = 0,6$, la valeur propre est $\lambda_1 = 0,09$, et sa distance au carré au profil moyen est $d_{\chi^2}^2(i, \text{profil moyen}) = 0,5$.

- (a) Calculer $\text{ctr}_1(i) = f_{i.} F_1(i)^2 / \lambda_1$.
- (b) Calculer $\cos^2_1(i) = F_1(i)^2 / d_{\chi^2}^2(i, \text{profil moyen})$.
- (c) Cette modalité domine-t-elle l'axe si elle est l'une de sept modalités en tout? Est-elle bien représentée sur cet axe?

Exercice 3 — Diagnostiquer une modalité rare

Dans un fichier de 500 répondants, une modalité « Autre » ne regroupe que 4 individus ($f_{i.} = 0,008$), et se retrouve isolée à l'extrémité du premier axe factoriel, très loin de toutes les autres modalités.

- (a) Pourquoi une modalité aussi rare peut-elle avoir une distance au centre énorme, alors même que son poids est presque nul?
- (b) Citer les trois remèdes possibles présentés dans le cours, dans l'ordre où on devrait les envisager.
- (c) Pourquoi serait-il trompeur de commenter cette modalité comme si elle structurait le premier axe?

2 Exercices cumulatifs (introduction au chapitre 9)

Exercice 4 — Reconstruire la coordonnée de l'étudiant

On reprend le profil de la catégorie « Étudiant » du cours : $(0,636; 0,091; 0,227; 0,045)$, et les coordonnées-colonnes sur l'axe 1 : $G_1 = (-0,544; 0,523; -0,366; 0,419)$ pour (Prix, Choix, Proximité, Service). La première valeur propre est $\lambda_1 = 0,2267$.

- (a) Calculer le barycentre non dilaté, et vérifier qu'on retrouve $-0,363$ (cours).
- (b) Calculer le facteur de dilatation $1/\sqrt{\lambda_1}$, et vérifier qu'on retrouve 2,100.
- (c) En déduire $F_1(\text{Étudiant})$, et vérifier qu'on retrouve $-0,762$ (cours). Sachant que le poids de l'étudiant est $f_{i.} = 22/300$, calculer $\text{ctr}_1(\text{Étudiant})$ et vérifier qu'on retrouve 18,8 %.

3 Applications en sciences économiques

Exercice 5 — Suivre une clientèle dans le temps

Une enseigne a réalisé son AFC « CSP $\times$ motif » en année N . En année $N+1$, elle interroge une nouvelle vague de clients et projette leurs profils, en supplémentaire, sur les axes déjà calculés en année N .

- (a) La nouvelle vague participe-t-elle au calcul des nouveaux axes? Justifier à partir de la formule barycentrique.
- (b) Si les points projetés de l'année $N+1$ tombent presque exactement sur ceux de l'année N , que peut-on en conclure sur la structure du marché?
- (c) Si, au contraire, les cadres se déplacent nettement vers le pôle « Prix » d'une année sur l'autre, comment interpréter commercialement ce déplacement?

Exercice 6 — Lire une proximité ligne-colonne sans se tromper

Sur le plan AFC du cours, la modalité « Retraité » est visuellement très proche de la modalité « Proximité ».

- (a) Cette proximité signifie-t-elle que la majorité des retraités choisissent le motif « Proximité »? Reformuler ce qu'elle signifie réellement, à l'aide de la notion de sur-représentation par rapport à l'indépendance.
- (b) Le cours précise que les retraités ne sont que 17 à citer « Proximité » sur 300 clients. Cela remet-il en cause la lecture précédente? Pourquoi?
- (c) Un collègue conclut, à partir de ce plan, que l'AFC autoriserait toujours à lire une distance entre un individu et une variable, comme en ACP. Corriger cette généralisation abusive.


1 Exercices du chapitre

Correction — Exercice 1

(a) $0,5 \times 1,2 + 0,3 \times (-0,8) + 0,2 \times 0,3 = 0,60 - 0,24 + 0,06 = 0,42.$

(b) $1/\sqrt{0,16} = 1/0,4 = 2,5.$

(c) $F_1(i) = 0,42 \times 2,5 = 1,05.$



Correction — Exercice 2

(a) $\text{ctr}_1(i) = \frac{0,15 \times 0,6^2}{0,09} = \frac{0,15 \times 0,36}{0,09} = \frac{0,054}{0,09} = 0,6 = 60\%.$

(b) $\cos^2_1(i) = \frac{0,6^2}{0,5} = \frac{0,36}{0,5} = 0,72.$

(c) La contribution moyenne sur 7 modalités vaut $1/7 \approx 14,3\%$. Avec 60 %, cette modalité pèse plus de **quatre fois** la moyenne : elle domine largement l'axe. Elle est en outre bien représentée, avec $\cos^2_1 = 0,72$ nettement au-dessus du seuil usuel de bonne représentation ($\approx 0,5-0,7$).

Correction — Exercice 3

(a) Le poids f_i (la taille) et la distance au centre $d^2_{\chi^2}(i, \text{profil moyen})$ (l'écart de profil) sont deux quantités indépendantes. Avec seulement 4 individus, le profil de « Autre » est **statistiquement instable** : quelques réponses atypiques suffisent à produire un profil très éloigné du profil moyen, donc une distance énorme, indépendamment du fait que son poids soit quasi nul.

(b) Dans l'ordre : **regrouper** cette modalité avec une modalité voisine si leurs profils se ressemblent (équivalence distributionnelle) ; sinon la passer en **élément supplémentaire** (elle ne participera plus au calcul des axes) ; ou, en dernier recours, **l'écarter** de l'analyse en le signalant explicitement.

(c) Parce que sa contribution réelle, $\text{ctr}_1 = f_i F_1^2 / \lambda_1$, reste **quasi nulle** malgré sa position visuelle extrême : le facteur $f_i = 0,008$ écrase le numérateur. Le point le plus excentré n'est pas nécessairement le plus déterminant – c'est précisément l'avertissement du cours (« le point le plus visible n'est pas le plus déterminant »).

2 Exercices cumulatifs (introduction au chapitre 9)

Correction — Exercice 4

(a)

$$0,636 \times (-0,544) + 0,091 \times 0,523 + 0,227 \times (-0,366) + 0,045 \times 0,419 \\ = -0,3460 + 0,0476 - 0,0831 + 0,0189 = -0,3626 \approx -0,363.$$

Vérifié.


(b) $1/\sqrt{0,2267} \approx 2,1003 \approx 2,100$. Vérifié.

(c) $F_1(\text{Étudiant}) = -0,3626 \times 2,1003 \approx -0,762$. Vérifié.

Avec $f_i = 22/300 \approx 0,0733$:

$$\text{ctr}_1(\text{Étudiant}) = \frac{0,0733 \times (-0,762)^2}{0,2267} = \frac{0,0733 \times 0,5806}{0,2267} \approx \frac{0,0426}{0,2267} \approx 0,1878 = 18,78\% \approx 18,8\%.$$

Vérifié (cours).



3 Applications en sciences économiques

Correction — Exercice 5

- (a) Non : par définition, un élément supplémentaire est projeté *après* le calcul des axes, avec la même formule barycentrique appliquée à son propre profil, mais il n'entre ni dans les marges ni dans la diagonalisation qui a produit ces axes. Sa contribution est nulle par construction.
- (b) Si les points de l'année $N+1$ tombent presque exactement sur ceux de l'année N , cela signifie que la **structure de la clientèle n'a pas changé** : chaque catégorie socioprofessionnelle continue de sur-consommer les mêmes motifs de fréquentation dans les mêmes proportions relatives.
- (c) Un déplacement des cadres vers le pôle « Prix » indique que cette catégorie, auparavant motivée surtout par le choix et le service, devient **plus sensible au prix** qu'auparavant – un signal commercial concret (par exemple, une clientèle cadre plus attentive à son budget, ou une érosion du pouvoir d'achat perçu) que l'enseigne peut suivre d'une vague d'enquête à l'autre.

Correction — Exercice 6

- (a) Non. La proximité sur le plan signifie que les retraités **sur-représentent** le motif « Proximité » par rapport à ce que prédirait l'indépendance entre CSP et motif – pas que la majorité des retraités choisissent ce motif. Le profil-ligne du retraité est (16,7 ; 3,3 ; 56,7 ; 23,3) % : « Proximité » y est effectivement majoritaire (56,7 %), mais ce qui compte pour la position sur le plan est l'écart à la moyenne (22,7 %), pas la majorité en tant que telle.
- (b) Non, cela ne remet pas en cause la lecture : la position sur le plan ne dépend pas de l'effectif absolu de la catégorie (17 retraités citant « Proximité ») mais du **profil relatif**. Un petit effectif peut produire un écart de profil tout aussi informatif qu'un grand effectif – c'est exactement la mise en garde du chapitre 8 sur la distinction entre poids et inertie.
- (c) La généralisation est fautive : c'est une lecture légitime **seulement en AFC**, parce que chaque nuage (lignes, colonnes) y est *littéralement* le barycentre de l'autre, à un facteur de dilatation commun près. En ACP, individus et variables vivent dans des espaces géométriquement différents (le chapitre 5 l'interdisait explicitement) : une proximité visuelle entre un individu et une variable sur un biplot d'ACP ne se commente pas de la même façon.