

Analyse des données avancée

Introduction : Reprendre l'analyse des données par l'algèbre

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer $X'X$ à la main

On dispose d'un tableau à 4 individus et 2 variables, déjà centrées :

Individu	x_1	x_2
1	-3	-3
2	-2	2
3	2	-2
4	3	3

- (a) Vérifier que les deux colonnes sont bien centrées (somme nulle chacune).
- (b) Calculer $X'X = \begin{pmatrix} \sum x_{i1}^2 & \sum x_{i1}x_{i2} \\ \sum x_{i1}x_{i2} & \sum x_{i2}^2 \end{pmatrix}$ terme par terme.
- (c) Que remarque-t-on sur la structure de cette matrice (diagonale, symétrie) ?

Exercice 2 — Des valeurs propres aux valeurs singulières

On reprend la matrice $X'X = \begin{pmatrix} 26 & 10 \\ 10 & 26 \end{pmatrix}$ obtenue à l'exercice 1.

- (a) Écrire l'équation caractéristique $\det(X'X - \lambda I) = 0$ sous la forme $\lambda^2 - \text{trace} \times \lambda + \det = 0$.
- (b) Résoudre cette équation du second degré et donner les deux valeurs propres.
- (c) En déduire les deux valeurs singulières de X (racines carrées des valeurs propres de $X'X$).

Exercice 3 — Explorer, ce n'est pas confirmer

Un chargé d'études présente à sa direction le résultat d'une ACP sur un fichier client : « l'axe 1 est significatif au seuil de 5 %, ce qui prouve l'existence d'un segment de clientèle ».

- (a) Cette phrase est-elle recevable dans le cadre d'une démarche exploratoire telle que définie par le cours ? Justifier.
- (b) Reformuler la conclusion de façon correcte, sans recourir à aucune notion de test statistique.
- (c) Quelle règle méthodologique le cours propose-t-il pour décider si une structure observée mérite d'être retenue ?

2 Applications en sciences économiques

Exercice 4 — Deux méthodes, un seul verdict

Un cabinet d'études marketing réalise une ACP sur les habitudes d'achat de 500 clients et obtient un premier axe qui semble opposer deux profils de consommation. Une classification automatique (une méthode différente, non vue dans ce cours) réalisée indépendamment sur le même fichier fait apparaître exactement les deux mêmes groupes.

- (a) D'après la règle énoncée dans l'introduction du cours, cette convergence de deux méthodes indépendantes change-t-elle le statut de la structure observée ? Comment ?
- (b) À l'inverse, si seule l'ACP avait révélé cette opposition, que faudrait-il en conclure, avec la prudence requise par une démarche exploratoire ?
- (c) Pourquoi est-il essentiel que les deux méthodes soient appliquées de façon réellement **indépendante** pour que cette convergence ait une valeur probante ?

Exercice 5 — Pourquoi calculer à la main avant de calculer en vrai

Une enseigne dispose d'un fichier réel de 300 clients notant 8 critères de satisfaction, soit 2 400 nombres, et d'un exemple réduit à 4 individus et 2 variables.

- (a) Quel est l'intérêt pédagogique de disposer d'un exemple minuscule, calculable entièrement à la main, avant d'aborder le fichier réel ?
- (b) Le cours choisit délibérément des valeurs qui donnent des résultats sans décimale (valeurs propres 16 et 4 sur son propre exemple). Pourquoi ce choix, plutôt que des données « réalistes » dès le départ ?
- (c) Une fois la mécanique comprise sur l'exemple à 4 individus, quel type d'erreur ce détour permet-il d'éviter lors de l'analyse du fichier à 300 clients (par un logiciel, cette fois) ?

1 Exercices du chapitre


Correction — Exercice 1

(a) Somme de x_1 : $-3 - 2 + 2 + 3 = 0$. Somme de x_2 : $-3 + 2 - 2 + 3 = 0$. Les deux colonnes sont bien centrées.

(b) $\sum x_{i1}^2 = (-3)^2 + (-2)^2 + 2^2 + 3^2 = 9 + 4 + 4 + 9 = 26$. $\sum x_{i2}^2 = (-3)^2 + 2^2 + (-2)^2 + 3^2 = 9 + 4 + 4 + 9 = 26$.

$\sum x_{i1}x_{i2} = (-3)(-3) + (-2)(2) + (2)(-2) + (3)(3) = 9 - 4 - 4 + 9 = 10$. Donc $\mathbf{X}'\mathbf{X} = \begin{pmatrix} 26 & 10 \\ 10 & 26 \end{pmatrix}$.

(c) La matrice est **symétrique** (comme toute matrice $\mathbf{X}'\mathbf{X}$) et a de plus ses deux termes diagonaux **égaux** ($26 = 26$) : cette égalité n'est pas générale, elle vient du choix particulier des données (les deux variables ont la même dispersion). C'est cette structure particulière qui permettra, à l'exercice 2, de trouver les valeurs propres sans résolution numérique compliquée.



Correction — Exercice 2

(a) Trace = $26 + 26 = 52$. Déterminant = $26 \times 26 - 10 \times 10 = 676 - 100 = 576$. Équation : $\lambda^2 - 52\lambda + 576 = 0$.

(b) Discriminant = $52^2 - 4 \times 576 = 2704 - 2304 = 400$, $\sqrt{400} = 20$. $\lambda = \frac{52 \pm 20}{2}$, soit $\lambda_1 = 36$ et $\lambda_2 = 16$.

(c) Valeurs singulières = $\sqrt{36} = 6$ et $\sqrt{16} = 4$.

Correction — Exercice 3

(a) Non, cette phrase n'est pas recevable : le cours est explicite, « rien de ce cours n'est un test statistique. Il n'y a ni hypothèse nulle, ni p -valeur, ni intervalle de confiance ». Parler d'un axe « significatif au seuil de 5 % » emprunte le vocabulaire de l'inférence à une démarche qui n'en fait pas.

(b) Une formulation correcte serait : « l'axe 1 de l'ACP fait apparaître, sur ce fichier, une opposition entre deux groupes de clients ; il s'agit d'un résumé descriptif du tableau observé, dont la pertinence reste à confirmer. »

(c) Le cours propose de **recouper** la structure par une seconde méthode : « une structure qu'une seule méthode voit n'est pas une structure ». Si une seconde méthode, appliquée indépendamment, retrouve la même opposition, on peut retenir le résultat ; sinon, il ne doit pas être présenté comme acquis.

2 Applications en sciences économiques

Correction — Exercice 4

(a) Oui, cette convergence change le statut de la structure : deux méthodes indépendantes (l'ACP et la classification) qui aboutissent au même résultat constituent précisément le **recoupement** exigé par le cours. La structure peut désormais être présentée avec confiance comme un résultat robuste, et non comme un simple artefact d'une seule technique.

(b) Sans confirmation par une seconde méthode, il faudrait présenter cette opposition avec la plus

grande prudence, comme une hypothèse de lecture du tableau et non comme un résultat établi – « une structure qu’une seule méthode voit n’est pas une structure ».

(c) Si les deux méthodes n’étaient pas réellement indépendantes (par exemple si la classification était elle-même construite à partir des coordonnées de l’ACP), leur accord ne prouverait rien de plus que la cohérence interne d’un même calcul répété deux fois. L’indépendance des deux démarches est ce qui donne à leur convergence une valeur de **confirmation** authentique.

Correction — Exercice 5

(a) Un exemple minuscule permet de dérouler **tous** les calculs (centrage, $X'X$, valeurs propres, valeurs singulières) à la main, sans qu’aucune étape ne reste une « boîte noire » confiée à un logiciel. On comprend ainsi ce que le logiciel fera ensuite sur le fichier réel, plutôt que de se contenter d’en lire les résultats.

(b) Des données choisies pour tomber juste (valeurs propres entières, sans décimale) permettent de vérifier chaque étape du calcul *sans calculatrice* et sans risquer de confondre une erreur de calcul avec un résultat correct mais peu lisible. Des données « réalistes », avec leurs décimales, rendraient cette vérification manuelle pénible et masqueraient la mécanique derrière l’arithmétique.

(c) Ce détour permet d’éviter de prendre les résultats d’un logiciel pour argent comptant sans pouvoir en repérer une éventuelle incohérence (unité mal choisie, variable non centrée, erreur de paramétrage) – ayant vu la mécanique sur un cas où l’on peut tout vérifier à la main, on sait ensuite reconnaître si un résultat produit sur les 300 clients « a du sens » ou trahit une erreur de spécification.