

Analyse des données avancée

Introduction : Reprendre l'analyse des données par l'algèbre

Jaouad Madkour

25 septembre 2026

Plan de l'introduction

Prérequis	1
Ce que ce cours suppose acquis	1
Ce que le cours établit lui-même	2
Avant de commencer	2
Ce que ce cours reprend, et pourquoi	2
Le problème, rappelé en une image	2
La place de l'analyse des données	3
Explorer et confirmer	3
Deux démarches, deux logiques	3
Ce que l'exploratoire n'autorise pas	3
La carte des méthodes	4
Les deux fils rouges	4
Trois cents clients, huit notes	4
Quatre individus, deux variables	4
Pourquoi ces valeurs précises	5
Ce qu'il faut retenir	5
Le résumé du chapitre	5

Prérequis

Ce que ce cours suppose acquis

Les cours qui précèdent

Introduction à l'analyse des données et Algèbre linéaire.

Les notions mobilisées

De l'analyse des données : la variable centrée réduite, la covariance, l'inertie, l'idée de l'ACP et de l'AFC.

De l'algèbre linéaire, cette fois exigée : la **diagonalisation** d'une matrice symétrique, les **formes quadratiques**, la **projection orthogonale**.

Ce que le cours établit lui-même

Repris depuis le début

La **décomposition en valeurs singulières** est établie dans le cours : elle n'est pas supposée connue.

Ce cours reprend l'intégralité de l'analyse des données, mais avec les démonstrations que la Licence avait admises. Il ne se contente pas d'ajouter des méthodes : il refait les premières autrement.

Avant de commencer

Ce que ce cours reprend, et pourquoi

Le même objet, un autre niveau

Le cours *Introduction à l'analyse des données*, en Licence, a montré **ce que font** les méthodes factorielles : réduire la dimension en perdant le moins d'information possible.


Ce cours reprend l'ensemble depuis le début pour montrer **pourquoi elles le font**, et **comment** — puis le prolonge jusqu'à la classification, la discrimination et le positionnement.

La différence tient en une phrase

En Licence, on a admis que les axes factoriels étaient les vecteurs propres d'une certaine matrice.

Ici, on le **démontre** — et l'on découvre au passage que l'analyse en composantes principales, l'analyse des correspondances et le positionnement multidimensionnel sont **le même calcul**, appliqué à trois métriques différentes.

Le problème, rappelé en une image




Et le problème n'est pas seulement le nombre de graphiques.

Vingt-huit nuages pris deux à deux ne montrent que des liaisons *par paires*. Une structure qui n'apparaît qu'en combinant quatre variables reste invisible sur les vingt-huit.


L'analyse des données ne fait pas plus de graphiques : elle en fait un seul, et le bon.

La place de l'analyse des données



Explorer et confirmer

Deux démarches, deux logiques



Ce que l'exploratoire n'autorise pas

Aucun test, aucune probabilité

Rien de ce cours n'est un test statistique. Il n'y a ni hypothèse nulle, ni p -valeur, ni intervalle de confiance.

Les méthodes décrivent **le tableau qu'on leur donne**. Elles ne disent rien d'une population dont ce tableau serait un échantillon.

La conséquence pratique, souvent oubliée

Un axe factoriel n'est pas « significatif ». Une segmentation n'est pas « vraie ». Ce sont des **résumés**, dont la seule justification est d'être **utiles et reproductibles**.

D'où la règle qui gouverne tout le cours : **une structure qu'une seule méthode voit n'est pas une structure**. On la confirmera par une seconde méthode, ou on ne la retiendra pas.

La carte des méthodes

	Variables quantitatives	Variables qualitatives
Décrire	ACP chapitres 5 à 8	AFC et ACM chapitres 9 à 11
Classer	CAH et <i>k-means</i> chapitres 12 à 15	les mêmes, après une AFC ou une ACM
Prédire	AFD chapitres 16 et 17	régression logistique <i>hors programme</i>

Une seule question commande le choix : quelle est la nature des variables, et que veut-on en faire ?
 Décrire un nuage, y former des groupes, ou séparer des groupes déjà connus. Les six méthodes du cours remplissent ce tableau — il n'y a pas d'autre case.

Les deux fils rouges

Trois cents clients, huit notes

Le fichier qui traverse tout le cours

Une enseigne interroge 300 clients. Chacun note **huit critères** de 0 à 20 : prix, choix, qualité, agencement, propreté, rapidité, conseil, accueil.

S'y ajoutent des variables **signalétiques** — sexe, âge, catégorie socioprofessionnelle, fréquence de visite, ancienneté, panier moyen, motif — qui ne serviront pas à construire les axes, mais à les interpréter.

Ce qu'on en attend

Aucune question n'est posée d'avance. On demande au tableau **ce qu'il contient**, et l'on verra qu'il contient deux choses seulement : un niveau général de satisfaction, et une opposition entre deux familles de critères.

Tout le reste — les $300 \times 8 = 2\,400$ nombres — est du détail individuel.

Quatre individus, deux variables

Le tableau qui se calcule à la main

Le fichier de 300 clients ne se diagonalise pas au tableau. Un second exemple, minuscule, servira à **écrire les calculs en entier** :

Individu	x_1	x_2
1	-2	-2
2	-1	1
3	1	-1
4	2	2

Les deux colonnes sont **déjà centrées** : leurs sommes valent zéro.

Pourquoi ces valeurs précises

Intuition

Elles ont été choisies pour que tout tombe juste. On verra apparaître $\mathbf{X}'\mathbf{X} = \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix}$, de valeurs propres 16 et 4, donc de **valeurs singulières 4 et 2**.
Aucune décimale, aucune calculatrice : c'est la seule façon de voir la mécanique.

Ce qu'il faut retenir

Le résumé du chapitre

Cinq points

1. Ce cours reprend l'analyse des données **depuis le début**, en donnant les démonstrations que la Licence avait admises.
2. La démarche est **exploratoire** : aucune hypothèse préalable, donc aucun test.
3. Une structure vue par une seule méthode ne se retient pas : **il faut la recouper**.
4. Deux fils rouges : 300 clients et 8 notes pour les résultats, 4 individus et 2 variables pour les calculs.
5. Le fichier des 300 clients est réel et fourni : **tous les chiffres du cours sont reproductibles**.

La suite

Avant de calculer quoi que ce soit, il faut dire précisément ce sur quoi l'on calcule : un tableau, des **poids** sur les lignes, une **métrique** sur les colonnes. C'est l'objet du chapitre 1, et c'est là que se jouent la plupart des choix qu'un logiciel fait à notre place.