

Chapitre 1

Le tableau, les poids et la métrique

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Correction — Exercice 1

(a) Moyenne brute = $\frac{25 + 32 + 40 + 55}{4} = \frac{152}{4} = 38$.

(b) $g = 0,35 \times 25 + 0,30 \times 32 + 0,20 \times 40 + 0,15 \times 55 = 8,75 + 9,6 + 8 + 8,25 = 34,6$.

(c) Le centre pondéré (34,6) est **inférieur** à la moyenne brute (38). C'est cohérent : le redressement relève le poids des ménages à **bas** revenu ($p_1 = 0,35$ pour le revenu le plus faible, contre 0,25 en poids uniforme) et abaisse celui des ménages à **haut** revenu ($p_4 = 0,15$ pour le revenu le plus élevé) – il est donc logique que la moyenne redressée soit tirée vers le bas par rapport à la moyenne brute.

Correction — Exercice 2

(a) $d_I^2(A, B) = (3600 - 1200)^2 + (12 - 15)^2 = 2400^2 + (-3)^2 = 5\,760\,000 + 9 = 5\,760\,009$.

(b) Part du panier : $\frac{5\,760\,000}{5\,760\,009} \approx 100,00\%$. Part de la note : $\frac{9}{5\,760\,009} \approx 0,00\%$.

(c) $d_M^2(A, B) = \left(\frac{2400}{850}\right)^2 + \left(\frac{-3}{2,5}\right)^2 \approx 2,824^2 + 1,2^2 \approx 7,972 + 1,44 \approx 9,412$. Part du panier : $\frac{7,972}{9,412} \approx$

84,7 %. Part de la note : $\frac{1,44}{9,412} \approx 15,3\%$. Avec $M = I$, la note de satisfaction ne pesait **rien** dans la distance (moins de 0,01 %) : deux clients à la note radicalement différente (15 contre 12) auraient été jugés « proches » dès lors que leur panier se ressemble. La métrique normée restitue à la note un poids substantiel (15,3 %), bien plus représentatif de son importance réelle dans le jugement de similarité entre clients.

Correction — Exercice 3

(a) Actives : ce sont les 8 notes de satisfaction qui définissent le « point de vue » de l'analyse – c'est leur structure que l'on cherche à décrire.

(b) Illustrative : l'objectif est d'expliquer la satisfaction *par* l'ancienneté, pas de faire construire les axes par l'ancienneté elle-même – elle doit donc être projetée après coup sur des axes bâtis sans elle.

(c) Si l'ancienneté participait à la construction des axes, retrouver ensuite qu'elle « explique » le premier axe reviendrait à constater ce qu'on y a soi-même mis dès le départ – une tautologie, et non un résultat. En la gardant illustrative, on construit les axes sur la seule satisfaction, puis on observe – ou non – que l'ancienneté s'y ordonne : c'est alors une découverte véritable, pas une évidence circulaire.


2 Exercices cumulatifs (introduction au chapitre 1)

Correction — Exercice 4

(a) $g_1 = \frac{1}{4}(-2 - 1 + 1 + 2) = \frac{1}{4}(0) = 0$. $g_2 = \frac{1}{4}(-2 + 1 - 1 + 2) = \frac{1}{4}(0) = 0$. On retrouve bien $g = (0, 0)$: les données de l'introduction sont effectivement déjà centrées sous poids uniformes.

(b) $g_1 = 0,4 \times (-2) + 0,3 \times (-1) + 0,2 \times (1) + 0,1 \times (2) = -0,8 - 0,3 + 0,2 + 0,2 = -0,7$. $g_2 = 0,4 \times (-2) + 0,3 \times (1) + 0,2 \times (-1) + 0,1 \times (2) = -0,8 + 0,3 - 0,2 + 0,2 = -0,5$. Nouveau centre : $g = (-0,7; -0,5)$.

(c) Il faudrait **recentrer** X en remplaçant chaque ligne x_i par $x_i - g$ (soit $X - 1g'$ avec ce nouveau $g = (-0,7, -0,5)$), avant de calculer $X'DX$ – c'est cette étape de centrage, rappelée au chapitre 1, qui garantit que les axes factoriels passeront par le centre de gravité *effectif* du nuage pondéré, et non par l'origine des données brutes.



3 Applications en sciences économiques

Correction — Exercice 5

(a) Un poids uniforme $p_i = 1/3$ donnerait à la région Sud (qui ne résume que 8 magasins) exactement le même poids qu'à la région Nord (qui en résume 45) : c'est précisément la situation « des données agrégées » mise en garde par le cours – « une ligne qui résume 40 magasins ne doit pas peser autant qu'une ligne qui en résume 2 ».

(b) Une pondération appropriée est proportionnelle au nombre de magasins résumés : $p_{\text{Nord}} = \frac{45}{68} \approx 0,662$, $p_{\text{Sud}} = \frac{8}{68} \approx 0,118$, $p_{\text{Est}} = \frac{15}{68} \approx 0,221$ (total = 68 magasins).

(c) Avec cette pondération, la région **Nord** pèsera le plus dans le calcul du centre de gravité (66,2 % du poids total), ce qui est cohérent avec le fait qu'elle résume, à elle seule, plus de magasins que les deux autres régions réunies.

Correction — Exercice 6

(a) Non : le chiffre d'affaires se compte en millions de dh, le taux de marge en points de pourcentage (de 2 à 18), la rotation des stocks en jours (de 10 à 90) – trois unités et trois ordres de grandeur totalement différents.

(b) Oui, l'analyste doit **normer** ($\mathbf{M} = \mathbf{D}_{1/s^2}$) : c'est exactement le cas visé par la règle du cours.

(c) Sans normalisation, le **chiffre d'affaires** dominerait presque certainement le premier axe : exprimé en millions de dh, sa variance brute est mécaniquement des ordres de grandeur plus élevée que celle d'un taux de marge en points ou d'une rotation en jours. Le résultat serait trompeur car il ne refléterait, en réalité, qu'un classement des entreprises par taille, et non par profil financier – et il changerait du tout au tout si l'on comptait le chiffre d'affaires en milliers de dh plutôt qu'en millions, ce qui, comme le rappelle le cours, signale qu'« un résultat qui dépend du choix de l'unité n'est pas un résultat ».