

Analyse des données avancée

Chapitre 1 : Le tableau, les poids et la métrique

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Un sondage redressé

Un institut interroge 4 ménages sur leur revenu mensuel (en k€) : 25, 32, 40, 55. Sachant que les hauts revenus sont sous-représentés dans l'échantillon, l'institut leur attribue des poids redressés $p = (0,35; 0,30; 0,20; 0,15)$ (qui somment bien à 1).

- (a) Calculer la moyenne **brute** (non pondérée) des quatre revenus.
- (b) Calculer le centre de gravité **pondéré** $g = \sum_i p_i x_i$.
- (c) Le centre pondéré est-il supérieur ou inférieur à la moyenne brute ? Ce résultat est-il cohérent avec le sens du redressement (sous-représentation des hauts revenus, donc poids relevés pour les bas revenus) ?

Exercice 2 — Pourquoi la métrique identité écrase un panier moyen

Deux clients sont décrits par leur panier moyen (en dh) et leur note de satisfaction (sur 20) : client A = (1200, 15), client B = (3600, 12). On donne les écarts-types sur l'ensemble du fichier : $s_{\text{panier}} = 850$, $s_{\text{note}} = 2,5$.

- (a) Calculer $d_I^2(A, B)$, la distance au carré avec la métrique identité $\mathbf{M} = \mathbf{I}$.
- (b) Calculer la part de cette distance imputable au panier, et celle imputable à la note.
- (c) Calculer $d_M^2(A, B)$ avec la métrique normée $\mathbf{M} = \mathbf{D}_{1/s^2} = \text{diag}(1/s_{\text{panier}}^2, 1/s_{\text{note}}^2)$, puis refaire le partage des contributions. Que révèle ce contraste sur le choix de $\mathbf{M} = \mathbf{I}$ ici ?

Exercice 3 — Choisir le statut d'une variable

Une enseigne veut savoir si l'ancienneté de ses clients « explique » leur niveau de satisfaction, mesuré par 8 notes de critères.

- (a) Les 8 notes de satisfaction doivent-elles être actives ou illustratives ? Justifier.
- (b) L'ancienneté doit-elle être active ou illustrative ? Justifier en particulier au regard de l'objectif de l'étude.
- (c) Un collègue propose d'inclure l'ancienneté parmi les variables actives, « pour qu'elle pèse davantage dans le résultat ». Pourquoi cette suggestion rendrait-elle la conclusion de l'étude circulaire ?

2 Exercices cumulatifs (introduction au chapitre 1)

Exercice 4 — Le centre de gravité du fil rouge, sous deux pondérations

On reprend le fil rouge de l'introduction : 4 individus, $x_1 = (-2, -1, 1, 2)$ et $x_2 = (-2, 1, -1, 2)$.

- (a) Avec des poids uniformes $p_i = 1/4$, calculer $g = (g_1, g_2) = (\sum_i p_i x_{i1}, \sum_i p_i x_{i2})$. Retrouve-t-on bien que les données sont déjà centrées, comme l'affirmait l'introduction ?
- (b) On attribue maintenant des poids non uniformes $p = (0,4; 0,3; 0,2; 0,1)$ (qui somment à 1) à ces mêmes quatre individus, sans changer $\mathbf{X}$. Calculer le nouveau centre de gravité g .
- (c) Ce nouveau centre n'est plus (0,0). D'après le cours, que faudrait-il faire à $\mathbf{X}$ avant de calculer $\mathbf{X}'\mathbf{D}\mathbf{X}$ pour que les axes factoriels passent bien par ce nouveau centre de gravité ?

3 Applications en sciences économiques

Exercice 5 — Agréger sans écraser

Une chaîne de distribution dispose de résultats agrégés par région : la région Nord résume 45 magasins, la région Sud 8 magasins, la région Est 15 magasins.

- (a) Si l'analyse traite les trois régions avec un poids uniforme $p_i = 1/3$, quel problème méthodologique cela pose-t-il, d'après le cours ?
- (b) Proposer une pondération D plus appropriée pour ces trois lignes.
- (c) Avec cette nouvelle pondération, quelle région pèsera le plus dans le calcul du centre de gravité du nuage des régions ?

Exercice 6 — Normer un bilan financier ou non

Un analyste construit une ACP sur des ratios financiers d'entreprises : chiffre d'affaires (en millions de dh, très dispersé), taux de marge (en %, entre 2 et 18), et rotation des stocks (en jours, entre 10 et 90).

- (a) Ces trois variables ont-elles la même unité et le même ordre de grandeur de dispersion ?
- (b) D'après la règle du cours (« on norme dès que les variables n'ont pas la même unité »), l'analyste doit-il normer ?
- (c) Si l'analyste ne normait pas, quelle variable dominerait presque certainement le premier axe, et pourquoi ce résultat serait-il trompeur ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Moyenne brute = $\frac{25 + 32 + 40 + 55}{4} = \frac{152}{4} = 38$.
- (b) $g = 0,35 \times 25 + 0,30 \times 32 + 0,20 \times 40 + 0,15 \times 55 = 8,75 + 9,6 + 8 + 8,25 = 34,6$.
- (c) Le centre pondéré (34,6) est **inférieur** à la moyenne brute (38). C'est cohérent : le redressement relève le poids des ménages à **bas** revenu ($p_1 = 0,35$ pour le revenu le plus faible, contre 0,25 en poids uniforme) et abaisse celui des ménages à **haut** revenu ($p_4 = 0,15$ pour le revenu le plus élevé) – il est donc logique que la moyenne redressée soit tirée vers le bas par rapport à la moyenne brute.

Correction — Exercice 2

- (a) $d_I^2(A, B) = (3600 - 1200)^2 + (12 - 15)^2 = 2400^2 + (-3)^2 = 5\,760\,000 + 9 = 5\,760\,009$.
- (b) Part du panier : $\frac{5\,760\,000}{5\,760\,009} \approx 100,00\%$. Part de la note : $\frac{9}{5\,760\,009} \approx 0,00\%$.
- (c) $d_M^2(A, B) = \left(\frac{2400}{850}\right)^2 + \left(\frac{-3}{2,5}\right)^2 \approx 2,824^2 + 1,2^2 \approx 7,972 + 1,44 \approx 9,412$. Part du panier : $\frac{7,972}{9,412} \approx 84,7\%$. Part de la note : $\frac{1,44}{9,412} \approx 15,3\%$. Avec $M = I$, la note de satisfaction ne pesait **rien** dans la distance (moins de 0,01 %) : deux clients à la note radicalement différente (15 contre 12) auraient été jugés « proches » dès lors que leur panier se ressemble. La métrique normée restitue à la note un poids substantiel (15,3 %), bien plus représentatif de son importance réelle dans le jugement de similarité entre clients.


Correction — Exercice 3

- (a) Actives : ce sont les 8 notes de satisfaction qui définissent le « point de vue » de l'analyse – c'est leur structure que l'on cherche à décrire.
- (b) Illustrative : l'objectif est d'expliquer la satisfaction *par* l'ancienneté, pas de faire construire les axes par l'ancienneté elle-même – elle doit donc être projetée après coup sur des axes bâtis sans elle.
- (c) Si l'ancienneté participait à la construction des axes, retrouver ensuite qu'elle « explique » le premier axe reviendrait à constater ce qu'on y a soi-même mis dès le départ – une tautologie, et non un résultat. En la gardant illustrative, on construit les axes sur la seule satisfaction, puis on observe – ou non – que l'ancienneté s'y ordonne : c'est alors une découverte véritable, pas une évidence circulaire.

2 Exercices cumulatifs (introduction au chapitre 1)

Correction — Exercice 4

- (a) $g_1 = \frac{1}{4}(-2 - 1 + 1 + 2) = \frac{1}{4}(0) = 0$. $g_2 = \frac{1}{4}(-2 + 1 - 1 + 2) = \frac{1}{4}(0) = 0$. On retrouve bien $g = (0, 0)$: les données de l'introduction sont effectivement déjà centrées sous poids uniformes.
- (b) $g_1 = 0,4 \times (-2) + 0,3 \times (-1) + 0,2 \times (1) + 0,1 \times (2) = -0,8 - 0,3 + 0,2 + 0,2 = -0,7$. $g_2 = 0,4 \times (-2) + 0,3 \times (1) + 0,2 \times (-1) + 0,1 \times (2) = -0,8 + 0,3 - 0,2 + 0,2 = -0,5$. Nouveau centre : $g = (-0,7; -0,5)$.
- (c) Il faudrait **recentrer** X en remplaçant chaque ligne x_i par $x_i - g$ (soit $X - 1g'$ avec ce nouveau $g = (-0,7, -0,5)$), avant de calculer $X'DX$ – c'est cette étape de centrage, rappelée au chapitre 1, qui garantit que les axes factoriels passeront par le centre de gravité *effectif* du nuage pondéré, et non par l'origine des données brutes.



3 Applications en sciences économiques

Correction — Exercice 5

(a) Un poids uniforme $p_i = 1/3$ donnerait à la région Sud (qui ne résume que 8 magasins) exactement le même poids qu'à la région Nord (qui en résume 45) : c'est précisément la situation « des données agrégées » mise en garde par le cours – « une ligne qui résume 40 magasins ne doit pas peser autant qu'une ligne qui en résume 2 ».

(b) Une pondération appropriée est proportionnelle au nombre de magasins résumés : $p_{\text{Nord}} = \frac{45}{68} \approx 0,662$, $p_{\text{Sud}} = \frac{8}{68} \approx 0,118$, $p_{\text{Est}} = \frac{15}{68} \approx 0,221$ (total = 68 magasins).

(c) Avec cette pondération, la région **Nord** pèsera le plus dans le calcul du centre de gravité (66,2 % du poids total), ce qui est cohérent avec le fait qu'elle résume, à elle seule, plus de magasins que les deux autres régions réunies.

Correction — Exercice 6

(a) Non : le chiffre d'affaires se compte en millions de dh, le taux de marge en points de pourcentage (de 2 à 18), la rotation des stocks en jours (de 10 à 90) – trois unités et trois ordres de grandeur totalement différents.

(b) Oui, l'analyste doit **normer** ($\mathbf{M} = \mathbf{D}_{1/s^2}$) : c'est exactement le cas visé par la règle du cours.

(c) Sans normalisation, le **chiffre d'affaires** dominerait presque certainement le premier axe : exprimé en millions de dh, sa variance brute est mécaniquement des ordres de grandeur plus élevée que celle d'un taux de marge en points ou d'une rotation en jours. Le résultat serait trompeur car il ne refléterait, en réalité, qu'un classement des entreprises par taille, et non par profil financier – et il changerait du tout au tout si l'on comptait le chiffre d'affaires en milliers de dh plutôt qu'en millions, ce qui, comme le rappelle le cours, signale qu'« un résultat qui dépend du choix de l'unité n'est pas un résultat ».