

Chapitre 1

Le tableau, les poids et la métrique

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse de données avancée

1 Exercices du chapitre

Exercice 1 — Un sondage redressé

Un institut interroge 4 ménages sur leur revenu mensuel (en k€) : 25, 32, 40, 55. Sachant que les hauts revenus sont sous-représentés dans l'échantillon, l'institut leur attribue des poids redressés $p = (0,35; 0,30; 0,20; 0,15)$ (qui somment bien à 1).

- Calculer la moyenne **brute** (non pondérée) des quatre revenus.
- Calculer le centre de gravité **pondéré** $g = \sum_i p_i x_i$.
- Le centre pondéré est-il supérieur ou inférieur à la moyenne brute ? Ce résultat est-il cohérent avec le sens du redressement (sous-représentation des hauts revenus, donc poids relevés pour les bas revenus) ?

Exercice 2 — Pourquoi la métrique identité écrase un panier moyen

Deux clients sont décrits par leur panier moyen (en dh) et leur note de satisfaction (sur 20) : client A = (1200, 15), client B = (3600, 12). On donne les écarts-types sur l'ensemble du fichier : $s_{\text{panier}} = 850$, $s_{\text{note}} = 2,5$.

- Calculer $d_I^2(A, B)$, la distance au carré avec la métrique identité $\mathbf{M} = \mathbf{I}$.
- Calculer la part de cette distance imputable au panier, et celle imputable à la note.
- Calculer $d_M^2(A, B)$ avec la métrique normée $\mathbf{M} = \mathbf{D}_{1/s^2} = \text{diag}(1/s_{\text{panier}}^2, 1/s_{\text{note}}^2)$, puis refaire le partage des contributions. Que révèle ce contraste sur le choix de $\mathbf{M} = \mathbf{I}$ ici ?

Exercice 3 — Choisir le statut d'une variable

Une enseigne veut savoir si l'ancienneté de ses clients « explique » leur niveau de satisfaction, mesuré par 8 notes de critères.

- Les 8 notes de satisfaction doivent-elles être actives ou illustratives ? Justifier.
- L'ancienneté doit-elle être active ou illustrative ? Justifier en particulier au regard de l'objectif de l'étude.
- Un collègue propose d'inclure l'ancienneté parmi les variables actives, « pour qu'elle pèse davantage dans le résultat ». Pourquoi cette suggestion rendrait-elle la conclusion de l'étude circulaire ?

2 Exercices cumulatifs (introduction au chapitre 1)

Exercice 4 — Le centre de gravité du fil rouge, sous deux pondérations

On reprend le fil rouge de l'introduction : 4 individus, $x_1 = (-2, -1, 1, 2)$ et $x_2 = (-2, 1, -1, 2)$.

- Avec des poids uniformes $p_i = 1/4$, calculer $g = (g_1, g_2) = (\sum_i p_i x_{i1}, \sum_i p_i x_{i2})$. Retrouve-t-on bien que les données sont déjà centrées, comme l'affirmait l'introduction ?
- On attribue maintenant des poids non uniformes $p = (0,4; 0,3; 0,2; 0,1)$ (qui somment à 1) à ces mêmes quatre individus, sans changer $\mathbf{X}$. Calculer le nouveau centre de gravité g .
- Ce nouveau centre n'est plus (0,0). D'après le cours, que faudrait-il faire à $\mathbf{X}$ avant de calculer $\mathbf{X}'\mathbf{D}\mathbf{X}$ pour que les axes factoriels passent bien par ce nouveau centre de gravité ?

3 Applications en sciences économiques

Exercice 5 — Agréger sans écraser

Une chaîne de distribution dispose de résultats agrégés par région : la région Nord résume 45 magasins, la région Sud 8 magasins, la région Est 15 magasins.

- (a) Si l'analyse traite les trois régions avec un poids uniforme $p_i = 1/3$, quel problème méthodologique cela pose-t-il, d'après le cours ?
- (b) Proposer une pondération D plus appropriée pour ces trois lignes.
- (c) Avec cette nouvelle pondération, quelle région pèsera le plus dans le calcul du centre de gravité du nuage des régions ?

Exercice 6 — Normer un bilan financier ou non

Un analyste construit une ACP sur des ratios financiers d'entreprises : chiffre d'affaires (en millions de dh, très dispersé), taux de marge (en %, entre 2 et 18), et rotation des stocks (en jours, entre 10 et 90).

- (a) Ces trois variables ont-elles la même unité et le même ordre de grandeur de dispersion ?
- (b) D'après la règle du cours (« on norme dès que les variables n'ont pas la même unité »), l'analyste doit-il normer ?
- (c) Si l'analyste ne normait pas, quelle variable dominerait presque certainement le premier axe, et pourquoi ce résultat serait-il trompeur ?