

Analyse des données avancée

Chapitre 3 : Diagonalisation et décomposition en valeurs singulières

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Analyse des données avancée

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Diagonaliser une matrice symétrique à la main

On considère $\mathbf{A} = \begin{pmatrix} 13 & 5 \\ 5 & 13 \end{pmatrix}$.

- (a) Écrire le polynôme caractéristique sous la forme $(13 - \lambda)^2 - 25 = 0$ et le résoudre.
- (b) Donner les deux vecteurs propres associés (on admettra qu'ils sont, comme pour toute matrice de cette forme, les deux bissectrices).
- (c) Vérifier que $\lambda_1 + \lambda_2 = \text{trace}(\mathbf{A})$ et $\lambda_1 \lambda_2 = \det(\mathbf{A})$.

Exercice 2 — Une valeur propre nulle signale une redondance

Un tableau à 3 variables centrées est construit ainsi : $x_3 = 2x_1$ exactement (la troisième variable est le double de la première pour chaque individu).

- (a) Pourquoi $\mathbf{a} = (2, 0, -1)'$ donne-t-il $\mathbf{X}\mathbf{a} = \mathbf{0}$ pour tout individu de ce tableau ?
- (b) En déduire que $\mathbf{a}'\mathbf{V}\mathbf{a} = 0$ pour ce vecteur $\mathbf{a}$ particulier, sachant que $\mathbf{a}'\mathbf{V}\mathbf{a}$ est la variance de $\mathbf{X}\mathbf{a}$.
- (c) Que peut-on en conclure sur les valeurs propres de $\mathbf{V}$, et sur le « vrai » nombre de dimensions utiles de ce tableau à 3 variables ?

Exercice 3 — Eckart et Young sur un spectre à six valeurs propres

Un tableau réduit à $p = 6$ variables a pour valeurs propres 3,1, 1,4, 0,6, 0,4, 0,3, 0,2.

- (a) Calculer l'inertie retenue par la meilleure approximation de rang 2, $\mathbf{X}_{(2)}$.
- (b) Calculer, en pourcentage, l'inertie ainsi conservée.
- (c) Calculer l'erreur d'approximation $\|\mathbf{X} - \mathbf{X}_{(2)}\|^2$ d'après le théorème d'Eckart et Young. En quel sens peut-on affirmer qu'**aucune** autre matrice de rang 2 ne ferait mieux ?

2 Exercices cumulatifs (introduction au chapitre 3)

Exercice 4 — Diagonaliser et vérifier le fil rouge en entier

On reprend le fil rouge : $\mathbf{X} = \begin{pmatrix} -2 & -2 \\ -1 & 1 \\ 1 & -1 \\ 2 & 2 \end{pmatrix}$, $\mathbf{X}'\mathbf{X} = \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix}$, de valeurs propres 16 et 4 (introduction),

et de vecteur propre $\mathbf{u}_1 = \mathbf{v}_1 = (1, 1)'/\sqrt{2}$ associé à $\lambda_1 = 16$ (cours).

- (a) Vérifier que $\mathbf{X}'\mathbf{X}\mathbf{v}_1 = 16\mathbf{v}_1$ (calculer $\mathbf{X}'\mathbf{X}\mathbf{v}_1$ terme à terme et comparer à $16\mathbf{v}_1$).
- (b) Calculer $\mathbf{X}\mathbf{v}_1$ (un vecteur à 4 coordonnées), puis $\mathbf{u}_1 = \mathbf{X}\mathbf{v}_1/\sigma_1$ avec $\sigma_1 = \sqrt{16} = 4$.
- (c) Calculer $\sum_i (\mathbf{X}\mathbf{v}_1)_i^2$ et vérifier qu'on retrouve bien $\lambda_1 = 16$, conformément au « contrôle à faire sur toute sortie de logiciel » rappelé par le cours.

3 Applications en sciences économiques

Exercice 5 — Combien de facteurs retenir dans un tableau de bord

Une direction financière suit $p = 6$ indicateurs réduits, de valeurs propres 3,1, 1,4, 0,6, 0,4, 0,3, 0,2 (mêmes valeurs qu'à l'exercice 3).

- (a) Si la direction ne veut retenir que 2 facteurs de synthèse, quelle proportion de l'inertie totale ces 2 facteurs conservent-ils ?
- (b) D'après Eckart et Young, existe-t-il une autre façon de choisir 2 combinaisons linéaires des 6 indicateurs qui conserverait **davantage** d'inertie ?
- (c) Formuler, en une phrase, ce que le théorème d'Eckart et Young garantit à la direction financière lorsqu'elle décide de ne suivre que 2 facteurs de synthèse plutôt que les 6 indicateurs bruts.

Exercice 6 — Pourquoi la dualité simplifie le calcul en pratique

Une enseigne dispose d'un fichier de $n = 800$ magasins décrits par $p = 6$ indicateurs de performance réduits.

- (a) $\mathbf{X}'\mathbf{X}$ (nuage des variables) et $\mathbf{X}\mathbf{X}'$ (nuage des magasins) sont-elles de la même taille ? Donner la taille de chacune.
- (b) D'après la dualité du cours, ces deux matrices ont-elles les mêmes valeurs propres non nulles ?
- (c) En pratique, quelle matrice est-il préférable de diagonaliser pour obtenir les axes factoriels le plus rapidement, et pourquoi le résultat sur l'inertie expliquée sera-t-il rigoureusement le même quel que soit le choix ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $(13 - \lambda)^2 - 25 = 0 \Leftrightarrow 13 - \lambda = \pm 5$, donc $\lambda_1 = 18$ et $\lambda_2 = 8$.
- (b) $\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ (associé à $\lambda_1 = 18$), $\mathbf{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$ (associé à $\lambda_2 = 8$).
- (c) $\lambda_1 + \lambda_2 = 18 + 8 = 26 = \text{trace}(\mathbf{A}) = 13 + 13$. $\lambda_1 \lambda_2 = 18 \times 8 = 144 = \det(\mathbf{A}) = 13 \times 13 - 5 \times 5 = 169 - 25 = 144$. Les deux vérifications concordent.

Correction — Exercice 2

- (a) $(\mathbf{Xa})_i = 2x_{i1} + 0 \times x_{i2} - x_{i3} = 2x_{i1} - x_{i3}$. Or $x_{i3} = 2x_{i1}$ pour tout individu, donc $(\mathbf{Xa})_i = 2x_{i1} - 2x_{i1} = 0$ pour chaque i : $\mathbf{Xa} = \mathbf{0}$.
- (b) $\mathbf{a}'\mathbf{Va}$ est, par définition, la variance de la nouvelle variable $\mathbf{Xa}$. Puisque $\mathbf{Xa} = \mathbf{0}$ pour tous les individus, cette « variable » est identiquement nulle, donc de variance nulle : $\mathbf{a}'\mathbf{Va} = 0$.
- (c) L'existence d'un vecteur $\mathbf{a} \neq \mathbf{0}$ tel que $\mathbf{a}'\mathbf{Va} = 0$ signifie que $\mathbf{V}$ possède une valeur propre **nulle** (associée à ce même $\mathbf{a}$, à normalisation près) : c'est exactement le cas décrit par le cours, « une valeur propre nulle signale une variable redondante ». Bien que le tableau comporte 3 colonnes, il ne contient en réalité que 2 dimensions d'information utile – x_3 n'ajoutant rien que x_1 ne dise déjà.


Correction — Exercice 3

- (a) Inertie retenue = $3,1 + 1,4 = 4,5$.
- (b) $\frac{4,5}{6} = 75\%$.
- (c) Erreur = $0,6 + 0,4 + 0,3 + 0,2 = 1,5$. Le théorème d'Eckart et Young garantit que $\mathbf{X}_{(2)}$, construite à partir des deux premiers vecteurs singuliers, est la matrice de rang 2 qui minimise $\|\mathbf{X} - \mathbf{B}\|^2$ **parmi toutes les matrices de rang 2 possibles** – ce n'est donc pas une bonne approximation parmi d'autres, mais *la meilleure*, au sens le plus strict.

2 Exercices cumulatifs (introduction au chapitre 3)

Correction — Exercice 4

- (a) $\mathbf{X}'\mathbf{X}\mathbf{v}_1 = \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 16 \\ 16 \end{pmatrix} = 16 \times \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 16 \mathbf{v}_1$. Vérifié.
- (b) $\mathbf{X}\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} -2-2 \\ -1+1 \\ 1-1 \\ 2+2 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} -4 \\ 0 \\ 0 \\ 4 \end{pmatrix} \approx \begin{pmatrix} -2,828 \\ 0 \\ 0 \\ 2,828 \end{pmatrix}$. $\mathbf{u}_1 = \frac{\mathbf{X}\mathbf{v}_1}{4} \approx \begin{pmatrix} -0,707 \\ 0 \\ 0 \\ 0,707 \end{pmatrix}$.
- (c) $\sum_i (\mathbf{X}\mathbf{v}_1)_i^2 = (-2,828)^2 + 0^2 + 0^2 + 2,828^2 \approx 8 + 0 + 0 + 8 = 16$. On retrouve exactement $\lambda_1 = 16$: le contrôle est vérifié.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $\frac{3,1 + 1,4}{6} = \frac{4,5}{6} = 75\%$.

(b) Non : d'après Eckart et Young, ces 2 facteurs de synthèse (construits à partir des deux premiers vecteurs singuliers) forment, parmi **toutes** les combinaisons possibles de 2 facteurs, celle qui conserve le **maximum** d'inertie – aucune autre paire de combinaisons linéaires des 6 indicateurs ne peut faire mieux que ces 75 %.

(c) Le théorème garantit à la direction que ces 2 facteurs constituent le **meilleur résumé possible** en 2 dimensions de l'information contenue dans les 6 indicateurs – ce n'est pas une simplification parmi d'autres, c'est la simplification optimale, et l'écart qu'elle introduit (25 % d'inertie non conservée) est connu et quantifié à l'avance.

Correction — Exercice 6

(a) Non : $\mathbf{X}'\mathbf{X}$ (nuage des variables) est 6×6 , tandis que $\mathbf{X}\mathbf{X}'$ (nuage des magasins) est 800×800 – des tailles radicalement différentes.

(b) Oui : d'après la dualité, $\mathbf{X}'\mathbf{X}$ et $\mathbf{X}\mathbf{X}'$ ont exactement les mêmes valeurs propres non nulles (les σ_k^2), malgré leurs tailles différentes.

(c) Il est bien plus efficace de diagonaliser $\mathbf{X}'\mathbf{X}$, la matrice 6×6 (nuage des variables), plutôt que $\mathbf{X}\mathbf{X}'$, la matrice 800×800 (nuage des magasins) – un calcul très nettement plus rapide. Le résultat sur l'inertie expliquée sera rigoureusement identique quel que soit le choix, puisque les deux matrices partagent exactement les mêmes valeurs propres non nulles : ce n'est pas une approximation, c'est une conséquence directe de la décomposition en valeurs singulières de $\mathbf{X}$.