

Analyse des données avancée

Chapitre 3 : Diagonalisation et décomposition en valeurs singulières

Jaouad Madkour

25 septembre 2026

Plan du chapitre

Diagonaliser une symétrique	1
Le théorème spectral	1
Semi-définie positive	2
Le petit tableau, diagonalisé en entier	2
Les vecteurs propres	2
Ce que les deux directions disent déjà	3
Décomposition en valeurs	3
Ce que la diagonalisation ne sait pas faire	3
Le lien avec les deux diagonalisations	3
La décomposition du petit tableau	4
La vérification qui ne trompe pas	4
Approcher un tableau simplifié	4
Le théorème d'Eckart et Young	4
Sur nos données	5
Ce qu'il faut retenir	5
Le résumé du chapitre	5

Diagonaliser une symétrique

Le théorème spectral

L'énoncé

Toute matrice **symétrique réelle** $\mathbf{A}$ d'ordre p s'écrit

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}', \quad \mathbf{U}'\mathbf{U} = \mathbf{I}$$

avec $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p)$ réelle. Les colonnes de $\mathbf{U}$ sont **orthonormées**.

Ce que le théorème promet, et qui n'allait pas de soi

Trois choses, dont aucune n'est vraie pour une matrice quelconque : les valeurs propres sont **réelles**, il y en a **toujours** p , et les vecteurs propres sont **orthogonaux**.
C'est cette orthogonalité qui donnera aux axes factoriels leur propriété la plus utile : **le deuxième axe n'a rien à ajouter à ce que le premier a dit**.

Semi-définie positive

Le cas qui nous concerne

Une matrice de variance-covariance $\mathbf{V} = \mathbf{X}'\mathbf{D}\mathbf{X}$ est **symétrique semi-définie positive** :

$$\mathbf{a}'\mathbf{V}\mathbf{a} = \sum_i p_i (\mathbf{x}'_i \mathbf{a})^2 \geq 0 \quad \text{pour tout } \mathbf{a}$$

Ses valeurs propres sont donc **toutes positives ou nulles**.

La lecture statistique

$\mathbf{a}'\mathbf{V}\mathbf{a}$ est la **variance de la combinaison linéaire** $\mathbf{X}\mathbf{a}$. Une variance ne peut pas être négative : la positivité n'est pas un détail technique, c'est la même chose dite en algèbre.
Une valeur propre nulle signale une **variable redondante** — une colonne combinaison exacte des autres.

Le petit tableau, diagonalisé en entier

La matrice

$$\mathbf{A} = \mathbf{X}'\mathbf{X} = \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix}$$

Le polynôme caractéristique :

$$(10 - \lambda)^2 - 36 = 0 \iff 10 - \lambda = \pm 6$$

$$\lambda_1 = 16, \quad \lambda_2 = 4$$

Les vecteurs propres

Exemple

Pour $\lambda_1 = 16$: $-6a_1 + 6a_2 = 0$, donc $a_1 = a_2$.

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mathbf{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

Vérifications : $\mathbf{u}'_1 \mathbf{u}_2 = 0$, $\lambda_1 + \lambda_2 = 20 = \text{trace}(\mathbf{A})$, $\lambda_1 \lambda_2 = 64 = \det(\mathbf{A})$.

Ce que les deux directions disent déjà

Intuition

$\mathbf{u}_1$ est la **bissectrice** : la direction où les deux variables varient ensemble. Elle porte $16/20 = 80\%$ de l'information.

$\mathbf{u}_2$ est la direction où elles s'opposent. Sans avoir prononcé le mot ACP, on vient de la faire.

Décomposition en valeurs

Ce que la diagonalisation ne sait pas faire

Le problème

$\mathbf{X}$ est $n \times p$ — **rectangulaire**. Elle n'a ni valeurs propres, ni vecteurs propres.

On peut diagonaliser $\mathbf{X}'\mathbf{X}$, qui est $p \times p$, ou $\mathbf{X}\mathbf{X}'$, qui est $n \times n$ — mais rien ne dit encore comment les deux se relient.

La décomposition en valeurs singulières

Toute matrice $\mathbf{X}$ de rang r s'écrit

$$\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}'$$

- $\mathbf{U}$, $n \times r$, colonnes orthonormées — les vecteurs singuliers à **gauche** ;
- $\mathbf{V}$, $p \times r$, colonnes orthonormées — les vecteurs singuliers à **droite** ;
- $\Sigma = \text{diag}(\sigma_1 \geq \dots \geq \sigma_r > 0)$, les **valeurs singulières**.

Le lien avec les deux diagonalisations

Les trois identités

$$\mathbf{X}'\mathbf{X} = \mathbf{V}\Sigma^2\mathbf{V}' \qquad \mathbf{X}\mathbf{X}' = \mathbf{U}\Sigma^2\mathbf{U}'$$

$$\mathbf{X}\mathbf{v}_k = \sigma_k \mathbf{u}_k \qquad \mathbf{X}'\mathbf{u}_k = \sigma_k \mathbf{v}_k$$

Le résultat qui va tout gouverner

$\mathbf{X}'\mathbf{X}$ et $\mathbf{X}\mathbf{X}'$ n'ont pas la même taille, mais **exactement les mêmes valeurs propres non nulles** : les σ_k^2 .

C'est la **dualité**. Analyser le nuage des individus ou celui des variables donnera les mêmes valeurs propres — non par coïncidence, mais parce que ce sont les deux faces d'une seule décomposition. Le chapitre 5 en tire toutes les conséquences.

La décomposition du petit tableau

Les valeurs singulières

$\mathbf{X}'\mathbf{X}$ a pour valeurs propres 16 et 4, donc

$$\sigma_1 = \sqrt{16} = 4, \quad \sigma_2 = \sqrt{4} = 2$$

Les vecteurs à gauche, par $\mathbf{X}\mathbf{v}_k = \sigma_k \mathbf{u}_k$

$$\mathbf{X}\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} -4 \\ 0 \\ 0 \\ 4 \end{pmatrix} \Rightarrow \mathbf{u}_1 = \frac{\mathbf{X}\mathbf{v}_1}{\sigma_1} = \frac{1}{4\sqrt{2}} \begin{pmatrix} -4 \\ 0 \\ 0 \\ 4 \end{pmatrix} = \begin{pmatrix} -0,707 \\ 0 \\ 0 \\ 0,707 \end{pmatrix}$$

Les individus 2 et 3 ont une coordonnée **nulle** sur le premier axe : ils sont exactement sur le second.

La vérification qui ne trompe pas

Intuition

$$\sum_i (\mathbf{X}\mathbf{v}_1)_i^2 = \frac{16 + 0 + 0 + 16}{2} = 16 = \lambda_1$$

La somme des carrés des coordonnées sur un axe est sa valeur propre. C'est le contrôle à faire sur toute sortie de logiciel.

Approcher un tableau simplifié

Le théorème d'Eckart et Young

La meilleure approximation de rang k

$$\mathbf{X}_{(k)} = \sum_{m=1}^k \sigma_m \mathbf{u}_m \mathbf{v}_m'$$

est, parmi **toutes** les matrices de rang k , celle qui minimise $\|\mathbf{X} - \mathbf{B}\|^2$.

L'erreur commise vaut $\sigma_{k+1}^2 + \dots + \sigma_r^2$.

Pourquoi ce théorème est le vrai fondement du cours

Il ne dit pas seulement que la solution factorielle est bonne : il dit qu'**aucune autre méthode ne peut faire mieux**, à rang égal.

Retenir deux axes, c'est remplacer un tableau 300×8 par le meilleur tableau de rang 2 qui existe. Et l'erreur est **connue d'avance** : la somme des valeurs propres abandonnées.

Sur nos données

Le coût du résumé

$$\lambda_1 + \lambda_2 = 4,535 + 1,645 = 6,180 \quad \text{sur } 8$$

Le plan retient 77,3 % de l'inertie ; l'erreur d'approximation est

$$0,382 + 0,349 + 0,327 + 0,283 + 0,249 + 0,229 = 1,820$$

Ce que cela veut dire pour l'enseigne

Deux nombres par client — au lieu de huit — restituent plus des trois quarts de ce que le questionnaire contenait.

Le quart perdu n'est pas du signal : ce sont six valeurs propres presque égales, entre 0,23 et 0,38, c'est-à-dire **la signature du bruit**. Le chapitre 6 en fait un critère.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Une matrice **symétrique réelle** se diagonalise en base orthonormée, à valeurs propres réelles.
2. Une matrice de variance-covariance est **semi-définie positive** : ses valeurs propres sont positives.
3. Toute matrice rectangulaire admet une **décomposition en valeurs singulières** $\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}'$.
4. $\mathbf{X}'\mathbf{X}$ et $\mathbf{X}\mathbf{X}'$ ont les **mêmes valeurs propres non nulles** — c'est la dualité.
5. $\mathbf{X}\mathbf{v}_k = \sigma_k \mathbf{u}_k$: la relation qui fera passer des variables aux individus.
6. **Eckart et Young** : la troncature de la décomposition est la meilleure approximation de rang donné, et l'erreur vaut la somme des valeurs propres écartées.

La suite

L'outil est en place. Le chapitre 4 pose le problème de l'ACP et le résout — en trois lignes, désormais.