

# Analyse des données avancée

## Chapitre 12 : Distances et dissimilarités



---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 août 2026

Que veut dire « se ressembler »


Ce qu'une distance doit vérifier

Classer sur les axes factoriels

Ce qu'il faut retenir

Que veut dire « se ressembler »

---



## Une question qui paraît simple

Le directeur commercial demande : « regroupez-moi les clients qui se ressemblent ».

**Se ressemblent selon quoi ?** Selon leurs notes, selon leur panier, selon leur fréquence de visite ? Et si l'on prend les notes, faut-il compter la propreté autant que le prix ?

## Ce que la classification exige, et l'ACP n'exigeait pas

L'ACP se contentait des données : la géométrie découlait des corrélations.

**La classification exige une décision préalable** : celle d'une distance. Aucun algorithme ne la choisira à votre place, et le résultat en dépend entièrement.

| Distance    | Formule                                                                                 | Quand l'employer                    |
|-------------|-----------------------------------------------------------------------------------------|-------------------------------------|
| Euclidienne | $\sqrt{\sum_j (x_{ij} - x_{i'j})^2}$                                                    | variables quantitatives réduites    |
| Manhattan   | $\sum_j  x_{ij} - x_{i'j} $                                                             | si l'on craint les valeurs extrêmes |
| du $\chi^2$ | $\sum_j \frac{1}{c_j} \left( \frac{n_{ij}}{n_{i.}} - \frac{n_{i'j}}{n_{i'.}} \right)^2$ | profils, tableaux de contingence    |
| de Jaccard  | $1 - \frac{ A \cap B }{ A \cup B }$                                                     | présence / absence, paniers d'achat |

**Le choix de la distance précède le choix de la méthode — et pèse davantage.**

Deux clients « proches » ne le sont que pour une distance donnée. Sur des variables non réduites, l'euclidienne classe selon la variable la plus dispersée : **centrer et réduire est une décision, pas une formalité.**

La distance du  $\chi^2$  a une propriété que les autres n'ont pas — *l'équivalence distributionnelle* : regrouper deux colonnes de profils identiques ne change rien au résultat. C'est ce qui fait d'elle la distance des tableaux de contingence.

La distance de Jaccard ignore les doubles absences : deux clients qui n'ont acheté *ni* l'un *ni* l'autre produit ne se ressemblent pas pour autant.

Ce qu'une distance doit vérifier

---

### Distance et dissimilarité

Une **distance** vérifie :  $d(i, i) = 0$ ,  $d(i, j) = d(j, i)$ , et l'inégalité triangulaire  $d(i, k) \leq d(i, j) + d(j, k)$ .

Une **dissimilarité** ne vérifie que les deux premières.

### Pourquoi la nuance compte au chapitre 18

Quand on demande à un client « ces deux enseignes se ressemblent-elles ? », rien ne garantit l'inégalité triangulaire : il peut juger  $A$  proche de  $B$ ,  $B$  proche de  $C$ , et  $A$  très loin de  $C$ .

**Les jugements humains ne forment pas une distance.** C'est précisément pour cela que le positionnement multidimensionnel existe : il cherche la carte qui approche au mieux des dissimilarités qui n'en sont pas.



### Notre fichier mélange les deux natures

Huit notes quantitatives, cinq variables qualitatives. Aucune distance usuelle ne les traite ensemble.

Trois solutions, par ordre de préférence croissante : **découper les notes en tranches** et tout traiter en qualitatif; utiliser un **indice mixte** comme celui de Gower; ou **faire une analyse factorielle d'abord** et classer sur les coordonnées obtenues.

### La troisième est la bonne, et c'est celle du cours

On classe sur les **premiers axes factoriels**, jamais sur les variables brutes.

Ces axes sont quantitatifs, non corrélés, et de même nature quelle que soit l'origine des données. La distance euclidienne y retrouve tout son sens.

Classer sur les axes factoriels

---

## Trois raisons, et la troisième est décisive

### Pourquoi passer par l'ACP avant de classer

1. **Débruiter** : les derniers axes ne portent que de l'erreur de mesure.
2. **Décorrélérer** : sur des variables corrélées, la distance euclidienne compte plusieurs fois la même information.
3. **Homogénéiser** : une seule échelle, quelle que soit la nature des données de départ.

### Le deuxième point, sur nos données

Prix, choix et qualité sont corrélés autour de 0,70. Deux clients qui diffèrent sur ces trois notes diffèrent **trois fois pour une seule raison**.

La distance euclidienne sur les huit notes brutes surpondère donc le bloc « offre ». **Sur les composantes, le problème disparaît par construction** : elles sont non corrélées.

## Une question distincte de celle du chapitre 7

Pour **représenter**, deux axes suffisaient — on ne dessine pas en dimension trois.

Pour **classer**, on peut en garder davantage : rien n'oblige à visualiser. L'usage est de conserver les axes jusqu'à 80 ou 90 % de l'inertie.

## Notre choix : les deux premiers axes

Ils portent 77,3 %, et le troisième ne pèse que 4,8 % — du bruit.

On classera donc sur  $F_1$  et  $F_2$ . Avantage supplémentaire, et il n'est pas mince : la partition obtenue sera directement lisible sur le plan que nous savons déjà interpréter.

Ce qu'il faut retenir

---

## Six points

1. Classer exige de **choisir une distance** — décision que l'ACP n'imposait pas.
2. Euclidienne pour les variables réduites, **khi-deux** pour les profils, **Jaccard** pour les présences-absences.
3. Une **dissimilarité** ne vérifie pas l'inégalité triangulaire; les jugements humains non plus.
4. Sur données **mixtes**, la meilleure voie est de classer sur les **axes factoriels**.
5. Trois raisons : **débruiter, décorréler, homogénéiser**.
6. Nous classerons sur  $F_1$  et  $F_2$ , soit **77,3 %** de l'information.

## La suite

La distance est choisie. Reste à construire les groupes — et deux familles d'algorithmes s'y emploient, avec des logiques opposées.

On commence par celle qui ne demande pas de fixer le nombre de classes à l'avance.