

# Analyse des données avancée

## Chapitre 3 : Diagonalisation et décomposition en valeurs singulières

---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 25 septembre 2026

Diagonaliser une symétrique

Décomposition en valeurs

Approcher un tableau simplifié

Ce qu'il faut retenir

## Diagonaliser une symétrique

---

# Le théorème spectral

## L'énoncé

Toute matrice **symétrique réelle**  $\mathbf{A}$  d'ordre  $p$  s'écrit

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}', \quad \mathbf{U}'\mathbf{U} = \mathbf{I}$$

avec  $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p)$  réelle. Les colonnes de  $\mathbf{U}$  sont **orthonormées**.

## Ce que le théorème promet, et qui n'allait pas de soi

Trois choses, dont aucune n'est vraie pour une matrice quelconque : les valeurs propres sont **réelles**, il y en a **toujours**  $p$ , et les vecteurs propres sont **orthogonaux**.

C'est cette orthogonalité qui donnera aux axes factoriels leur propriété la plus utile : **le deuxième axe n'a rien à ajouter à ce que le premier a dit.**

# Semi-définie positive

## Le cas qui nous concerne

Une matrice de variance-covariance  $V = X'DX$  est **symétrique semi-définie positive** :

$$a'Va = \sum_i p_i (x'_i a)^2 \geq 0 \quad \text{pour tout } a$$

Ses valeurs propres sont donc **toutes positives ou nulles**.

## La lecture statistique

$a'Va$  est la **variance de la combinaison linéaire**  $Xa$ . Une variance ne peut pas être négative : la positivité n'est pas un détail technique, c'est la même chose dite en algèbre.

Une valeur propre nulle signale une **variable redondante** — une colonne combinaison exacte des autres.

### La matrice

$$\mathbf{A} = \mathbf{X}'\mathbf{X} = \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix}$$

Le polynôme caractéristique :

$$(10 - \lambda)^2 - 36 = 0 \iff 10 - \lambda = \pm 6$$

$$\lambda_1 = 16, \quad \lambda_2 = 4$$

### Exemple

Pour  $\lambda_1 = 16$  :  $-6a_1 + 6a_2 = 0$ , donc  $a_1 = a_2$ .

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mathbf{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

Vérifications :  $\mathbf{u}_1' \mathbf{u}_2 = 0$ ,  $\lambda_1 + \lambda_2 = 20 = \text{trace}(\mathbf{A})$ ,  $\lambda_1 \lambda_2 = 64 = \det(\mathbf{A})$ .

### Intuition

$u_1$  est la **bissectrice** : la direction où les deux variables varient ensemble. Elle porte  $16/20 = 80\%$  de l'information.

$u_2$  est la direction où elles s'opposent. Sans avoir prononcé le mot ACP, on vient de la faire.

## Décomposition en valeurs

---

# Ce que la diagonalisation ne sait pas faire

## Le problème

$\mathbf{X}$  est  $n \times p$  — **rectangulaire**. Elle n'a ni valeurs propres, ni vecteurs propres.

On peut diagonaliser  $\mathbf{X}'\mathbf{X}$ , qui est  $p \times p$ , ou  $\mathbf{X}\mathbf{X}'$ , qui est  $n \times n$  — mais rien ne dit encore comment les deux se relient.

## La décomposition en valeurs singulières

Toute matrice  $\mathbf{X}$  de rang  $r$  s'écrit

$$\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}'$$

- $\mathbf{U}$ ,  $n \times r$ , colonnes orthonormées — les vecteurs singuliers à **gauche** ;
- $\mathbf{V}$ ,  $p \times r$ , colonnes orthonormées — les vecteurs singuliers à **droite** ;
- $\Sigma = \text{diag}(\sigma_1 \geq \dots \geq \sigma_r > 0)$ , les **valeurs singulières**.

# Le lien avec les deux diagonalisations

## Les trois identités

$$\mathbf{X}'\mathbf{X} = \mathbf{V}\Sigma^2\mathbf{V}'$$

$$\mathbf{X}\mathbf{X}' = \mathbf{U}\Sigma^2\mathbf{U}'$$

$$\mathbf{X}\mathbf{v}_k = \sigma_k \mathbf{u}_k$$

$$\mathbf{X}'\mathbf{u}_k = \sigma_k \mathbf{v}_k$$

## Le résultat qui va tout gouverner

$\mathbf{X}'\mathbf{X}$  et  $\mathbf{X}\mathbf{X}'$  n'ont pas la même taille, mais **exactement les mêmes valeurs propres non nulles** : les  $\sigma_k^2$ .

C'est la **dualité**. Analyser le nuage des individus ou celui des variables donnera les mêmes valeurs propres — non par coïncidence, mais parce que ce sont les deux faces d'une seule décomposition. Le chapitre 5 en tire toutes les conséquences.

# La décomposition du petit tableau

## Les valeurs singulières

$\mathbf{X}'\mathbf{X}$  a pour valeurs propres 16 et 4, donc

$$\sigma_1 = \sqrt{16} = 4, \quad \sigma_2 = \sqrt{4} = 2$$

## Les vecteurs à gauche, par $\mathbf{X}\mathbf{v}_k = \sigma_k \mathbf{u}_k$

$$\mathbf{X}\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} -4 \\ 0 \\ 0 \\ 4 \end{pmatrix} \Rightarrow \mathbf{u}_1 = \frac{\mathbf{X}\mathbf{v}_1}{\sigma_1} = \frac{1}{4\sqrt{2}} \begin{pmatrix} -4 \\ 0 \\ 0 \\ 4 \end{pmatrix} = \begin{pmatrix} -0,707 \\ 0 \\ 0 \\ 0,707 \end{pmatrix}$$

Les individus 2 et 3 ont une coordonnée **nulle** sur le premier axe : ils sont exactement sur le second.

## Intuition

$$\sum_i (\mathbf{X}\mathbf{v}_1)_i^2 = \frac{16 + 0 + 0 + 16}{2} = 16 = \lambda_1$$

**La somme des carrés des coordonnées sur un axe est sa valeur propre.** C'est le contrôle à faire sur toute sortie de logiciel.

## Approcher un tableau simplifié

---

# Le théorème d'Eckart et Young

## La meilleure approximation de rang $k$

$$\mathbf{X}_{(k)} = \sum_{m=1}^k \sigma_m \mathbf{u}_m \mathbf{v}_m'$$

est, parmi **toutes** les matrices de rang  $k$ , celle qui minimise  $\|\mathbf{X} - \mathbf{B}\|^2$ .

L'erreur commise vaut  $\sigma_{k+1}^2 + \dots + \sigma_r^2$ .

## Pourquoi ce théorème est le vrai fondement du cours

Il ne dit pas seulement que la solution factorielle est bonne : il dit qu'**aucune autre méthode ne peut faire mieux**, à rang égal.

Retenir deux axes, c'est remplacer un tableau  $300 \times 8$  par le meilleur tableau de rang 2 qui existe. Et l'erreur est **connue d'avance** : la somme des valeurs propres abandonnées.

### Le coût du résumé

$$\lambda_1 + \lambda_2 = 4,535 + 1,645 = 6,180 \quad \text{sur } 8$$

Le plan retient 77,3 % de l'inertie ; l'erreur d'approximation est

$$0,382 + 0,349 + 0,327 + 0,283 + 0,249 + 0,229 = 1,820$$

### Ce que cela veut dire pour l'enseigne

Deux nombres par client — au lieu de huit — restituent plus des trois quarts de ce que le questionnaire contenait.

Le quart perdu n'est pas du signal : ce sont six valeurs propres presque égales, entre 0,23 et 0,38, c'est-à-dire **la signature du bruit**. Le chapitre 6 en fait un critère.

## Ce qu'il faut retenir

---

## Le résumé du chapitre

### Six points

1. Une matrice **symétrique réelle** se diagonalise en base orthonormée, à valeurs propres réelles.
2. Une matrice de variance-covariance est **semi-définie positive** : ses valeurs propres sont positives.
3. Toute matrice rectangulaire admet une **décomposition en valeurs singulières**  $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}'$ .
4.  $\mathbf{X}'\mathbf{X}$  et  $\mathbf{X}\mathbf{X}'$  ont **les mêmes valeurs propres non nulles** — c'est la dualité.
5.  $\mathbf{X}\mathbf{v}_k = \sigma_k \mathbf{u}_k$  : la relation qui fera passer des variables aux individus.
6. **Eckart et Young** : la troncature de la décomposition est la meilleure approximation de rang donné, et l'erreur vaut la somme des valeurs propres écartées.

### La suite

L'outil est en place. Le chapitre 4 pose le problème de l'ACP et le résout — en trois