

Analyse des données

Chapitre 2 : Analyse en Composantes Principales (ACP)

Jaouad Madkour

29 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous ?


Présentation élémentaire

Formalisation

Représentations graphiques

Choix de la dimension

Où en sommes-nous?



Pourquoi ce chapitre ?

Dès qu'on observe **quatre indicateurs ou plus** sur un ensemble d'individus (clients, entreprises, magasins), il devient impossible de les représenter sur un seul graphique. L'**Analyse en Composantes Principales** (ACP) résume ce nuage de dimension p dans un espace de dimension réduite (souvent 2), en déformant le moins possible la réalité. C'est la méthode factorielle centrale : toutes les autres du cours en découlent.

Résumer sans trop déformer

On dispose d'un tableau $n \times p$ (n individus, p variables quantitatives). Les individus vivent dans un espace de dimension p : impossible à visualiser dès $p > 3$. L'ACP cherche le **sous-espace de dimension q** (2 ou 3) sur lequel projeter le nuage en **conservant au mieux sa dispersion**. Les nouvelles variables, les **composantes principales**, sont des combinaisons des variables initiales.

Ce qu'on analyse : la dispersion

C'est la **matrice des variances-covariances** (ou celle des corrélations) qui porte l'information à résumer, car l'ACP analyse la **dispersion** des données. On en extrait un petit nombre de **facteurs** qui permettent les graphiques recherchés, guidés par des **aides à l'interprétation** (contributions, cosinus carrés, corrélations).

Présentation élémentaire

Un exemple à quatre variables

Neuf collaborateurs, quatre compétences

Neuf collaborateurs sont évalués (note de 0 à 20) sur quatre compétences : **Comptabilité** et **Informatique** (pôle *technique*), **Communication** et **Négociation** (pôle *relationnel*). On sait décrire chaque compétence séparément, et mesurer la corrélation de deux d'entre elles. Mais comment étudier les **quatre simultanément** sur un seul graphique ? Chaque collaborateur est un point en dimension 4 : c'est exactement le problème que résout l'ACP.

Résultats préliminaires

Tout logiciel fournit d'abord les statistiques élémentaires (moyenne, écart-type, min, max) de chaque variable, puis la **matrice des corrélations** — une succession d'analyses bivariées, premier pas vers le multivarié. Si les quatre compétences sont fortement corrélées positivement, cela annonce un premier facteur « niveau global ».

Décomposition de la dispersion

La **dispersion totale** du nuage est la somme des variances des p variables. L'ACP en fait un **changement de base** : la dispersion totale ne change pas, mais se **répartit** différemment sur les nouveaux axes (les facteurs). Les **valeurs propres** $\lambda_1 \geq \lambda_2 \geq \dots$ mesurent la part de dispersion portée par chaque axe, et leur somme égale la dispersion totale.

Objectif atteint quand deux axes suffisent

Si les deux premières valeurs propres restituent la quasi-totalité de la dispersion, alors le graphique en dimension 2 résume presque parfaitement les données de dimension p . L'objectif — un résumé pertinent en petite dimension — est alors atteint.

Corrélations variables-facteurs

Le résultat fondamental sur les variables est le tableau des **corrélations entre variables initiales et facteurs**. Ce sont elles qui **donnent un sens aux axes**. Une variable très corrélée (positivement ou négativement) à un facteur contribue fortement à sa signification.

Interprétation des deux premiers axes

Dans l'exemple, l'**axe 1** est corrélé positivement à **toutes** les compétences : c'est l'axe du **niveau global** (un collaborateur bien noté partout a un score élevé). L'**axe 2** oppose le pôle relationnel (corrélations positives) au pôle technique (corrélations négatives) : c'est un axe de **profil**, distinguant les collaborateurs à dominante relationnelle de ceux à dominante technique.

Coordonnées, contributions, cosinus carrés

Pour chaque individu, on lit ses **coordonnées** sur les axes (qui servent à tracer le graphique), ses **contributions** à la variance de chaque axe (qui identifient les individus influents), et ses **cosinus carrés** (qui mesurent la **qualité de représentation** sur chaque axe).

Individus influents

Un individu qui contribue à lui seul à près de 30 % de la variance d'un axe est **prépondérant** dans sa définition : souvent un profil extrême (le meilleur ou le plus faible). Repérer ces individus évite d'interpréter un axe qui ne refléterait qu'un cas particulier.

Cosinus carré = qualité

Chaque individu initial est un vecteur en dimension p ; on le représente par sa **projection** sur le plan factoriel. Le **cosinus carré** de l'angle entre le vecteur et sa projection mesure la qualité : proche de 1, le point est bien représenté; proche de 0, sa position sur le graphique est trompeuse. Les cosinus carrés **s'additionnent** axe par axe.

Formalisation

Espace des individus, espace des variables

Le tableau X ($n \times p$) se lit de deux façons. Chaque **individu** est un vecteur de $\mathbb{R}^p$ (espace des individus, muni d'une métrique M). Chaque **variable** centrée est un vecteur de $\mathbb{R}^n$ (espace des variables, muni de la **métrique des poids** $D = \text{diag}(w_1, \dots, w_n)$).

Interprétation géométrique de la métrique des poids

Dans l'espace des variables muni de la métrique des poids, les notions usuelles prennent un sens statistique : la **longueur** d'un vecteur-variable est son **écart-type**, et le **cosinus** de l'angle entre deux vecteurs-variables est leur **corrélation**. Toute la géométrie de l'ACP découle de cette correspondance.

Les trois objectifs de l'ACP

L'ACP poursuit trois buts liés : (i) la **représentation optimale des individus** dans un sous-espace de dimension q , minimisant la déformation du nuage; (ii) la **représentation des variables** explicitant au mieux leurs liaisons; (iii) la **réduction de dimension** (compression), utile en préalable à une régression ou à d'autres méthodes.

Composantes principales et facteurs

Une **composante principale** C^k est la combinaison linéaire des variables, de variance maximale, **non corrélée** aux précédentes. Sa variance est la valeur propre λ_k . Les **axes principaux** (vecteurs propres de la matrice des covariances) portent les composantes; les **facteurs** sont les combinaisons qui les définissent. Mathématiquement, l'ACP est la **décomposition en valeurs singulières** du tableau centré.

Réduire ou non les variables


Si les variables ont des **unités ou des variances très différentes**, on les **réduit** (division par l'écart-type) avant l'analyse : l'ACP porte alors sur la matrice des **corrélations** R . Sinon, un « effet taille » — dû à la variable la plus dispersée — accaparerait le premier axe.

Représentations graphiques

Le cercle des corrélations

Représentation des variables

Dans le cas réduit, chaque variable se projette à l'intérieur du cercle des corrélations (rayon 1). Plus une variable est **proche du cercle**, mieux elle est représentée. L'**angle** entre deux variables reflète leur corrélation : proches = corrélées positivement, opposées = corrélées négativement, orthogonales = non corrélées.



Projeter sans influencer

Un **individu supplémentaire** est projeté sur les axes **sans avoir participé à leur calcul**. Utile pour positionner un nouveau client, un nouveau magasin ou une observation atypique (préalablement écartée) par rapport à une structure déjà établie.

Positionner une nouvelle agence

Après avoir construit l'ACP sur le réseau d'agences existant, on projette une **agence récemment ouverte** comme individu supplémentaire : sa position révèle immédiatement à quel profil d'agences elle ressemble, sans recalculer toute l'analyse.

Choix de la dimension

Combien d'axes retenir ?

Part d'inertie

Le critère le plus courant : retenir assez d'axes pour que la **part d'inertie (dispersion) expliquée** dépasse un seuil fixé à l'avance (par exemple 80 %).

Règle de Kaiser

En ACP réduite, chaque variable initiale a une variance de 1. On ne conserve alors que les composantes de valeur propre **supérieure à 1** (plus « informatives » qu'une variable initiale). Ce critère a tendance à **surestimer** le nombre d'axes.

Éboulis des valeurs propres (scree plot)

Le graphique de la **décroissance des valeurs propres** aide à repérer un **coude** : on conserve les axes situés avant la cassure. Intuitivement, un grand écart $\lambda_q - \lambda_{q+1}$ garantit la stabilité du sous-espace retenu.

valeur propre



coude :
2 axes retenus

Une méthode linéaire et sensible aux extrêmes

L'ACP optimise un critère **quadratique** : elle ne capte que les liaisons **linéaires** et reste **sensible aux valeurs extrêmes**. D'où l'importance de l'exploration descriptive préalable (chapitre 1) : transformations, repérage des outliers, réduction éventuelle des variables.

ACP d'un tableau de ratios financiers

Sur un échantillon d'entreprises décrites par une dizaine de **ratios financiers** (rentabilité, endettement, liquidité, rotation...), l'ACP dégagne souvent deux axes lisibles : un axe de **performance** globale et un axe **structure financière** (endettement vs autonomie). Deux graphiques remplacent alors la lecture fastidieuse d'une grande matrice de corrélations.

Synthèse du chapitre

L'ACP projette un nuage de dimension p sur le plan qui **conserve le mieux la dispersion**. On interprète les **axes** via les corrélations variables-facteurs, les **individus** via leurs coordonnées, contributions et cosinus carrés, et on choisit la **dimension** par la part d'inertie ou l'éboulis. C'est le socle des méthodes suivantes : l'analyse discriminante (chapitre 3) et le positionnement multidimensionnel (chapitre 4) en sont des variantes.