

Analyse des données

Chapitre 3 : Analyse Factorielle Discriminante (AFD)

Jaouad Madkour

30 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous ?

Le principe géométrique

Réalisation de l'AFD

ACP contre AFD

Où en sommes-nous?



Pourquoi ce chapitre ?

L'ACP résume un nuage **sans tenir compte de groupes** connus. Mais en gestion, on connaît souvent une **partition a priori** des individus : clients fidèles / perdus, entreprises saines / défaillantes, produits en croissance / en déclin. L'**Analyse Factorielle Discriminante** (AFD) cherche la représentation qui **sépare le mieux ces groupes**, et identifie les variables responsables de la distinction.

Variables explicatives et variable de groupe

On dispose de p variables **quantitatives** $X^1, \dots, X^p$ (rôle explicatif) et d'une variable **qualitative** T à m modalités (la variable à expliquer). La situation ressemble à la régression multiple, mais comme T est **qualitative**, la méthode est différente : il s'agit de séparer des classes, non de prédire un nombre.

Deux techniques sous un même nom

Descriptive : parmi toutes les ACP possibles des X^j , chercher celle dont le graphique des individus **discrimine au mieux** les m classes (recherche de facteurs de distinction). **Décisionnelle** : connaissant les X^j d'un nouvel individu mais pas sa classe, l'**affecter** à une modalité (scoring, reconnaissance de formes). Ce chapitre traite surtout du volet descriptif.

Le principe géométrique

Décomposition de la dispersion

Chaque classe Ω_ℓ a un **barycentre** g_ℓ (le profil moyen du groupe). La matrice des covariances totale se décompose en

$$S = S_e + S_r,$$

où S_e est la covariance **interclasse** (between, dispersion des barycentres) et S_r la covariance **intraclasse** (within, dispersion à l'intérieur des groupes, assimilée au « bruit »).

Privilégier l'inter au détriment de l'intra

Pour faire ressortir les groupes, on projette les individus dans la direction qui **maximise la variance interclasse** (écarte les barycentres) tout en **minimisant la variance intraclasse** (resserre chaque groupe). C'est le contraire du bruit : on veut des groupes **compacts et bien séparés**.

AFD = ACP avec la métrique intraclasse

On considère les individus d'une même classe comme des observations répétées d'un même « effet ».

La métrique naturelle est alors $M = S_r^{-1}$ (inverse de la covariance intraclasse, dite **métrique de Mahalanobis**). L'AFD est l'ACP des barycentres (G, S_r^{-1}, D) : elle diagonalise $S_e S_r^{-1}$.

Pourquoi cette métrique change tout

La métrique de Mahalanobis **corrige la forme** des groupes : elle rend les classes plus « sphériques » autour de leur barycentre en neutralisant les corrélations internes. Deux variables redondantes ne comptent alors qu'une fois — ce qu'une ACP ordinaire ne fait pas.

Réalisation de l'AFD

Axes discriminants

On diagonalise $S_e S_r^{-1}$: les vecteurs propres sont les **vecteurs discriminants**, les sous-espaces qu'ils engendrent les **axes discriminants**. Le rang de la matrice vaut au plus $m - 1$: avec m groupes, on obtient au maximum $m - 1$ axes discriminants (une droite pour 2 groupes, un plan pour 3).

Représentation des individus et des barycentres

On représente simultanément les **individus** et les **barycentres** des classes sur les axes discriminants. Différencier graphiquement la classe de chaque individu (couleur, symbole) permet d'**apprécier visuellement la qualité de la séparation**. Comme en ACP, des cosinus carrés mesurent la qualité de représentation.

Représentation des variables

Chaque variable X^j est représentée par un vecteur dont les coordonnées expriment sa **corrélation expliquée** avec les axes. On interprète ainsi les axes **en fonction des variables initiales** : quelles compétences, quels ratios séparent le mieux les groupes.

L'AFD sert-elle à quelque chose ?


Le point pratique essentiel : la représentation **sépare-t-elle réellement les classes** ? Si les groupes se chevauchent sur le graphique, l'AFD ne sert à rien — les X^j n'expliquent pas T . Dans le cas favorable, le graphique des individus interprète la discrimination, celui des variables interprète les axes, et leur synthèse explique T selon les X^j .

ACP contre AFD


La valeur ajoutée de la métrique

Deux vues du même jeu de données

Sur un même jeu où les individus appartiennent à des groupes connus, on peut tracer le premier plan d'une **ACP** et celui d'une **AFD**. L'ACP ignore les groupes et peut les laisser se mélanger; l'AFD, grâce à la métrique intraclasse, **écarte les barycentres** et resserre les groupes, rendant la typologie beaucoup plus nette.



groupes confondus



groupes séparés

Scoring de défaillance d'entreprise

On décrit des entreprises par des ratios financiers (p variables) et on connaît leur statut T : **saine** ou **défaillante** ($m = 2$). L'AFD construit **un seul axe discriminant** (car $m - 1 = 1$) — un **score** combinant les ratios — qui sépare au mieux les deux populations. Les ratios les plus corrélés à cet axe (rentabilité, endettement, trésorerie) sont les **signaux d'alerte**; un nouveau dossier se projette sur l'axe pour estimer son risque. C'est le principe historique du score de Altman et des modèles de credit scoring.

Segmentation confirmée de la clientèle

Si l'on dispose déjà de segments clients (m modalités : premium, standard, occasionnel), l'AFD vérifie si les variables de comportement d'achat **séparent réellement** ces segments et identifie lesquelles portent la distinction — utile pour cibler les campagnes.

Synthèse du chapitre

L'AFD est une **ACP avec groupes connus** : elle diagonalise l'inertie interclasse relativement à l'inertie intraclasse (métrique de Mahalanobis) pour obtenir au plus $m - 1$ **axes discriminants**. Elle sert à la fois à **visualiser** la séparation des groupes et à **construire un score** d'affectation. Au chapitre suivant, on abandonne le tableau individus $\times$ variables pour ne connaître que des **distances** entre individus : c'est le positionnement multidimensionnel.