

Analyse des données

Chapitre 6 : Axes, valeurs propres et inertie

Jaouad Madkour

18 août 2026

Faculté d'Économie et de Gestion de Tanger


Le calcul et son sens

Coordonnées et composantes

Ce que les valeurs propres ne disent pas

Ce qu'il faut retenir

Le calcul et son sens



Ce que donne la diagonalisation

Soit R la matrice des corrélations, symétrique et $p \times p$. Elle admet p valeurs propres réelles positives $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ et p vecteurs propres orthogonaux.

Le k -ième **axe principal** est le k -ième vecteur propre. La **variance** de la composante correspondante est λ_k .

La propriété qui fait tout fonctionner

$$\lambda_1 + \lambda_2 + \dots + \lambda_p = \text{trace}(R) = p$$

La trace d'une matrice de corrélations vaut p , puisque sa diagonale ne contient que des 1.

Les valeurs propres se partagent donc exactement l'inertie totale. C'est ce qui donne un sens au mot « pourcentage d'inertie expliquée ».

Les huit valeurs propres

Axe	λ_k	Part	Cumul
1	4,535	56,69 %	56,69 %
2	1,645	20,57 %	77,26 %
3	0,382	4,77 %	82,03 %
4	0,349	4,37 %	86,40 %
5 à 8	$\leq 0,327$	13,60 %	100 %

Le résultat, en une phrase

Deux dimensions restituent plus des trois quarts de l'information contenue dans huit variables.

Ce n'est pas un artifice de présentation : cela signifie qu'un client est presque entièrement décrit par deux nombres au lieu de huit.

Coordonnées et composantes

La coordonnée sur l'axe k

$$F_k(i) = \sum_{j=1}^p z_{ij} u_{kj}$$

La note réduite du client i sur chaque variable, pondérée par le poids de cette variable dans l'axe k .

Un client, deux nombres

Le client 166 a noté 16, 19, 19, 17, 18, 15, 14, 19. Toutes ses notes sont hautes, et légèrement plus hautes sur l'offre.

Sa coordonnée sur l'axe 1 vaut +4,61 – très loin à droite. Sur l'axe 2, +0,84 – légèrement du côté de l'offre. **Deux nombres résument huit notes, et disent l'essentiel : un client très satisfait, sans préférence marquée.**

Ce que vérifient les composantes

1. Leur **moyenne est nulle** — le nuage est centré.
2. Leur **variance est λ_k** .
3. Elles sont **deux à deux non corrélées** : $\text{cov}(F_k, F_\ell) = 0$.

La troisième propriété est celle qui compte

Les huit notes étaient fortement corrélées; **les composantes ne le sont plus du tout.**

C'est ce qui permet de les traiter comme des variables autonomes dans la suite : on classera les clients sur F_1 et F_2 au chapitre 15, sans se demander si ces deux variables font double emploi. Elles ne peuvent pas en faire.

Ce que les valeurs propres ne
disent pas

Un pourcentage élevé n'est pas une garantie

Deux situations, un même 77 pour cent

Cas A : deux blocs de variables corrélées, comme ici. Les axes s'interprètent, l'analyse a un contenu.

Cas B : une seule variable extrême écrase tout et fabrique un premier axe à 70 %. Le pourcentage est excellent, l'analyse ne vaut rien.

La règle de prudence

Le pourcentage d'inertie mesure la fidélité de la représentation, pas son intérêt.

Un plan très fidèle à un nuage sans structure reste un plan sans structure. C'est pourquoi on regarde toujours, après les valeurs propres, **les contributions** — pour vérifier qu'aucune variable et aucun individu ne monopolise un axe.

L'ACP contre le hasard

Si les p variables étaient indépendantes, toutes les valeurs propres vaudraient 1 et aucun axe ne dominerait.

Le critère de Kaiser en découle : ne retenir que les axes de valeur propre supérieure à 1, c'est-à-dire ceux qui résument mieux qu'une variable prise seule.

Sur nos données

$\lambda_1 = 4,54$ et $\lambda_2 = 1,65$ dépassent 1. $\lambda_3 = 0,38$ est nettement en dessous.

Le critère retient exactement deux axes — et le chapitre suivant montrera que les deux autres critères disent la même chose.

Ce qu'il faut retenir

Six points

1. Les axes principaux sont les **vecteurs propres** de R , les variances ses **valeurs propres**.
2. $\sum_k \lambda_k = \text{trace}(R) = p$: les λ_k **partagent l'inertie totale**.
3. Sur nos données : **56,7 %** et **20,6 %**, soit **77,3 %** sur un plan.
4. La coordonnée d'un individu est $F_k(i) = \sum_j z_{ij} u_{kj}$.
5. Les composantes sont centrées, de variance λ_k , et **non corrélées entre elles**.
6. Un pourcentage élevé mesure la **fidélité**, jamais l'**intérêt** de l'analyse.

La suite

Deux axes, dit le critère de Kaiser. Mais il existe deux autres critères, et ils ne concordent pas toujours.

Le chapitre 7 les met côte à côte, et dit lequel l'emporte quand ils divergent.