


# Analyse des données

## Chapitre 6 : Axes, valeurs propres et inertie



---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 21 août 2026

Le calcul et son sens


Coordonnées et composantes

Ce que les valeurs propres ne disent pas

Ce qu'il faut retenir

## Le calcul et son sens

---



## Ce que donne la diagonalisation

Soit  $R$  la matrice des corrélations, symétrique et  $p \times p$ . Elle admet  $p$  valeurs propres réelles positives  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$  et  $p$  vecteurs propres orthogonaux.

Le  $k$ -ième **axe principal** est le  $k$ -ième vecteur propre. La **variance** de la composante correspondante est  $\lambda_k$ .

## La propriété qui fait tout fonctionner

$$\lambda_1 + \lambda_2 + \dots + \lambda_p = \text{trace}(R) = p$$

La trace d'une matrice de corrélations vaut  $p$ , puisque sa diagonale ne contient que des 1.

**Les valeurs propres se partagent donc exactement l'inertie totale.** C'est ce qui donne un sens au mot « pourcentage d'inertie expliquée ».

### Les huit valeurs propres

| Axe   | $\lambda_k$  | Part    | Cumul   |
|-------|--------------|---------|---------|
| 1     | 4,535        | 56,69 % | 56,69 % |
| 2     | 1,645        | 20,57 % | 77,26 % |
| 3     | 0,382        | 4,77 %  | 82,03 % |
| 4     | 0,349        | 4,37 %  | 86,40 % |
| 5 à 8 | $\leq 0,327$ | 13,60 % | 100 %   |

### Le résultat, en une phrase

Deux dimensions restituent plus des trois quarts de l'information contenue dans huit variables.

Ce n'est pas un artifice de présentation : cela signifie qu'un client est presque entièrement décrit par deux nombres au lieu de huit.

## Coordonnées et composantes

---

### La coordonnée sur l'axe $k$

$$F_k(i) = \sum_{j=1}^p z_{ij} u_{kj}$$

La note réduite du client  $i$  sur chaque variable, pondérée par le poids de cette variable dans l'axe  $k$ .

### Un client, deux nombres

Le client 166 a noté 16, 19, 19, 17, 18, 15, 14, 19. Toutes ses notes sont hautes, et légèrement plus hautes sur l'offre.

Sa coordonnée sur l'axe 1 vaut +4,61 – très loin à droite. Sur l'axe 2, +0,84 – légèrement du côté de l'offre. **Deux nombres résument huit notes, et disent l'essentiel : un client très satisfait, sans préférence marquée.**

### Ce que vérifient les composantes

1. Leur **moyenne est nulle** — le nuage est centré.
2. Leur **variance est  $\lambda_k$** .
3. Elles sont **deux à deux non corrélées** :  $\text{cov}(F_k, F_\ell) = 0$ .

### La troisième propriété est celle qui compte

Les huit notes étaient fortement corrélées; **les composantes ne le sont plus du tout.**

C'est ce qui permet de les traiter comme des variables autonomes dans la suite : on classera les clients sur  $F_1$  et  $F_2$  au chapitre 15, sans se demander si ces deux variables font double emploi. Elles ne peuvent pas en faire.

Ce que les valeurs propres ne  
disent pas

---

# Un pourcentage élevé n'est pas une garantie

## Deux situations, un même 77 pour cent

**Cas A** : deux blocs de variables corrélées, comme ici. Les axes s'interprètent, l'analyse a un contenu.

**Cas B** : une seule variable extrême écrase tout et fabrique un premier axe à 70 %. Le pourcentage est excellent, l'analyse ne vaut rien.

## La règle de prudence

Le pourcentage d'inertie mesure la fidélité de la représentation, pas son intérêt.

Un plan très fidèle à un nuage sans structure reste un plan sans structure. C'est pourquoi on regarde toujours, après les valeurs propres, **les contributions** — pour vérifier qu'aucune variable et aucun individu ne monopolise un axe.

### L'ACP contre le hasard

Si les  $p$  variables étaient indépendantes, toutes les valeurs propres vaudraient 1 et aucun axe ne dominerait.

**Le critère de Kaiser en découle** : ne retenir que les axes de valeur propre supérieure à 1, c'est-à-dire ceux qui résument mieux qu'une variable prise seule.

### Sur nos données

$\lambda_1 = 4,54$  et  $\lambda_2 = 1,65$  dépassent 1.  $\lambda_3 = 0,38$  est nettement en dessous.

**Le critère retient exactement deux axes** — et le chapitre suivant montrera que les deux autres critères disent la même chose.

Ce qu'il faut retenir

---

## Six points

1. Les axes principaux sont les **vecteurs propres** de  $R$ , les variances ses **valeurs propres**.
2.  $\sum_k \lambda_k = \text{trace}(R) = p$  : les  $\lambda_k$  **partagent l'inertie totale**.
3. Sur nos données : **56,7 %** et **20,6 %**, soit **77,3 %** sur un plan.
4. La coordonnée d'un individu est  $F_k(i) = \sum_j z_{ij} u_{kj}$ .
5. Les composantes sont centrées, de variance  $\lambda_k$ , et **non corrélées entre elles**.
6. Un pourcentage élevé mesure la **fidélité**, jamais l'**intérêt** de l'analyse.

## La suite

Deux axes, dit le critère de Kaiser. Mais il existe deux autres critères, et ils ne concordent pas toujours.

Le chapitre 7 les met côte à côte, et dit lequel l'emporte quand ils divergent.