


Analyse des données

Chapitre 5 : Centrer, réduire, et la matrice des corrélations




Deux transformations, deux effets

La matrice des corrélations



L'effet taille

Ce qu'il faut retenir

Deux transformations, deux effets



Centrer et réduire



Sans réduction, l'ACP mesurerait des dirhams contre des années.

Le panier varie de plusieurs centaines, l'ancienneté de quelques unités : le premier axe suivrait le panier et ne dirait rien d'autre que « le panier a une grande variance ».

Réduire, c'est donner à chaque variable le même poids — une inertie de 1 chacune. L'ACP porte alors sur la *matrice des corrélations*, et non sur celle des covariances.

Deux gestes distincts

Centrer : $x_{ij} - \bar{x}_j$. Le centre de gravité vient à l'origine. Cela ne change ni les distances, ni la forme du nuage.

Réduire : diviser par s_j . Chaque variable a désormais une variance de 1 — donc une inertie de 1.

Le centrage est obligatoire, la réduction est un choix

Sans centrage, le premier axe passerait par l'origine du repère et **mesurerait surtout la position moyenne du nuage** — une information sans intérêt.

La réduction, elle, se discute. Elle s'impose dès que les unités diffèrent. Elle se discute quand les variables sont dans la même unité — et nos huit notes le sont toutes.

Faut-il réduire des notes sur vingt ?

Elles sont dans la même unité, et leurs écarts-types sont presque égaux — de 2,38 à 2,40.

La réduction ne changera donc quasiment rien ici. On la fait quand même, pour trois raisons : par convention, parce que les λ_k deviennent alors comparables à 1, et parce que l'inertie totale vaut exactement p .

Le cas où cela change tout

Si l'une des notes avait été un montant en dirhams — le panier moyen — son écart-type aurait été de plusieurs centaines.

Sans réduction, **elle aurait absorbé le premier axe à elle seule**, et l'ACP aurait « découvert » que le panier a une grande variance. Un résultat exact et parfaitement inutile.

La matrice des corrélations

Ce que l'ACP va diagonaliser

	prix	choix	qual.	agen.	prop.	rapid.	cons.	accu.
prix	1	0,67	0,67	0,59	0,43	0,22	0,15	0,09
choix	0,67	1	0,73	0,69	0,56	0,32	0,34	0,31
qualité	0,67	0,73	1	0,71	0,56	0,41	0,36	0,35
agencement	0,59	0,69	0,71	1	0,59	0,50	0,44	0,41
propreté	0,43	0,56	0,56	0,59	1	0,64	0,59	0,58
rapidité	0,22	0,32	0,41	0,50	0,64	1	0,69	0,71
conseil	0,15	0,34	0,36	0,44	0,59	0,69	1	0,73
accueil	0,09	0,31	0,35	0,41	0,58	0,71	0,73	1

L'ACP est déjà là, dans ce tableau.

Deux blocs sombres se détachent : **prix, choix, qualité, agencement** d'un côté — ce que le magasin *propose* — et **propreté, rapidité, conseil, accueil** de l'autre — ce que le personnel *fait*. Entre les deux, les corrélations tombent à 0,09.

L'ACP ne fera que rendre visible cette structure — mais sur 30 variables, aucun œil ne l'aurait vue dans le tableau.

Trois vérifications

1. **Les corrélations sont-elles fortes?** Si toutes sont proches de 0, l'ACP n'a rien à résumer.
2. **Y a-t-il des blocs?** Ils annoncent les axes.
3. **Une corrélation dépasse-t-elle 0,95?** Les deux variables font double emploi.

Sur nos données, le verdict est net

Deux blocs de corrélations autour de 0,70 : **prix, choix, qualité, agencement** d'un côté; **propreté, rapidité, conseil, accueil** de l'autre.

Entre les deux blocs, les corrélations tombent à 0,09 entre le prix et l'accueil. **L'ACP est donc légitime, et l'on sait déjà à peu près ce qu'elle va montrer.**

La mesure de Kaiser-Meyer-Olkin

$$\text{KMO} = \frac{\sum_{j \neq k} r_{jk}^2}{\sum_{j \neq k} r_{jk}^2 + \sum_{j \neq k} a_{jk}^2}$$

où les a_{jk} sont les corrélations partielles. On lit : $> 0,80$ excellent, $> 0,70$ correct, $< 0,50$ inacceptable.

Ce que l'indice compare

Une corrélation forte peut venir d'une liaison directe entre deux variables, ou d'une cause commune à toutes. **Seul le second cas justifie une ACP.**

Le KMO oppose corrélations simples et corrélations partielles pour distinguer les deux. En pratique, une matrice qui montre des blocs visibles à l'œil passe le test.

L'effet taille

Effet taille

Lorsque **toutes** les corrélations sont positives, le premier axe est corrélé positivement à toutes les variables.

Il ne mesure alors pas une opposition, mais un **niveau général** : le grand contre le petit, le satisfait contre le mécontent.

C'est exactement notre cas

Nos vingt-huit corrélations sont toutes positives, de 0,09 à 0,73. Le premier axe sera donc un axe de **niveau** : la satisfaction d'ensemble.

Ce n'est ni un défaut ni un artefact : c'est un fait, et il vaut d'être dit. Il existe bel et bien des clients contents de tout et des clients mécontents de tout.

Il pousse les oppositions sur l'axe 2

Comme l'axe 1 est confisqué par le niveau général, **les contrastes ne peuvent apparaître que sur l'axe 2** — perpendiculaire par construction.

C'est pourquoi, en présence d'un effet taille, le deuxième axe est souvent le plus riche. Ici, il opposera l'offre au service, et c'est lui qui portera le résultat de gestion.

La conséquence pratique

Ne jamais s'arrêter au premier axe quand toutes les corrélations sont positives.

Il dira invariablement « il y a des satisfaits et des mécontents ». L'information neuve est ailleurs.

Ce qu'il faut retenir

Six points

1. **Centrer** est obligatoire; **réduire** est un choix, imposé dès que les unités diffèrent.
2. Sur données réduites, l'ACP porte sur la **matrice des corrélations** et $I_{\text{tot}} = p$.
3. On **lit** cette matrice avant de calculer : blocs, forces, redondances.
4. Nos données montrent deux blocs nets — **offre** et **service** — reliés par $r = 0,09$.
5. Toutes les corrélations positives produisent un **effet taille** sur l'axe 1.
6. En ce cas, **l'information neuve est sur l'axe 2**.

La suite

Les données sont préparées, la matrice est lue, le résultat est presque deviné.

Il reste à le calculer — et le chapitre 6 le fait, en donnant enfin un sens statistique aux valeurs propres.