

# Analyse des données

## Chapitre 19 : Classer un nouveau client

---

Jaouad Madkour

18 août 2026

Faculté d'Économie et de Gestion de Tanger

La règle d'affectation


Mesurer les erreurs

Le scoring

Ce qu'il faut retenir

## La règle d'affectation

---



# Le principe

## Affecter au centre le plus proche

On projette le nouvel individu sur les axes discriminants, on calcule sa distance aux  $K$  centres de groupes, **et on l'affecte au plus proche.**

C'est la règle géométrique, la plus simple, et celle que nous employons.

## Nos trois centres sur l'axe 1

| Groupe       | Centre |
|--------------|--------|
| Rare         | -0,785 |
| Mensuelle    | -0,036 |
| Hebdomadaire | +0,901 |

Un client dont le score discriminant vaut  $+0,6$  sera classé « hebdomadaire » : c'est de ce centre qu'il est le plus proche.

### Ce que la règle géométrique ignore

**Les effectifs.** Si un groupe représente 5 % de la clientèle, l'y affecter devrait demander davantage de preuves. La règle bayésienne pondère par les probabilités a priori.

**Les coûts d'erreur.** Classer à tort un client fidèle en occasionnel n'a pas les mêmes conséquences que l'inverse.

### En pratique, sur nos données

Les trois groupes font 112, 87 et 101 clients : les effectifs sont presque égaux, et la pondération a priori ne changerait presque rien.

**Les coûts, eux, ne sont jamais égaux dans la vraie vie.** Envoyer une offre de reconquête à un client déjà fidèle coûte un timbre ; ne pas l'envoyer à un client sur le départ coûte un client.

## Mesurer les erreurs

---

# La matrice de confusion

| réel               | prédit |           |        | total | % exact |
|--------------------|--------|-----------|--------|-------|---------|
|                    | Rare   | Mensuelle | Hebdo. |       |         |
| Rare               | 78     | 23        | 11     | 112   | 69,6 %  |
| Mensuelle          | 24     | 40        | 23     | 87    | 46,0 %  |
| Hebdomadaire       | 1      | 17        | 83     | 101   | 82,2 %  |
| taux global        |        |           |        | 300   | 67,0 %  |
| validation croisée |        |           |        |       | 65,3 %  |
| hasard             |        |           |        |       | 33,3 %  |

**Le tableau ne se lit pas par son total, mais par ses cases.**

67 % de bons classements contre 33 % au hasard : la règle vaut quelque chose. **Mais la ligne du milieu s'effondre à 46 %** — les clients mensuels, coincés entre les deux extrêmes, sont les moins prévisibles. C'est logique : ils sont au centre de l'axe.

**Une seule erreur grave** : un seul client hebdomadaire classé « Rare ». Les confusions se font toujours entre voisins.

**Et le taux calculé sur les données ayant servi à construire la règle est toujours optimiste.** La validation croisée — on retire un client, on reconstruit la règle sans lui, on le classe — ramène à 65,3 %. C'est ce chiffre-là qu'on publie.

### Trois lectures, du général au détail

**Le taux global** : 67,0 % contre 33,3 % au hasard. La règle apporte quelque chose.

**Le groupe central** : 46,0 % seulement. Les clients mensuels, situés au milieu de l'axe, sont les moins prévisibles — et c'est logique.

**Les erreurs graves** : un seul client hebdomadaire classé « rare ». Les confusions se font entre voisins.

### Un taux global peut cacher un échec

Imaginons un groupe rare, 5 % des clients. Une règle qui ne le prédit **jamais** affiche 95 % de bons classements et ne sert à rien.

**C'est pourquoi on lit toujours les taux ligne par ligne.** Le taux global seul est un mauvais résumé, et il est pourtant celui que les rapports mettent en avant.

### Le problème du resubstitution

Classer les mêmes individus qui ont servi à construire la règle donne un taux **systématiquement trop bon** : la règle a été ajustée sur eux.

Ce chiffre-là ne se publie pas.

### La validation croisée, un contre tous

On retire un client, on reconstruit toute l'AFD sans lui, on le classe, on recommence trois cents fois.

Résultat : 65,3 % au lieu de 67,0 %. L'écart est ici modeste — signe que la règle n'est pas surajustée — mais il aurait pu atteindre dix points sur un petit échantillon.

## Le scoring

---

### Ce qu'on utilise vraiment en entreprise

Non pas la classe prédite, mais **le score lui-même** : la coordonnée sur l'axe discriminant, éventuellement transformée en probabilité.

On ordonne alors les clients du plus au moins probable, et l'on cible autant de clients que le budget le permet.

### La différence est considérable

La règle dit : « ce client sera hebdomadaire ». **Le score dit : « ce client est à +0,62, au 78<sup>e</sup> rang sur 300 ».**

Avec un budget pour deux mille courriers et cinquante mille clients, la classe prédite ne sert à rien — elle en désignerait quinze mille. Le score, lui, désigne les deux mille premiers.

### Deux réserves à écrire dans le rapport

**La règle prédit une association, pas un comportement.** Un client dont le score est élevé ressemble aux clients fidèles; rien ne dit qu'il le deviendra.

**Et le sens de la relation reste inconnu.** Le client note bien le service parce qu'il vient souvent, ou vient souvent parce que le service est bon? L'AFD sépare les groupes; elle n'explique pas pourquoi ils diffèrent.

### Où se trouve la suite

Établir un effet demanderait un dispositif que l'analyse des données ne fournit pas : une expérimentation, ou les méthodes d'inférence causale.

**C'est très exactement le seuil où s'arrêtait le cours d'économétrie** — et c'est le même pour toutes les méthodes descriptives.

Ce qu'il faut retenir

---

## Six points

1. La règle géométrique affecte au **centre le plus proche**.
2. Deux raffinements : les **effectifs a priori** et les **coûts d'erreur**.
3. La **matrice de confusion** se lit ligne par ligne, jamais par son seul total.
4. Chez nous : **67,0 %** global, mais **46,0 %** sur le groupe central.
5. Le taux calculé sur les données d'apprentissage est optimiste : **validation croisée à 65,3 %**.
6. En entreprise, on utilise le **score** et non la classe : il permet de trier et de cibler.

## La suite

Toutes nos méthodes partaient d'un tableau de mesures.

Le dernier chapitre de méthode part d'autre chose : un tableau où l'on n'a mesuré aucune variable, seulement demandé aux gens si deux choses se ressemblent.