

Analyse des données

Chapitre 5 : Classification (CAH et k-means)

Jaouad Madkour

29 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous ?


Classification ascendante hiérarchique

Réallocation dynamique (k-means)

Mesures d'éloignement

Application en gestion

Où en sommes-nous?



Pourquoi ce chapitre ?

Les chapitres précédents **représentaient** les données; celui-ci les **regroupe**. La **classification** cherche une **typologie** — une partition des individus en classes homogènes à l'intérieur et distinctes entre elles. C'est l'outil de la **segmentation** : segmenter une clientèle, un réseau de points de vente, un catalogue de produits, sans connaître les groupes à l'avance.

Segmentation = apprentissage non supervisé

Classer, ici, c'est répartir les individus en **classes** en optimisant un critère : chaque classe la plus **homogène** possible, les classes entre elles les plus **distinctes** possible. Aucune typologie n'est connue au départ : c'est de l'**apprentissage non supervisé** (*clustering*), à distinguer de la **discrimination** (chapitre 3), où les groupes sont connus.

Trop de partitions pour les essayer toutes

Le nombre de partitions d'un ensemble croît **plus qu'exponentiellement** : pour seulement 20 individus, il dépasse 10^{13} . Impossible de toutes les évaluer. Les méthodes se contentent donc d'un **algorithme itératif** convergeant vers une « bonne » partition — en général un **optimum local**.

Quatre décisions


Toute classification suppose de choisir : (i) une **mesure d'éloignement** entre individus; (ii) un **critère d'homogénéité** des classes (souvent lié à la variance inter ou intraclasse); (iii) une **méthode** (hiérarchique ou par réallocation); (iv) le **nombre de classes** — le point le plus délicat.

Classification ascendante hiérarchique

Le principe

Construire un arbre (dendrogramme)

La CAH part de la partition triviale — chaque individu seul dans sa classe — et regroupe **itérativement les deux classes les plus proches**, jusqu'à n'obtenir qu'une seule classe. Les regroupements successifs forment un **arbre binaire**, ou **dendrogramme**, dont la hauteur de chaque branche mesure la distance entre les groupes réunis.



Couper l'arbre

On lit le graphique de la **décroissance de la distance interclasse** (de droite à gauche) : une **rupture nette** signale un bon nombre de classes, exactement comme le coude de l'éboulis en ACP. On **coupe alors le dendrogramme** à cette hauteur pour obtenir la partition.

Une méthode sensible


Attention : une CAH est un objet **sensible**. Modifier une seule distance dans le tableau peut changer le nombre et l'organisation des classes. Il est prudent de **stabiliser** la partition obtenue, et de la **visualiser** sur les axes d'une ACP ou d'un MDS.

Réallocation dynamique (k-means)

L'algorithme des centres mobiles

k-means : k fixé à l'avance

Contrairement à la CAH, le nombre de classes k est **fixé au départ**. On tire au hasard k centres, puis on itère deux étapes jusqu'à convergence : (i) **affecter** chaque individu au centre le plus proche ; (ii) **recalculer** les centres comme barycentres des classes obtenues. Une dizaine d'itérations suffit en général.



Classification mixte

La CAH exige de stocker toute la matrice des distances $n \times n$: coûteux pour de grands volumes. Le k-means, lui, ne fournit pas le nombre de classes. La stratégie **mixte** combine les deux : k-means pour dégrossir un grand fichier en nombreuses petites classes, CAH sur leurs barycentres pour **choisir le nombre de classes**, puis k-means final pour stabiliser.

Mesures d'éloignement

Bien choisir la distance

Ressemblance, dissimilarité, distance

On distingue l'**indice de ressemblance** (similarité), l'**indice de dissemblance** (dissimilarité, nul entre un individu et lui-même), l'**indice de distance** (dissemblance qui s'annule seulement pour des individus identiques) et la **distance** proprement dite (qui vérifie en plus l'inégalité triangulaire). La **distance euclidienne** en est le cas le plus courant.

Réduire les variables quantitatives

Pour des variables quantitatives d'échelles hétérogènes, il est vivement conseillé de les **réduire** avant de calculer les distances — sinon la variable la plus dispersée (par ex. le chiffre d'affaires en euros) écraserait les autres. On peut aussi utiliser la métrique de **Mahalanobis** pour atténuer les corrélations.

Le choix de la distance est déterminant

Le résultat d'une classification dépend **fortement** de la distance retenue. Deux clients peuvent être « proches » par leurs montants d'achat (distance euclidienne) mais « éloignés » par la **forme** de leur comportement (distance fondée sur la corrélation). Comparer plusieurs distances est toujours instructif.

Application en gestion

Segmentation RFM

On décrit chaque client par trois indicateurs **RFM** — **Récence** du dernier achat, **Fréquence** des commandes, **Montant** dépensé — après réduction des variables. Une CAH de Ward, coupée à 4 ou 5 classes, dégage des segments actionnables : « clients fidèles à forte valeur », « nouveaux clients », « clients dormants »... Chaque segment appelle une action marketing différente.

Double classification clients × produits

On peut classer **simultanément** les lignes (clients) et les colonnes (produits) d'un tableau d'achats, et visualiser le résultat en **carte de chaleur** (*heatmap*) réordonnée : des blocs de couleur font apparaître quels **groupes de clients** achètent quels **groupes de produits** — base d'un moteur de recommandation ou d'un plan de merchandising.

Synthèse du chapitre

La classification cherche une **partition** en classes homogènes et distinctes. La **CAH** construit un dendrogramme qu'on coupe pour choisir le nombre de classes; le **k-means** répartit les individus autour de k centres mobiles; la méthode **mixte** combine les deux. Le choix de la **distance** et du **critère de saut** est déterminant, et la partition gagne à être **visualisée** sur une ACP ou un MDS. Classification et MDS sont complémentaires : le MDS place, la classification regroupe.

Vue d'ensemble des cinq chapitres

Nous avons parcouru la chaîne complète de l'analyse exploratoire des données : **décrire** (ch. 1), **résumer** un nuage par l'ACP (ch. 2), **discriminer** des groupes connus par l'AFD (ch. 3), **cartographier** à partir de distances par le MDS (ch. 4), et **regrouper** par la classification (ch. 5). Ces méthodes se combinent : une étude réelle en gestion enchaîne souvent description, ACP, puis segmentation, chacune éclairant les autres.