


Analyse des données

Chapitre 7 : Combien d'axes retenir




Trois critères

Ce que l'on perd


Une remarque sur la stabilité

Ce qu'il faut retenir

Trois critères



L'éboulis des valeurs propres



Les trois critères disent la même chose.

Le coude : la falaise entre l'axe 2 et l'axe 3 — de 1,65 à 0,38. On coupe au pied de la falaise.

Kaiser : garder les axes de valeur propre > 1 , c'est-à-dire ceux qui résument mieux qu'une variable seule. Ici : deux.

Le cumul : $56,7 + 20,6 = 77,3\%$ de l'information conservée sur un simple plan.

Quand les trois concordent, la décision est facile. Quand ils divergent, c'est l'interprétabilité qui tranche.

Ce que chacun propose

Le coude (Cattell) : garder les axes situés avant la rupture de pente de l'éboulis.

Kaiser : garder les axes de valeur propre > 1 — donc plus informatifs qu'une variable seule.

Le cumul : garder assez d'axes pour atteindre un seuil, souvent 70 ou 80 %.

Leur verdict sur nos données

Le coude est entre l'axe 2 et l'axe 3 : la valeur propre chute de 1,645 à 0,382. **Deux axes.**

Kaiser : $4,54 > 1$, $1,65 > 1$, $0,38 < 1$. **Deux axes.**

Le cumul : 77,3 % à deux axes. **Deux axes.**

Le cas fréquent, et il faut le prévoir

Sur des données réelles, Kaiser retient souvent trop d'axes — il est connu pour cela — et le cumul en réclame parfois beaucoup pour atteindre 80 %.

Le coude est alors le plus fiable des trois, parce qu'il regarde une *rupture* et non un seuil arbitraire.

Le vrai critère, et il n'est dans aucun manuel de formules

Un axe se garde s'il s'interprète.

Un troisième axe à 8 % que l'on sait nommer vaut mieux qu'un troisième axe à 12 % dont on ne peut rien dire. L'analyse des données produit du sens; un axe sans sens n'est pas un résultat.

Ce que l'on perd

Nos 22,7 pour cent perdus

Six axes portent l'information restante, aucun ne dépassant 4,8 %. Aucun n'a de structure : leurs valeurs propres sont toutes voisines de 0,3.

C'est la signature du bruit. Quand les dernières valeurs propres forment un plateau, ce qui reste n'est pas de l'information mal résumée : c'est de l'erreur de mesure.

Le contre-exemple qui doit alerter

Si le troisième axe avait valu 1,2 et le quatrième 0,25, il aurait fallu **le garder** — même à 15 %.

Un saut isolé au milieu de l'éboulis signale toujours une dimension réelle. Le plateau, lui, signale le bruit. **C'est la forme de l'éboulis qui parle, pas la hauteur des barres.**

Retenir des axes ne coûte rien, sauf du sens

Rien n'oblige à s'arrêter à deux : le calcul en produit huit. Mais **chaque axe supplémentaire demande une interprétation**, et donc un plan de plus à commenter.

Deux axes donnent un plan. Trois axes en donnent trois : $(1, 2)$, $(1, 3)$, $(2, 3)$.

Et l'inverse est pire

Se limiter à un axe parce qu'il fait **56,7 %** reviendrait ici à ne garder que la satisfaction d'ensemble — et à **perdre exactement le résultat qui intéresse la direction commerciale**.

Le deuxième axe ne pèse que **20,6 %** de l'inertie. Il porte **100 %** de la recommandation.

Une remarque sur la stabilité

Les axes sont-ils solides ?

Une question qu'on ne peut pas tester ici

L'analyse des données n'ayant pas de modèle probabiliste, **il n'existe pas de test de significativité d'un axe.**

On ne saura donc jamais dire « cet axe est significatif à 5 % ». C'est une limite réelle de la méthode, et il faut la connaître.

Ce que l'on peut faire à la place

Couper l'échantillon en deux au hasard, refaire l'ACP sur chaque moitié, et comparer les deux cercles de corrélations.

Si les mêmes blocs de variables réapparaissent aux mêmes places, la structure est solide. Si les axes changent de sens et de composition, elle ne l'est pas. **C'est artisanal, c'est convaincant, et cela ne coûte que deux lignes de code.**

Ce qu'il faut retenir

Six points

1. Trois critères : le **coude**, **Kaiser** ($\lambda > 1$), le **cumul** (70 à 80 %).
2. Sur nos données, les trois concordent : **deux axes**, **77,3 %**.
3. Quand ils divergent, le **coude** est le plus fiable.
4. Le critère qui tranche vraiment est l'**interprétabilité**.
5. Un **plateau** de dernières valeurs propres est la signature du bruit; un **saut isolé** signale une dimension réelle.
6. Il n'existe **aucun test** de significativité d'un axe : on vérifie la stabilité en coupant l'échantillon.

La suite

Deux axes retenus. Il faut maintenant leur donner un nom — et c'est le nuage des variables qui le donne.

Le chapitre 8 lit le cercle des corrélations.