

Analyse des données

Chapitre 1 : Description statistique élémentaire

Jaouad Madkour

30 juillet 2026

Faculté d'Économie et de Gestion de Tanger

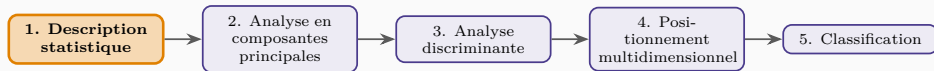
Où en sommes-nous ?

Décrire une variable

Liaison entre deux variables

Vers le cas multidimensionnel

Où en sommes-nous?



Pourquoi ce chapitre?

Avant d'appliquer les méthodes multidimensionnelles (ACP, classification, scoring...), tout analyste de gestion commence par **regarder ses données** : décrire chaque variable, repérer les valeurs aberrantes, mesurer les liaisons entre indicateurs. Ce premier chapitre rassemble les outils de la statistique descriptive — certains classiques, d'autres moins — qui constituent l'étape exploratoire indispensable de toute étude sur un jeu de données d'entreprise (clients, magasins, salariés, produits).

Statistique descriptive

La statistique descriptive fournit des **résumés synthétiques**, si possible graphiques, de séries de valeurs observées sur une population ou un échantillon. Ces résumés sont adaptés au **type** des variables : quantitatives (chiffre d'affaires, âge, note) ou qualitatives (région, catégorie de produit, mention de satisfaction).

Une variable, deux variables, puis p variables

On procède par étapes de complexité croissante : décrire **une** variable isolée (tendance centrale, dispersion), puis étudier la **liaison entre deux** variables, enfin préparer le passage au cas **multidimensionnel** (p variables observées simultanément) qui occupe le reste du cours.

Décrire une variable

Tendance centrale et dispersion

Une variable quantitative (discrète ou continue) est résumée par des indicateurs de **tendance centrale** — moyenne $\bar{x} = \sum_i w_i x_i$, médiane — et de **dispersion** — écart-type σ , intervalle inter-quartiles $Q_3 - Q_1$. D'autres indicateurs décrivent la forme de la distribution.

Asymétrie et aplatissement


La **dissymétrie** (*skewness*), liée au moment d'ordre 3, mesure le déséquilibre gauche/droite de la distribution. L'**aplatissement** (*kurtosis*), lié au moment d'ordre 4, mesure l'épaisseur des queues. En gestion, les distributions de revenus, de tailles d'entreprise ou de montants de commande sont typiquement **asymétriques à droite** (quelques très grandes valeurs).

Chiffre d'affaires d'un réseau de magasins

Le chiffre d'affaires mensuel des points de vente d'une enseigne est rarement symétrique : la majorité des magasins réalisent un CA modéré, tandis que quelques flagships tirent la moyenne vers le haut. La médiane, plus robuste, est alors un meilleur repère de « magasin typique » que la moyenne.

Diagramme-boîte (box-and-whiskers)

Le **diagramme-boîte** résume une série à partir de cinq nombres : minimum, premier quartile Q_1 , médiane, troisième quartile Q_3 , maximum. La boîte contient 50 % des observations; les points au-delà des moustaches signalent des **valeurs atypiques** (*outliers*). C'est l'outil idéal pour comparer plusieurs groupes côte à côte.



Modalités : nominal ou ordinal

Les observations d'une variable qualitative ne sont pas numériques mais sont des **modalités**. Si elles sont naturellement ordonnées (mention « insatisfait < neutre < satisfait », tranche d'âge), la variable est **ordinaire**; sinon (région, secteur d'activité, mode de paiement), elle est **nominale**.

Trois graphiques appropriés


Pour représenter la répartition en effectifs ou en fréquences des modalités, on utilise les diagrammes **en colonnes**, **en barres** ou **en secteurs** (camembert). Tous visent à montrer comment les individus se répartissent entre les catégories.

Liaison entre deux variables

Deux variables quantitatives : le nuage de points

Nuage de points (scatter-plot)

Pour deux variables quantitatives X et Y , le **nuage de points** représente chaque individu par ses coordonnées (x_i, y_i) . Il donne une idée visuelle de la **variation conjointe** des deux variables. Attention au choix des échelles : pour des variables hétérogènes, on représente souvent les variables **centrées-réduites**.



Une quantitative et une qualitative

Boîtes parallèles et décomposition de la variance

Pour croiser une variable quantitative Y avec une variable qualitative X à m modalités, on trace un **diagramme-boîte par sous-population**. La variance de Y se décompose alors en

$$\sigma_Y^2 = \underbrace{\sigma_E^2}_{\text{inter (expliquée)}} + \underbrace{\sigma_R^2}_{\text{intra (résiduelle)}},$$

la variance **inter** (between) mesurant l'écart entre les moyennes de groupes, la variance **intra** (within) la dispersion à l'intérieur des groupes.

Rapport de corrélation

L'indice de liaison associé est le **rapport de corrélation**

$$s_{Y/X}^2 = \frac{\sigma_E^2}{\sigma_Y^2} \in [0, 1].$$

Il vaut 0 quand X n'explique rien (toutes les moyennes de groupes sont égales) et 1 quand X explique toute la variance de Y .

Deux variables qualitatives

Table de contingence

Deux variables qualitatives (X à r modalités, Y à c modalités) observées sur n individus sont croisées dans une **table de contingence** $r \times c$, dont l'élément $n_{\ell h}$ est l'effectif conjoint des modalités x_ℓ et y_h . Les totaux de lignes et de colonnes sont les **effectifs marginaux**.

Khi-deux et indices dérivés

L'absence de liaison correspond à l'égalité de tous les **profils-lignes**. On mesure l'écart à cette situation par le **khi-deux** :

$$\chi^2 = \sum_{\ell=1}^r \sum_{h=1}^c \frac{(n_{\ell h} - s_{\ell h})^2}{s_{\ell h}},$$

où $s_{\ell h}$ est l'effectif attendu sous indépendance. Le χ^2 dépend de n , r et c ; on lui préfère des indices normés : le **phi-deux** $\varphi^2 = \chi^2/n$, le **T de Tschuprow** et le **C de Cramér**, tous compris entre 0 et 1.

Mode de paiement et catégorie de produit

Croiser le mode de paiement (carte, espèces, virement) avec la catégorie de produit achetée révèle d'éventuelles associations : un χ^2 élevé, résumé par un C de Cramér proche de 1, signale que le mode de règlement dépend fortement du type de produit — information précieuse pour concevoir

Vers le cas multidimensionnel

Les matrices S et R

Quand on observe p variables quantitatives sur le même échantillon, on range les variances (diagonale) et les covariances (hors-diagonale) dans la **matrice des variances-covariances** S , carrée $p \times p$, symétrique et semi-définie positive. En normant, on obtient la **matrice des corrélations** R : des 1 sur la diagonale, les corrélations deux à deux ailleurs. R décrit d'un coup d'œil la **structure de corrélation** des indicateurs.

Tableau de nuages (scatter-plot matrix)

Le **tableau de nuages** juxtapose, dans une grille $p \times p$, tous les nuages de points des variables prises deux à deux (avec, sur la diagonale, l'histogramme de chaque variable). Avec la matrice des corrélations, il offre une **vision globale** des liaisons — mais devient illisible dès que p est grand, d'où la nécessité des méthodes factorielles des chapitres suivants.

Les problèmes à surveiller

Fiabiliser les données avant d'analyser

L'exploration préalable sert surtout à **s'assurer de la fiabilité** des données : repérer valeurs extrêmes, erreurs de saisie, incohérences d'unité ou de codage.

Trois difficultés fréquentes

Valeurs manquantes : faut-il supprimer les individus concernés, supprimer une variable, ou imputer les valeurs ? Cela dépend du taux de valeurs manquantes et de leur caractère aléatoire.

Valeurs atypiques : elles influencent fortement les méthodes peu robustes (fondées sur des carrés d'écarts). Sont-ce des erreurs ? Sinon, faut-il transformer les variables ou adopter des méthodes robustes ?

Distributions dissymétriques : une transformation monotone (log, racine, puissance) améliore souvent la symétrie et linéarise les liaisons.

La transformation logarithmique

Les montants de commande, les tailles d'entreprise ou les capitalisations boursières suivent souvent une allure « log-normale » avec de nombreuses valeurs extrêmes. Passer au **logarithme** rend la distribution quasi symétrique et neutralise les outliers — un réflexe systématique avant une ACP ou une

Synthèse du chapitre

Décrire **une** variable (indicateurs, boîte, histogramme), mesurer la **liaison entre deux** variables selon leur type (corrélation, rapport de corrélation, khi-deux/Cramér), puis rassembler l'information dans les matrices S et R : voilà le socle exploratoire. Dès que p dépasse 3 ou 4, les graphiques deux à deux ne suffisent plus — c'est l'objet de l'**Analyse en Composantes Principales**, au chapitre suivant.