


Analyse des données

Chapitre 10 : Du khi-deux à l'analyse des correspondances




Le point de départ

Le passage aux profils

La distance du khi-deux

Ce qu'il faut retenir

Le point de départ



Le tableau croisé

observés	Prix	Choix	Proximité	Service	total
Étudiant	14	2	5	1	22
Employé	45	20	26	10	101
Cadre	8	40	8	16	72
Indépendant	12	19	12	32	75
Retraité	5	1	17	7	30
total	84	82	68	66	300

théoriques	Prix	Choix	Proximité	Service
Étudiant	6,16	6,01	4,99	4,84
Employé	28,28	27,61	22,89	22,22
Cadre	20,16	19,68	16,32	15,84
Indépendant	21,00	20,50	17,00	16,50
Retraité	8,40	8,20	6,80	6,60

Le khi-deux du chapitre 19 de l'inférence.

$$\chi^2 = \sum \frac{(n_{ij} - t_{ij})^2}{t_{ij}} = 110,41$$

Avec 12 degrés de liberté, le seuil à 5 % vaut 21,03.

L'indépendance est rejetée sans hésitation.

Et ensuite ? Le test dit qu'il y a une liaison. **Il ne dit pas laquelle.**

Cinq lignes, quatre colonnes, vingt écarts à commenter — l'AFC va les mettre sur un plan.

Le khi-deux d'indépendance, rappel

$$\chi^2 = \sum_{i,j} \frac{(n_{ij} - t_{ij})^2}{t_{ij}} \quad t_{ij} = \frac{n_{i.} \cdot n_{.j}}{n}$$

Ici $\chi^2 = 110,41$ pour 12 degrés de liberté. Le seuil à 5 % vaut 21,03 : l'indépendance est rejetée.


Et après ?

Le test répond par oui ou par non. Il ne dit pas **quelles cases** créent la liaison, ni **dans quel sens**.

Il faudrait commenter vingt écarts à l'effectif théorique. **L'AFC va les mettre sur un plan** — et le rapprochement avec l'ACP n'est pas une analogie : c'est le même calcul, sur une autre distance.

Le passage aux profils

Comparer ce qui est comparable



L'AFC compare des profils, pas des effectifs.

Il y a 22 étudiants et 101 employés : les comparer en effectifs n'aurait aucun sens.

En **pourcentages de ligne**, la comparaison redevient possible — et l'écart au **profil moyen** devient l'objet de l'analyse.

Un profil ligne égal au profil moyen n'apporte rien : il ira au centre du plan factoriel. C'est exactement ce que dit l'indépendance.

Les deux tableaux de profils

Profils lignes et profils colonnes

Profil ligne i : la répartition des motifs à l'intérieur de la CSP i , soit $n_{ij}/n_{i.}$.

Profil colonne j : la répartition des CSP à l'intérieur du motif j , soit $n_{ij}/n_{.j}$.

Les cinq profils lignes, en pourcentages

CSP	Prix	Choix	Proximité	Service
Étudiant	63,6	9,1	22,7	4,5
Employé	44,6	19,8	25,7	9,9
Cadre	11,1	55,6	11,1	22,2
Indépendant	16,0	25,3	16,0	42,7
Retraité	16,7	3,3	56,7	23,3
profil moyen	28,0	27,3	22,7	22,0

Ce que l'indépendance signifierait

La reformulation qui change tout

Deux variables sont indépendantes **si et seulement si** tous les profils lignes sont égaux au profil moyen.

Et symétriquement pour les profils colonnes.

L'AFC devient alors une ACP

Le nuage à analyser est celui des **cinq profils lignes**, et son centre de gravité est **le profil moyen**.

L'inertie de ce nuage mesure exactement l'écart à l'indépendance. **Chercher ses axes principaux, c'est chercher les directions selon lesquelles les profils s'écartent le plus du profil moyen** — c'est-à-dire les grandes lignes de la liaison.

La distance du khi-deux

Pourquoi pas la distance euclidienne

La distance entre deux profils lignes

$$d^2(i, i') = \sum_j \frac{1}{f_{\cdot j}} \left(\frac{n_{ij}}{n_{i\cdot}} - \frac{n_{i'j}}{n_{i'\cdot}} \right)^2$$

Chaque écart est divisé par la fréquence de la colonne : **les colonnes rares pèsent plus.**

Ce que la pondération corrige

Sans elle, un écart de 10 points sur un motif choisi par la moitié des clients compterait autant qu'un écart de 10 points sur un motif choisi par 5 % d'entre eux.

Or le second est bien plus remarquable. **La division par $f_{\cdot j}$ rétablit l'équilibre** : elle donne du poids à ce qui est rare.

L'équivalence distributionnelle

Si deux colonnes ont **le même profil**, les fusionner en une seule ne change **rien** aux distances entre les lignes.

Aucune autre distance usuelle ne possède cette propriété.

Pourquoi elle est décisive en pratique

Un questionnaire propose « Prix bas » et « Promotions » comme motifs distincts. Si les clients les remplissent de la même façon, le découpage était artificiel.

Avec la distance du khi-deux, le résultat est le même que si l'on avait posé une seule question.

L'analyse ne dépend donc pas du découpage arbitraire des modalités — une garantie que ne donne aucune autre méthode.

Ce qu'il faut retenir

Six points

1. Le **khi-deux** dit qu'il y a liaison ; il ne dit ni où ni dans quel sens.
2. L'AFC compare des **profils**, non des effectifs.
3. L'**indépendance** équivaut à : tous les profils égaux au profil moyen.
4. L'AFC est donc une **ACP du nuage des profils**, centrée sur le profil moyen.
5. La **distance du khi-deux** pondère chaque écart par l'inverse de la fréquence : le rare compte davantage.
6. Son **équivalence distributionnelle** rend l'analyse insensible au découpage des modalités.

La suite

La géométrie est posée. Il reste à voir ce que devient l'inertie dans ce cadre — et l'on va découvrir que le khi-deux et l'inertie sont **le même nombre**, à un facteur près.