


# Analyse des données

## Chapitre 13 : L'analyse des correspondances multiples



Le tableau à analyser


Ce qui change par rapport à l'AFC

La lecture

Ce qu'il faut retenir

## Le tableau à analyser

---



# Le tableau disjonctif complet

| client | fréquence   |       |       | carte |     | motif |       |       |       |
|--------|-------------|-------|-------|-------|-----|-------|-------|-------|-------|
|        | Rare        | Mens. | Hebd. | Oui   | Non | Prix  | Choix | Prox. | Serv. |
| 1      | 0           | 0     | 1     | 1     | 0   | 0     | 1     | 0     | 0     |
| 2      | 1           | 0     | 0     | 0     | 1   | 1     | 0     | 0     | 0     |
| 3      | 0           | 1     | 0     | 1     | 0   | 0     | 0     | 0     | 1     |
| ⋮      |             |       |       |       |     |       |       |       |       |
| 300    | 0           | 0     | 1     | 1     | 0   | 0     | 0     | 1     | 0     |
| somme  | 1 par ligne |       |       | 1     |     | 1     |       |       |       |

**Le tableau disjonctif complet : une colonne par modalité, un seul 1 par variable et par ligne.**

Chaque ligne totalise donc exactement  $p$ , le nombre de variables. Le tableau se comporte alors comme un tableau de contingence — et l'ACM n'est rien d'autre qu'une AFC appliquée à ce tableau.

C'est la même mécanique que les variables indicatrices de l'économétrie, à une différence près : ici on garde *toutes* les modalités, aucune n'est prise comme référence.

### Analyse des correspondances multiples

Une AFC appliquée au tableau disjonctif complet de  $p$  variables qualitatives.

Aucune théorie nouvelle : la même distance du khi-deux, la même décomposition, les mêmes règles de lecture.

### Nos cinq variables

CSP (5 modalités), fréquence (3), carte (2), motif (4), sexe (2).

Total :  $K = 16$  colonnes pour  $p = 5$  variables et  $n = 300$  lignes. Là où l'AFC exigeait dix tableaux, l'ACM n'en demande qu'un.

# Le tableau de Burt

|       | Rare | Mens. | Hebd. | Oui | Non | Prix | Choix | Prox. | Serv. |
|-------|------|-------|-------|-----|-----|------|-------|-------|-------|
| Rare  | 112  | 0     | 0     | 26  | 86  | 32   | 28    | 23    | 29    |
| Mens. | 0    | 87    | 0     | 57  | 30  | 21   | 28    | 21    | 17    |
| Hebd. | 0    | 0     | 101   | 84  | 17  | 31   | 26    | 24    | 20    |
| Oui   | 26   | 57    | 84    | 167 | 0   | 46   | 47    | 40    | 34    |
| Non   | 86   | 30    | 17    | 0   | 133 | 38   | 35    | 28    | 32    |
| Prix  | 32   | 21    | 31    | 46  | 38  | 84   | 0     | 0     | 0     |
| Choix | 28   | 28    | 26    | 47  | 35  | 0    | 82    | 0     | 0     |
| Prox. | 23   | 21    | 24    | 40  | 28  | 0    | 0     | 68    | 0     |
| Serv. | 29   | 17    | 20    | 34  | 32  | 0    | 0     | 0     | 66    |

**Le tableau de Burt : tous les croisements deux à deux, empilés.**

Hors diagonale, chaque bloc est un tableau de contingence ordinaire — *fréquence*  $\times$  *carte*, *fréquence*  $\times$  *motif*. Sur la diagonale, les effectifs de chaque modalité.

**Il donne les mêmes axes que le tableau disjonctif**, à une transformation près des valeurs propres. On le préfère quand le nombre d'individus est très grand : sa taille ne dépend que des modalités.

Sa lecture directe est illisible —  $16 \times 16$  ici, davantage en pratique. **C'est précisément pour cela que l'ACM existe.**

Ce qui change par rapport à l'AFC

---



Une formule qui ne dépend que du comptage

$$I_{\text{tot}} = \frac{K}{p} - 1$$


Ici  $16/5 - 1 = 2,20$ . Cette quantité ne dépend pas des données : elle ne dépend que du nombre de modalités.

La conséquence est sévère

Ajoutez une modalité — découpez l'âge en cinq tranches au lieu de trois — et l'inertie totale augmente, **sans qu'aucune information nouvelle n'entre dans le fichier.**

Les pourcentages d'inertie de l'ACM sont donc **structurellement bas et non comparables** d'une analyse à l'autre. Il faut le savoir avant de lire le premier tableau de sortie.

# Les valeurs propres, et comment ne pas s'en effrayer



## Ne jugez jamais une ACM sur ses pourcentages.

Le premier axe n'affiche que 15 %. Sur une ACP, ce serait un échec ; ici c'est normal.

**Pourquoi :** l'inertie totale d'une ACM vaut  $K/p - 1$  — ici  $16/5 - 1 = 2,20$  — et cette quantité augmente mécaniquement avec le nombre de modalités, sans que l'information augmente.

**La règle de Benzécri :** ne retenir que les axes dont  $\lambda_k > 1/p$ . Ici  $1/5 = 0,20$ , et **cinq axes** passent le seuil. On les interprète par les contributions, jamais par les pourcentages.

## Le seuil

Ne retenir que les axes tels que  $\lambda_k > 1/p$ .

Ici  $1/5 = 0,20$ , et cinq axes passent le seuil : 0,330, 0,296, 0,268, 0,238, 0,205.

## Pourquoi ce seuil-là


Un axe qui ne dépasse pas  $1/p$  n'explique pas plus qu'une modalité prise au hasard.

Benzécri proposait en outre une **correction** des valeurs propres retenues, qui rehausse fortement les pourcentages affichés. On la mentionne sans l'appliquer ici : **le principe à retenir est qu'on interprète une ACM par ses contributions, jamais par ses pourcentages.**

## La lecture

---

# Le plan des modalités



**Lire une ACM, c'est lire des contributions.**

**Axe 1 :** Rare 20,6 %, carte Non 20,0 %, Hebdomadaire 15,2 %, carte Oui 16,0 %. À elles quatre, ces modalités font 72 % de l'axe. **C'est l'axe de la fidélité.**

**Axe 2 :** Prix 21,8 % et Étudiant 16,5 % contre Choix 14,0 % et Cadre 13,5 %.

**Le sexe contribue pour 0,0 % aux deux axes.** Il est au centre, et il faut le dire : cette variable n'apporte rien.

## Axe 1 : la fidélité

Quatre modalités font 71,8 % de l'axe : *Rare* (20,6 %), *carte Non* (20,0 %), *carte Oui* (16,0 %), *Hebdomadaire* (15,2 %).

Deux variables sur cinq construisent donc presque tout le premier axe. **C'est l'axe de l'attachement à l'enseigne**, et il recoupe l'axe 1 de l'ACP — vu du côté des comportements plutôt que des opinions.

## Axe 2 : la position sociale et le motif

*Prix* (21,8 %) et *Étudiant* (16,5 %) d'un côté; *Choix* (14,0 %) et *Cadre* (13,5 %) de l'autre.

**C'est l'axe 1 de l'AFC du chapitre 12**, retrouvé dans une analyse qui ne l'avait pas cherché. Deux méthodes différentes, sur le même fichier, aboutissent au même constat : c'est ce qui donne confiance dans le résultat.

### Le sexe contribue pour zéro pour cent

Femme :  $F_1 = -0,027$ ,  $F_2 = +0,164$ . Homme :  $F_1 = +0,032$ ,  $F_2 = -0,193$ . Contributions arrondies à 0,0 % sur les deux axes.

Les deux modalités sont **collées à l'origine**.

### Il faut l'écrire noir sur blanc

Une modalité au centre du plan est une modalité dont le profil est **le profil moyen** : elle ne distingue rien.

**Le sexe ne structure ni la fréquentation, ni le motif de visite, ni la fidélité.** Le chapitre 9 avait déjà montré qu'il ne structurerait pas la satisfaction. Deux méthodes, deux fois le même résultat négatif — et une segmentation par sexe serait, sur ces données, sans fondement.

Ce qu'il faut retenir

---



### Six points

1. L'ACM est **une AFC du tableau disjonctif complet** : aucune notion nouvelle.
2. Le **tableau de Burt** donne les mêmes axes et se préfère quand  $n$  est très grand.
3. L'inertie totale vaut  $K/p - 1$  : elle **ne dépend que du nombre de modalités**.
4. Les pourcentages sont donc **structurellement bas** et non comparables d'une étude à l'autre.
5. **Règle de Benzécri** : retenir les axes tels que  $\lambda_k > 1/p$  — ici cinq.
6. On interprète par les **contributions**. Une modalité au centre ne distingue rien : c'est le cas du sexe.

### La suite

Nous savons décrire : un plan pour les notes, un plan pour les profils, un plan pour les modalités.

Décrire n'est pas décider. Une direction commerciale ne pilote pas trois cents clients un par un : elle en veut quelques groupes. C'est la quatrième partie.