


Analyse des données

Chapitre 4 : L'idée de l'analyse en composantes principales




Le principe

La contrainte

Ce que l'ACP ne fait pas

Ce qu'il faut retenir

Le principe



Analyse en composantes principales

Méthode qui remplace p variables quantitatives corrélées par un petit nombre de variables **nouvelles**, non corrélées entre elles, appelées **composantes principales**.

Chaque composante est une **combinaison linéaire** des variables d'origine.

Deux gains, et le second est le plus précieux

Le premier gain est la réduction : huit notes deviennent deux composantes, et l'on peut enfin dessiner.

Le second est l'interprétation : les composantes ne sont pas des artefacts de calcul. La première sera « la satisfaction d'ensemble », la seconde « l'offre contre le service ». **L'ACP fait apparaître des dimensions que le questionnaire n'avait pas prévues.**

Une nouvelle variable, fabriquée

$$C_1 = u_{11} z_1 + u_{12} z_2 + \cdots + u_{1p} z_p$$

où les z_j sont les variables centrées-réduites et les u_{1j} des poids, choisis pour que la variance de C_1 soit **maximale**.

Ce que cela donne concrètement

Sur nos données, la première composante donnera à peu près le même poids aux huit notes. **Elle mesure donc une moyenne de satisfaction** — un client qui note haut partout aura un C_1 élevé.

La deuxième opposera les poids : positifs sur le prix, le choix, la qualité ; négatifs sur l'accueil, le conseil, la rapidité. **Elle mesure un écart de jugement entre deux registres**.

La contrainte

Sans contrainte, le problème n'a pas de solution

Si l'on cherche seulement à rendre la variance de C_1 maximale, il suffit de multiplier tous les poids par mille : la variance est multipliée par un million.

Le problème n'aurait pas de maximum. On impose donc $u_{11}^2 + \dots + u_{1p}^2 = 1$: le vecteur des poids est de norme 1.

Le problème complet

$$\max_{\|u\|=1} \mathbb{V}(Xu)$$

puis la même chose pour u_2 , sous la contrainte supplémentaire $u_2 \perp u_1$, et ainsi de suite.

Le résultat central de l'ACP

Les vecteurs de poids cherchés sont les **vecteurs propres** de la matrice des corrélations R , rangés par valeur propre décroissante.

Et la **variance** de la k -ième composante est exactement la k -ième **valeur propre** λ_k .

Rien de neuf, une fois encore

Diagonaliser une matrice symétrique est le programme du cours d'algèbre linéaire. Ce que l'ACP y ajoute, c'est **une lecture statistique** : les vecteurs propres deviennent des directions d'analyse, les valeurs propres des quantités d'information.

Toute l'ACP tient dans cette traduction. Le chapitre 6 la détaille; ce chapitre-ci voulait seulement dire où l'on va.

Ce que l'ACP ne fait pas

L'inventaire

1. Elle ne capte que les liaisons **linéaires**.
2. Elle est sensible aux **points extrêmes**.
3. Elle ne dit rien de la **causalité**, et rien de la significativité.

La première limite est la plus sournoise

Deux variables liées par une relation en U ont une corrélation nulle. L'ACP les traitera comme indépendantes et **manquera complètement la structure**.

D'où la règle : **regarder les nuages deux à deux avant de lancer l'ACP** — au moins pour les variables les plus importantes. Le calcul ne remplace pas le coup d'œil, il le prolonge.

Un client, un axe

Un questionnaire rempli au hasard, ou un client qui a mis 0 partout par mécontentement, se retrouve très loin du centre.

Son inertie individuelle est énorme — et l'ACP, qui maximise l'inertie projetée, peut **construire un axe entier pour lui seul**. On le repère à sa contribution : au-delà de quelques pour cent pour un individu sur trois cents, il faut regarder de près.

Que faire alors

Deux solutions, et la seconde est presque toujours meilleure : le retirer purement et simplement s'il s'agit d'une erreur de saisie, ou **le passer en individu illustratif** s'il est authentique.

Il apparaîtra sur le plan sans avoir servi à le construire. **On le voit sans le subir.**

Ce qu'il faut retenir

Six points

1. L'ACP remplace p variables corrélées par quelques **composantes** non corrélées.
2. Chaque composante est une **combinaison linéaire** des variables réduites.
3. Les poids sont normés à 1, sans quoi le problème n'aurait pas de solution.
4. Les poids sont les **vecteurs propres** de la matrice des corrélations; les variances sont les **valeurs propres**.
5. L'ACP ne voit que le **linéaire** : regarder les nuages avant de calculer.
6. Un **point extrême** peut à lui seul créer un axe : le passer en illustratif.

La suite

Avant de diagonaliser quoi que ce soit, il faut décider sur quelle matrice travailler : celle des covariances, ou celle des corrélations.

Ce choix n'est pas technique — il change les résultats, et le chapitre 5 explique pourquoi.