

Analyse des données

Chapitre 16 : Les k-means et la consolidation

Jaouad Madkour

18 août 2026

Faculté d'Économie et de Gestion de Tanger


L'algorithme des centres mobiles

Choisir le nombre de classes

La consolidation


Ce qu'il faut retenir

L'algorithme des centres mobiles



Les trois étapes

1. Choisir k centres au hasard
2. Affecter chaque point au plus proche
3. Recalculer les centres



Trois étapes, répétées jusqu'à ce que plus rien ne bouge. Sur nos 300 clients, six à vingt itérations suffisent.

Chaque tour *diminue* l'inertie intraclasse : l'algorithme converge donc toujours. **Mais il converge vers un optimum local**, qui dépend des centres de départ — d'où la règle : relancer plusieurs fois, ou partir des centres d'une CAH.

Le critère

$$\min I_{\text{intraclasse}} = \frac{1}{n} \sum_{k=1}^K \sum_{i \in C_k} d^2(i, G_k)$$

Chaque itération le fait décroître : l'algorithme **converge toujours**.

Mais il converge vers un optimum local

Le nombre de partitions possibles de 300 clients en 4 classes dépasse 10^{178} . **Aucun algorithme ne les explore toutes.**

Les k -means descendent depuis leur point de départ jusqu'au premier creux rencontré. Un autre départ peut mener à un autre creux — et il n'existe aucun moyen de savoir si l'on tient le meilleur.

Quatre départs aléatoires, $k = 4$

Départ	Inertie interclasse	Itérations
1	76,51 %	22
7	76,54 %	8
42	76,54 %	16
2026	76,54 %	6


Trois fois le même optimum : bon signe

Quand des départs très différents aboutissent à la même partition, c'est que la structure est **robuste**.

Si les quatre lignes avaient donné 60, 71, 65 et 74 %, il aurait fallu conclure que le nuage n'a pas de groupes nets et **le dire dans le rapport**.

Choisir le nombre de classes

La courbe de l'inertie



Le même coude que l'éboulis, et la même logique.

De 3 à 4 classes, on gagne 9,6 points. De 4 à 5, seulement 3,6.

Au-delà, chaque classe supplémentaire ne fait plus que découper du bruit. La courbe monte encore, mais elle monterait jusqu'à 100 % pour $k = n$ — une classe par client.

Aucun critère ne prouve que 4 est le bon nombre. La CAH le suggérerait, le coude le confirme, et l'interprétation tranche.

Ce que chacune sait faire

	CAH	k -means
Nombre de classes	trouvé	à fournir
Réaffectation	impossible	à chaque tour
Calcul	$O(n^3)$	rapide
Résultat	unique	dépend du départ

Les défauts de l'une sont les qualités de l'autre

La CAH trouve le nombre de classes mais ne se corrige jamais. Les k -means se corrigent sans cesse mais ne trouvent pas le nombre.

La solution évidente : les enchaîner.

La consolidation

En trois temps

1. **ACP** pour obtenir des coordonnées propres.
2. **CAH de Ward** pour déterminer le nombre de classes et une partition initiale.
3. ***k*-means partant des centres de la CAH** pour corriger les affectations regrettables.

Le résultat sur nos clients

Trois itérations. **Vingt-six clients sur trois cents changent de classe.**

L'inertie interclasse passe de **74,93 % à 76,50 %** — un gain de **1,57 point**.

Le tableau de croisement

CAH \ consolidée	C1	C2	C3	C4	total
Classe 1	61	0	0	0	61
Classe 2	17	61	3	1	82
Classe 3	0	0	59	0	59
Classe 4	0	0	5	93	98
total	78	61	67	94	300

La consolidation : le meilleur des deux méthodes.

On part des **centres de la CAH** — qui ont fourni le nombre de classes — et on laisse tourner les k -means.

Trois itérations. 26 clients sur 300 changent de classe.

L'inertie interclasse passe de **74,93 %** à **76,50 %**.

Peu de mouvement, et c'est la bonne nouvelle : la partition ne dépendait pas de l'algorithme. Si la moitié des clients avaient changé de classe, il aurait fallu conclure qu'il n'y a pas de segments dans ces données.

Peu de mouvement est une bonne nouvelle

Vingt-six clients déplacés sur trois cents, c'est 8,7 %. **La partition ne dépendait donc presque pas de l'algorithme.**

Si la moitié des clients avaient changé de classe, la conclusion aurait été tout autre : il aurait fallu écrire que les données ne contiennent pas de segments stables, et renoncer à la segmentation.

La consolidation est un test, autant qu'une amélioration

Elle améliore la partition d'un point et demi — c'est peu.

Mais elle **vérifie** que deux logiques différentes — hiérarchique et itérative — retrouvent les mêmes groupes. **C'est le seul contrôle disponible en l'absence de test statistique.**

Ce qu'il faut retenir

Six points

1. Les k -means alternent **affectation** et **recalcul des centres**, jusqu'à stabilité.
2. Ils minimisent l'inertie **intraclasse** et convergent toujours — vers un **optimum local**.
3. Il faut donc **relancer plusieurs fois** : ici quatre départs donnent **76,5 %**.
4. Le **coude** de la courbe d'inertie confirme $k = 4$.
5. **CAH puis k -means** : l'une donne le nombre, l'autre corrige les affectations.
6. Chez nous, la consolidation déplace **26 clients** et gagne **1,57 point** — la partition est stable.

La suite

Quatre classes, et quatre nombres pour les décrire. Ce n'est pas encore une segmentation.

Une segmentation, c'est quatre portraits qu'un directeur commercial peut lire — et le chapitre 17 les construit.