


Analyse des données

Chapitre 1 : L'objet de l'analyse des données



Un problème que la statistique classique ne traite pas


Explorer plutôt que confirmer

Ce que le cours contient

Une remarque sur notre système universitaire

Ce qu'il faut retenir

Un problème que la statistique
classique ne traite pas



Une situation banale en gestion


Une enseigne interroge trois cents clients sur huit critères de satisfaction, et recueille en plus leur âge, leur profession, leur fréquence de visite, leur panier moyen.

Le fichier fait trois cents lignes et douze colonnes. **Que peut-on en dire?**

Analyse des données

Ensemble de méthodes qui **résumant un tableau à un grand nombre de variables** en le projetant sur un petit nombre de directions, choisies pour conserver le maximum d'information.

Pourquoi les outils précédents ne suffisent pas




Et le problème n'est pas seulement le nombre de graphiques.

Vingt-huit nuages pris deux à deux ne montrent que des liaisons *par paires*. Une structure qui n'apparaît qu'en combinant quatre variables reste invisible sur les vingt-huit.

L'analyse des données ne fait pas plus de graphiques : elle en fait un seul, et le bon.

Ce que le cours prolonge réellement



Ce cours prolonge la statistique descriptive, il ne prolonge pas l'inférence.

Aucune loi de probabilité n'y intervient, aucun test, aucune p -value. On ne parle jamais de population ni d'échantillon : **tout se passe dans le tableau que l'on a sous les yeux**, exactement comme en descriptive.

Ce qui change est la dimension. La descriptive s'arrêtait à deux variables — la covariance, le nuage, le coefficient de corrélation. L'analyse des données reprend ces trois objets et les fait travailler sur trente.

Aucune probabilité dans ce cours

Pas de loi, pas d'estimateur, pas de test, pas de p -value.

On ne remonte pas d'un échantillon vers une population : **on décrit le tableau que l'on a**, exactement comme en statistique descriptive.

Ce n'est pas une lacune, c'est une définition

La statistique inférentielle répond à *cette différence est-elle réelle ?* L'analyse des données répond à *qu'y a-t-il dans ce tableau ?*

Les deux questions sont légitimes; ce ne sont pas les mêmes. Confondre les deux — présenter une segmentation comme un fait démontré — est l'erreur la plus fréquente des mémoires de gestion.

Explorer plutôt que confirmer

Les deux démarches

Démarche confirmatoire

Statistique inférentielle, économétrie

une hypothèse **posée d'avance**



les données tranchent

on sait ce qu'on cherche

Démarche exploratoire

Analyse des données

aucune hypothèse préalable



les données suggèrent

on cherche ce qu'on ne sait pas

Les deux démarches ne s'opposent pas : elles se suivent.

L'exploration fait *naître* les hypothèses ; la confirmation les *juge*. Une segmentation obtenue par classification n'est pas un résultat prouvé : c'est une hypothèse de travail, qu'il faudra tester sur d'autres données.

Le danger est de présenter comme démontré ce qui n'a été qu'observé. Aucune *p*-value ne sortira de ce cours ; ce n'est pas un oubli.

Jean-Paul Benzécri, années soixante

L'analyse des données à la française naît de la linguistique et du dépouillement d'enquêtes, non de la théorie des probabilités.

Sa devise est restée : « *L'analyse des données est un outil pour dégager de la gangue des données le pur diamant de la véridique nature.* »

Le principe qui en découle

Le modèle doit suivre les données, et non l'inverse.

Là où l'économétrie pose une forme — une droite, une équation — et demande aux données de l'ajuster, l'analyse des données ne pose rien et laisse la structure apparaître. C'est un renversement complet de la démarche.

Ce que le cours contient

Les six familles de méthodes

	Variables quantitatives	Variables qualitatives	
Décrire	ACP chapitres 4 à 9	AFC et ACM chapitres 10 à 13	
Classer	CAH et <i>k</i>-means chapitres 14 à 17	les mêmes, après une AFC ou une ACM	MDS à partir de simples distances chapitre 20
Prédire	AFD chapitres 18 et 19	régression logistique <i>hors programme</i>	

Une seule question commande le choix : quelle est la nature des variables, et que veut-on en faire ?

Décrire un nuage, y former des groupes, ou séparer des groupes déjà connus. Les six méthodes du cours remplissent ce tableau — il n'y a pas d'autre case.

Le fichier clients.csv

Individus	300 clients d'une enseigne
Notes de satisfaction	8 critères, de 0 à 20
Signalétique	sexe, âge, CSP, fréquence, carte, panier, motif
Complément	8 enseignes concurrentes, jugées deux à deux

Un seul terrain, six méthodes

Les huit notes donneront l'**ACP**. La CSP croisée au motif de visite donnera l'**AFC**. Les variables qualitatives ensemble donneront l'**ACM**. Les clients seront **classés**, puis **discriminés**, et les enseignes **positionnées**.

Chaque méthode répondra à une question de gestion différente, sur le même fichier.

Une remarque sur notre système universitaire

Une frontière difficile à justifier

Dans nos maquettes, l'analyse des données figure au programme des étudiants de **gestion**, rarement à celui des étudiants d'**économie**.

La justification implicite : ce serait un outil d'études de marché, non un outil d'analyse économique.

Pourquoi cette frontière ne tient pas

Les typologies de régions, de branches, de pays, de trajectoires professionnelles, la construction d'indicateurs composites de développement, la mesure des inégalités multidimensionnelles — **tous relèvent de ces méthodes**.

Un économiste qui ne les possède pas se prive de la moitié des données dont il dispose. Les applications de ce cours seront commerciales ; **les méthodes, elles, ne le sont pas**.

Ce qu'il faut retenir

Six points

1. L'analyse des données **résume un tableau à beaucoup de variables** en le projetant sur peu de directions.
2. Elle prolonge la **statistique descriptive**, non l'inférence : ni loi, ni test, ni p -value.
3. Sa démarche est **exploratoire** : elle fait naître les hypothèses, elle ne les juge pas.
4. Six familles : **ACP, AFC, ACM, classification, AFD, MDS**.
5. Le fil rouge est une **enquête de satisfaction** sur 300 clients d'une enseigne.
6. Ses applications sont commerciales, **ses méthodes ne le sont pas** : elles valent pour toute donnée multidimensionnelle.

La suite

Avant toute méthode, il faut regarder le tableau : quelles variables construiront l'analyse, lesquelles ne feront que l'éclairer.

C'est la décision la plus lourde de conséquences de toute l'étude, et c'est le chapitre 2.