

Chapitre 13

Les méthodes d'apprentissage automatique

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse quantitative


1 Exercices du chapitre

Correction — Exercice 1

(a) $x = 45\,000 : (45\,000 - 52\,000)/15\,000 = -0,4667$. $x = 80\,000 : (80\,000 - 52\,000)/15\,000 = 1,8667$.

(b) $x = 45\,000 : (45\,000 - 20\,000)/(120\,000 - 20\,000) = 0,25$. $x = 80\,000 : (80\,000 - 20\,000)/(120\,000 - 20\,000) = 0,60$.

(c) Oui, les deux transformations sont des fonctions **affines croissantes** de x et préservent donc parfaitement l'ordre des observations. Mais elles ne donnent **pas** la même lecture : la valeur standardisée (1,87) dit « combien d'écarts-types au-dessus de la moyenne », alors que la valeur normalisée (0,60) dit seulement « où se situe l'observation entre le minimum et le maximum », sans référence à la dispersion typique des données.




Correction — Exercice 2

(a) $2,4 + 0,5 + 0,1 = 3,0 \checkmark$, conforme à la propriété d'une ACP sur variables standardisées.

(b) Part de PC1 = $2,4/3 = 80,00\%$.

(c) Part de PC1+PC2 = $(2,4 + 0,5)/3 = 2,9/3 \approx 96,67\%$. En pratique, **deux** composantes suffiraient largement à résumer l'information : elles couvrent déjà près de 97 % de la variance totale, laissant la troisième composante (3,33 %) proche du bruit.




Correction — Exercice 3

(a) Distances à $c_1 = (1,1)$: $A \approx 1,414$, $B = 1,000$, $C \approx 5,000$, $D \approx 6,403$. Distances à $c_2 = (5,5)$: $A \approx 7,071$, $B \approx 5,000$, $C \approx 1,414$, $D \approx 1,414$. Affectation : $A \rightarrow$ groupe 1, $B \rightarrow$ groupe 1, $C \rightarrow$ groupe 2, $D \rightarrow$ groupe 2.

(b) Nouveau centre du groupe 1 (moyenne de A, B) = $(0,5 ; 1)$. Nouveau centre du groupe 2 (moyenne de C, D) = $(5 ; 4,5)$.

(c) Les nouveaux centres $(0,5 ; 1)$ et $(5 ; 4,5)$ sont **différents** des centres initiaux $(1,1)$ et $(5,5)$ — l'algorithme n'a pas encore convergé. On répéterait l'itération : recalculer les distances de chaque point aux **nouveaux** centres, réaffecter si nécessaire, puis recalculer les centres à nouveau, jusqu'à ce que les affectations cessent de changer (stabilisation).




2 Exercices cumulatifs (introduction au chapitre 13)

Correction — Exercice 4

(a) $\lambda_1 = 1 + 0,92 = 1,92$. $\lambda_2 = 1 - 0,92 = 0,08$.

(b) Part de PC1 = $1,92/2 = 96,00\%$.

(c) Remplacer X_1 et X_2 par leur première composante principale règle le problème à la racine : par construction, les composantes principales sont **orthogonales** (non corrélées) entre elles – il ne peut donc plus y avoir de multicollinéarité, quel que soit le VIF initial des variables d'origine. Et comme cette unique composante restitue 96 % de la variance conjointe de X_1 et X_2 , on perd très peu d'information en abandonnant la seconde composante. C'est exactement le lien annoncé par le cours entre ACP et multicollinéarité du chapitre 8.




3 Applications en sciences économiques

Correction — Exercice 5

(a) Les trois premiers clients (10, 12, 11) sont plus proches de $c_1 = 10$; les trois derniers (50, 55, 52) sont plus proches de $c_2 = 50$.

(b) Nouveau $c_1 = (10 + 12 + 11)/3 = 11,0$. Nouveau $c_2 = (50 + 55 + 52)/3 \approx 52,33$.

(c) Oui : les deux groupes sont **nettement séparés** (écart d'environ 40 centaines de dirhams entre les deux centres, contre une dispersion interne à chaque groupe de seulement quelques unités), signe de deux segments de clientèle bien distincts. Sans remise à l'échelle préalable, une variable exprimée en dirhams (des milliers) écraserait totalement l'influence d'une variable comme l'âge (quelques dizaines) dans le calcul des distances euclidiennes : les K-moyennes finiraient par ne segmenter que sur la variable de plus grande échelle, quelle que soit sa pertinence réelle.



Correction — Exercice 6

- (a) Sans l'outlier : $(50\,000 - 30\,000) / (50\,000 - 30\,000) = 1,00$ (c'est le maximum de la série).
 (b) Avec l'outlier : $(50\,000 - 30\,000) / (900\,000 - 30\,000) = 20\,000 / 870\,000 \approx 0,023$.
 (c) Oui, de façon spectaculaire : la même observation passe de 1,00 (le maximum relatif du groupe) à 0,023 (quasiment nul) selon qu'on inclut ou non la valeur aberrante. Une seule observation extrême **comprime** tout le reste des données dans une plage étroite proche de 0, les rendant quasiment indiscernables entre elles – exactement la mise en garde du cours. La standardisation, elle, resterait beaucoup plus robuste : l'outlier gonflerait l'écart-type, mais sans écraser le reste de la distribution de façon aussi extrême.

