

Chapitre 13

Les méthodes d'apprentissage automatique

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse quantitative

1 Exercices du chapitre

Exercice 1 — Standardiser et normaliser une variable

La variable « revenu annuel » a pour moyenne $\hat{\mu} = 52\,000$ et écart-type $\hat{\sigma} = 15\,000$ dans l'échantillon, avec un minimum de 20 000 et un maximum de 120 000.

- (a) Calculer la valeur standardisée de $x = 45\,000$ et de $x = 80\,000$.
- (b) Calculer la valeur normalisée (min-max) de ces deux mêmes observations.
- (c) Les deux transformations préservent-elles l'ordre des observations? Donnent-elles la même interprétation de « combien $x = 80\,000$ est-il au-dessus de la moyenne »?

Exercice 2 — Part de variance expliquée par l'ACP

Une ACP sur 3 variables standardisées donne les valeurs propres $\lambda_1 = 2,4$, $\lambda_2 = 0,5$, $\lambda_3 = 0,1$.

- (a) Vérifier que la somme des valeurs propres vaut 3 (nombre de variables standardisées).
- (b) Calculer la part de variance expliquée par la première composante seule.
- (c) Calculer la part de variance expliquée par les deux premières composantes ensemble. Combien de composantes suffiraient, en pratique, à résumer l'essentiel de l'information?

Exercice 3 — Une itération des K-moyennes

On applique les K-moyennes ($K = 2$) à quatre points $A = (0,0)$, $B = (1,2)$, $C = (4,5)$, $D = (6,4)$, avec centres initiaux $c_1 = (1,1)$ et $c_2 = (5,5)$.

- (a) Calculer la distance euclidienne de chaque point aux deux centres, et affecter chaque point au centre le plus proche.
- (b) Recalculer chaque centre comme la moyenne des points de son groupe.
- (c) Les nouveaux centres sont-ils identiques aux centres initiaux? Que ferait-on à l'itération suivante si ce n'est pas le cas?

2 Exercices cumulatifs (introduction au chapitre 13)

Exercice 4 — L'ACP comme remède à la multicolinéarité du chapitre 8

Au chapitre 8 (exercice 1), la variable X_2 affichait un $VIF = 12,5$, signe de multicolinéarité sévère avec les autres variables explicatives. On simplifie ici la situation à deux variables X_1, X_2 de corrélation $\rho = 0,92$ (cohérente avec un VIF aussi élevé), standardisées.

- (a) Pour deux variables standardisées de corrélation ρ , la matrice de corrélation a pour valeurs propres $\lambda_1 = 1 + \rho$ et $\lambda_2 = 1 - \rho$. Calculer ces deux valeurs propres.
- (b) Calculer la part de variance expliquée par la première composante principale seule.
- (c) En quoi remplacer X_1 et X_2 par leur première composante principale règle-t-il directement le problème de multicolinéarité identifié au chapitre 8, tout en conservant la quasi-totalité de l'information?

3 Applications en sciences économiques

Exercice 5 — Segmenter des clients par leur montant moyen de transaction

Six clients ont pour montant moyen de transaction (en centaines de dirhams) : 10, 12, 11, 50, 55, 52. On applique les K-moyennes ($K = 2$) avec centres initiaux $c_1 = 10$ et $c_2 = 50$.

- (a) Affecter chaque client au centre le plus proche.
- (b) Recalculer les deux nouveaux centres.
- (c) Ce résultat est-il cohérent avec l'existence de deux segments de clientèle bien séparés ? Pourquoi la remise à l'échelle est-elle indispensable avant d'appliquer les K-moyennes sur des variables d'unités différentes (par exemple montant en dirhams et âge en années) ?

Exercice 6 — Une valeur aberrante compresse la normalisation min-max

Un jeu de données de revenus (en dirhams) comprend 30 000, 35 000, 40 000, 45 000, 50 000, auquel s'ajoute une valeur aberrante de 900 000 (erreur de saisie ou cas extrême réel).

- (a) Calculer la valeur normalisée (min-max) de $x = 50\,000$ **sans** la valeur aberrante.
- (b) Calculer la valeur normalisée de ce même $x = 50\,000$ **avec** la valeur aberrante incluse dans le calcul du minimum et du maximum.
- (c) Ce contraste illustre-t-il pourquoi le cours recommande la standardisation plutôt que la normalisation min-max en présence de valeurs extrêmes ?